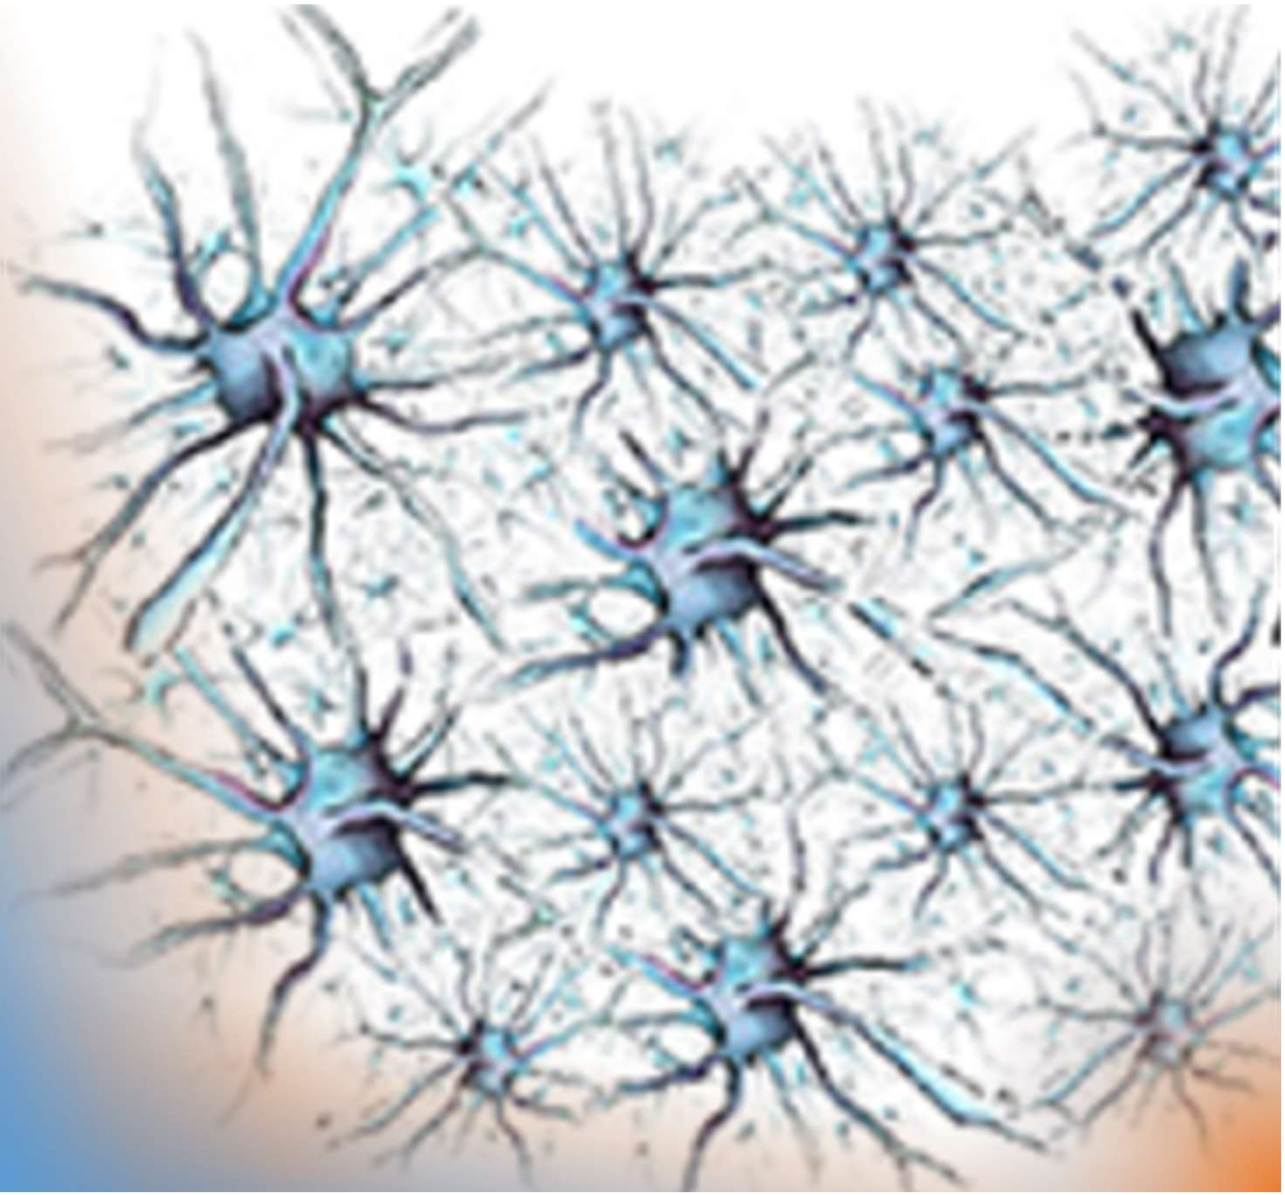


5 - Redes Neuronais Artificiais e Aprendizagem Profunda

Carlos Ramos

csr@isep.ipp.pt

Unidade Curricular:
Inteligência Artificial

Curso: Licenciatura em Engenharia Informática (ISEP)

Visão Geral da Aprendizagem Automática

- A Aprendizagem Automática (Machine Learning) é uma área da Inteligência Artificial
- Ao longo dos anos tem havido contributos de outros domínios científicos:
  - Reconhecimento de padrões (Pattern Recognition)
  - Estatística
  - Sistemas de Informação
- E…vários nomes
  - Extração e Descoberta de Conhecimento (Data Mining, Knowledge Discovery)

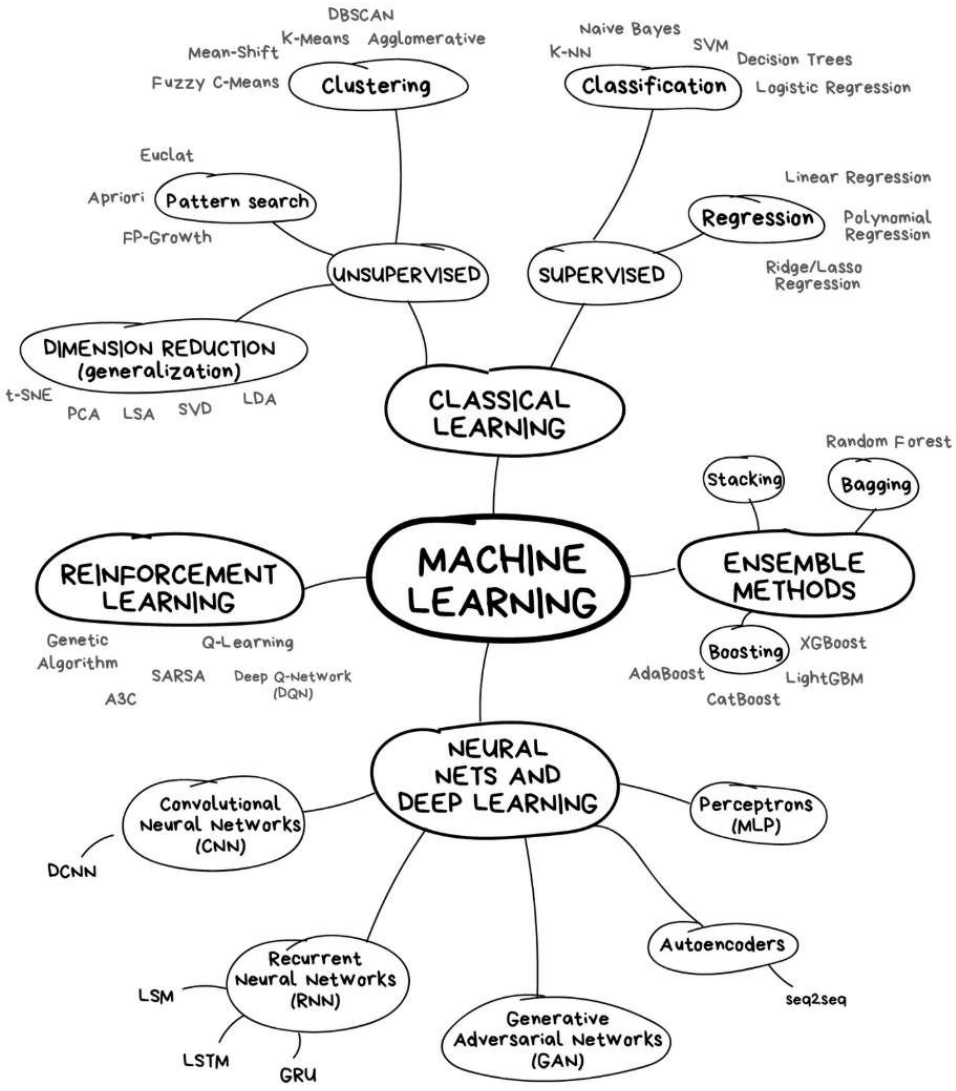


Figura retirada de https://vas3k.com/blog/machine_learning/

Métodos Clássicos de Aprendizagem Automática

- **Aprendizagem Supervisionada** – alguém indicou previamente o que é importante encontrar
  - **Classificação** – Prever se um determinado item cai numa ou noutra categoria já identificada anteriormente
    - Por exemplo. classificar numa imagem de uma cão qual é a sua raça (chiuaua ou labrador)
  - **Regressão** – usamos os dados que temos para adaptar a melhor forma que os representa
    - Por exemplo, dado um conjunto de pontos num gráfico y=f(x) determinar qual a reta que melhor os aproxima
- **Aprendizagem não Supervisionada** – não foi indicado previamente o que se pretendia encontrar, o sistema terá de encontrar padrões por si só
  - **Clustering** – Não tem classes pré-definidas, o objetivo é criar essas classes
    - Por exemplo, segmentar os clientes de um determinado produto
  - **Redução de Dimensão ou Generalização** – agrupa categorias conhecidas em outras mais gerais
  - **Associação** – associa itens
    - Por exemplo, quem compra uma impressora também comprará toners ou quem compra carnes vermelhas provavelmente comprará vinhos tintos

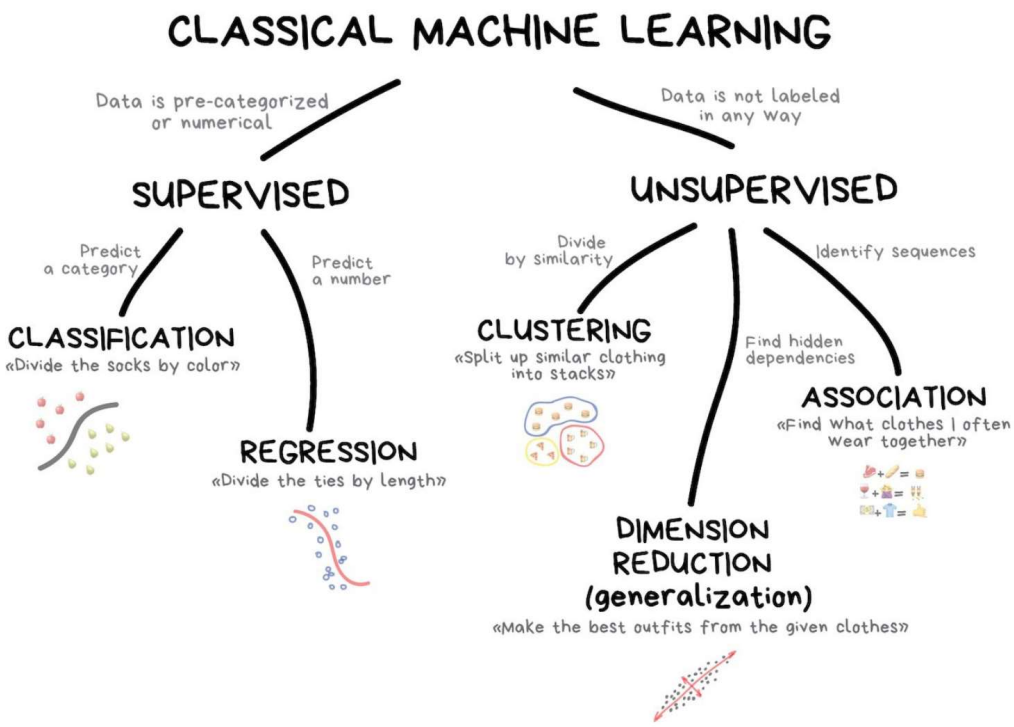


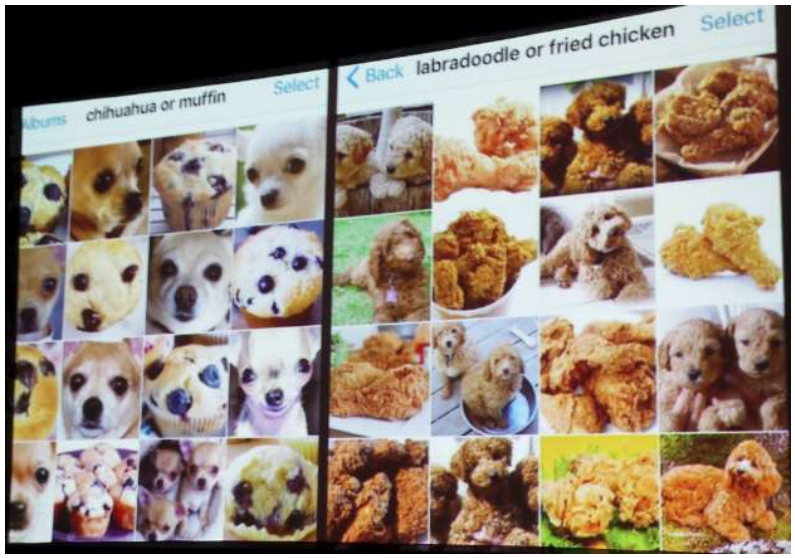
Figura retirada de https://vas3k.com/blog/machine_learning/

Uma boa listagem de algoritmos de ML está em https://machinelearningmastery.com/a-tour-of-machine-learning-algorithms/

As técnicas de Aprendizagem Automática têm tido muito sucesso, mas também têm também suas falhas e limitações

Incluindo Deep Learninig!

2 Exemplos de Aprendizagem Automática para Imagem/Visão por Computador:



Apenas identificam aquilo para que foram treinadas



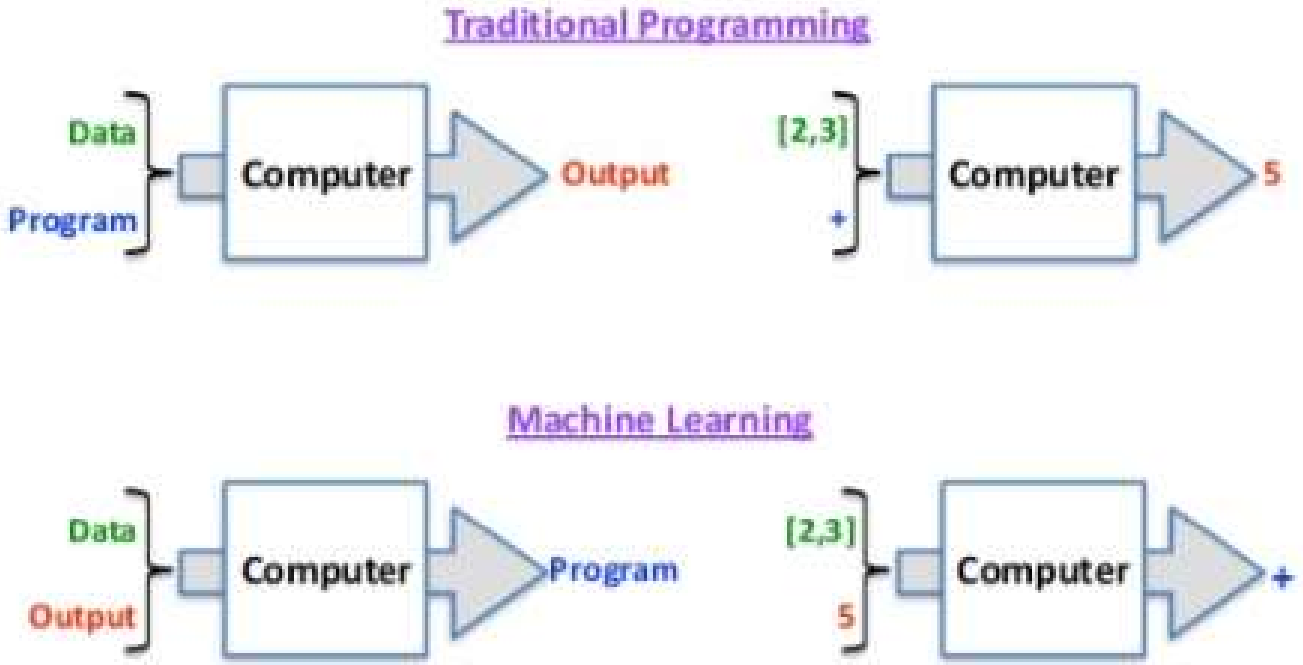
São capazes de efetuar classificação, previsão, etc
Mas têm dificuldade em compreender ou explicar

São um tipo de Black Box

Não são propriamente uma caixa mágica onde se colocam os dados na entrada e sai conhecimento na saída

Aprendizagem Automática (Machine Learning)

- ML representa uma maneira diferente de desenvolver sistemas



Métodos de Aprendizagem Automática

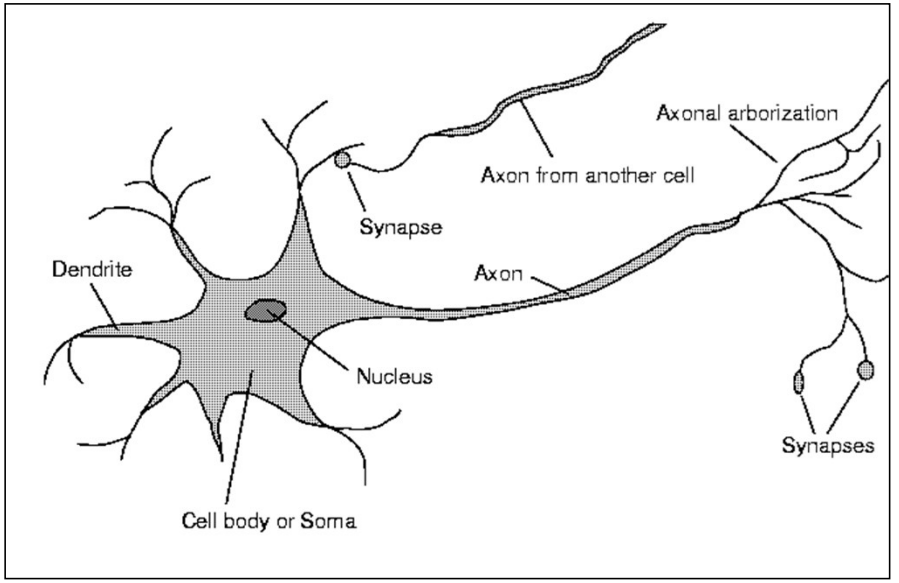
Há vários métodos de Aprendizagem Automática (Machine Learning)

- Naive-Bayes
- Árvores de Decisão
- KNN
- Redes Neuronais Artificiais
- …

As Redes Neuronais Artificiais correspondem a um método muito usado, por isso iremos centrar-nos no seu estudo. É também nelas que assentam as abordagens de Aprendizagem Profunda

Redes Neuronais (Neural Networks)

- Nascemos com ~100 mil milhões de neurónios
- Um neurónio pode conectar cerca de 100 mil outros neurónios através de sinais (eletroquímicos)
- As sinapses (que ligam os neurónios) podem libertar uma dada quantidade de transmissores químicos
- O valor acumulado que vem de várias sinapses pode ativar o neurónio quando este ultrapassa um determinado valor de threshold



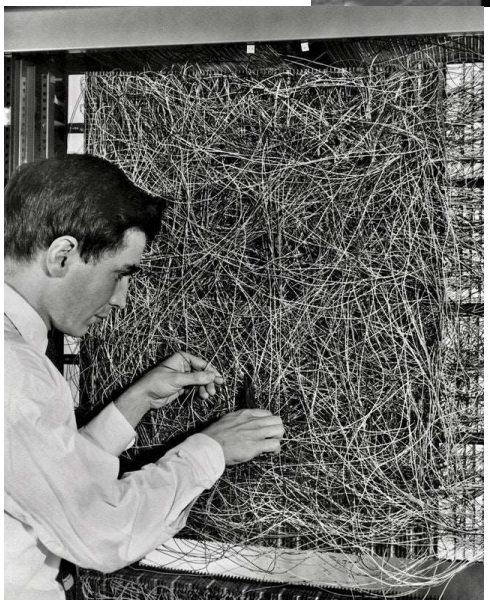
Neurónio Artificial e Perceptron

Em 1943 Warren McCulloch e Walter Pitts, desenvolvem o que é considerado o primeiro trabalho na área da IA, o modelo do Neurónio Artificial

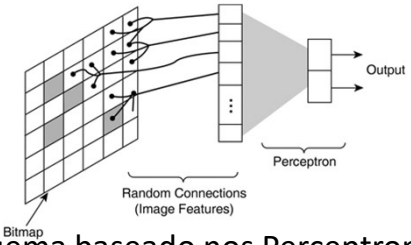
Em 1958 o Psicólogo Frank Rosenblatt introduz o conceito de Perceptron, que pode ser entendido como um elemento de aprendizagem supervisionada com classificadores binários

Desenvolveu trabalho no Mark1, um computador orientado para reconhecimento de imagem com 400 fotocélulas conectadas aos neurónios artificiais (perceptrons). Os pesos das entradas dos neurónios eram obtidos pela variação de potenciómetros





Frank Rosenblatt e o computador MARK1, um computador com perceptrons



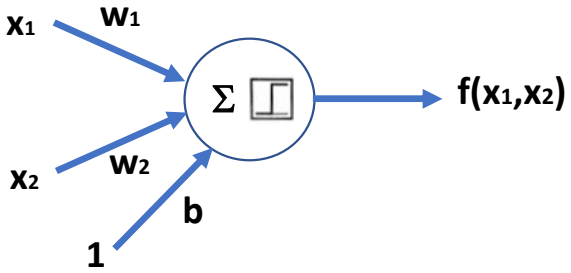
Esquema baseado nos Perceptrons de Rosenblatt
O “bitmap” gerado conecta-se às entradas dos perceptorns
À saída podemos classificar a imagem

Perceptron

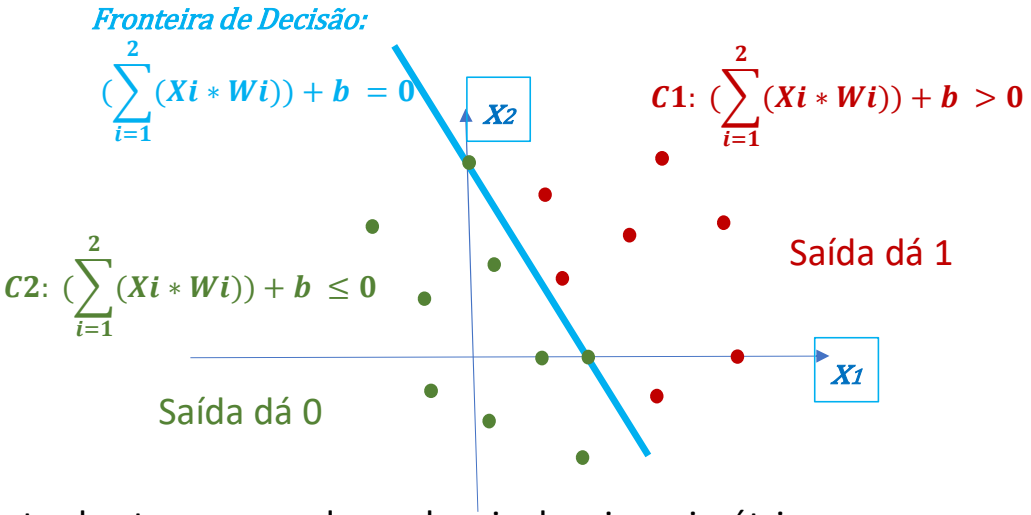
O Perceptron de Rosenblatt usa o modelo de nourónio de McCulloch-Pitts

Contudo, o Perceptron permite efetuar uma aprendizagem supervisionada para classificar uma entidade entre duas classes C1 e C2 separadas por uma fronteira de decisão

$$\begin{cases} f(X1,\dots,Xn) = 1 \; se \; (\sum_{i=1}^{n}(Xi * Wi)) + b \; > 0 \\ f(X1,\dots,Xn) = 0 \; caso \; contrário \end{cases}$$

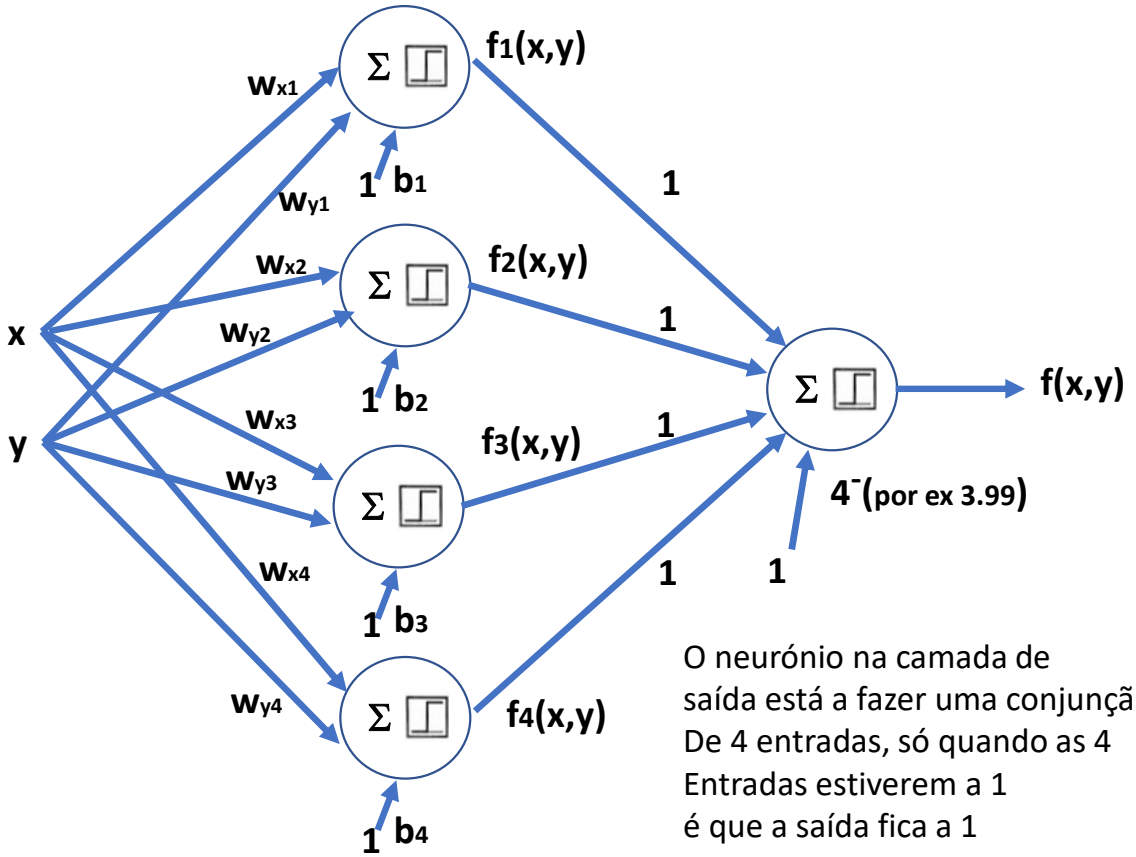


Um neurónio com 2 entradas corresponde a uma Fronteira de decisão bidimensional

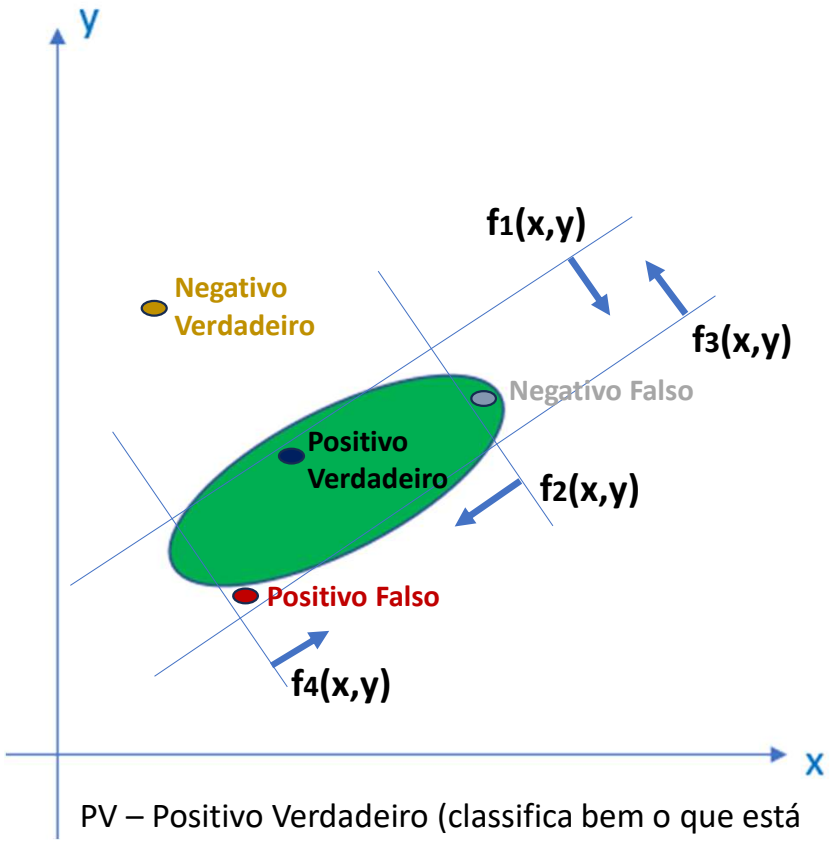


Para inverter basta que os valores de wi e b sejam simétricos fazendo com que na saída os pontos verdes originem 1 e os vermelhos 0

Exemplo: detetar um cluster de pontos num espaço x-y



O neurónio na camada de saída está a fazer uma conjunção De 4 entradas, só quando as 4 Entradas estiverem a 1 é que a saída fica a 1



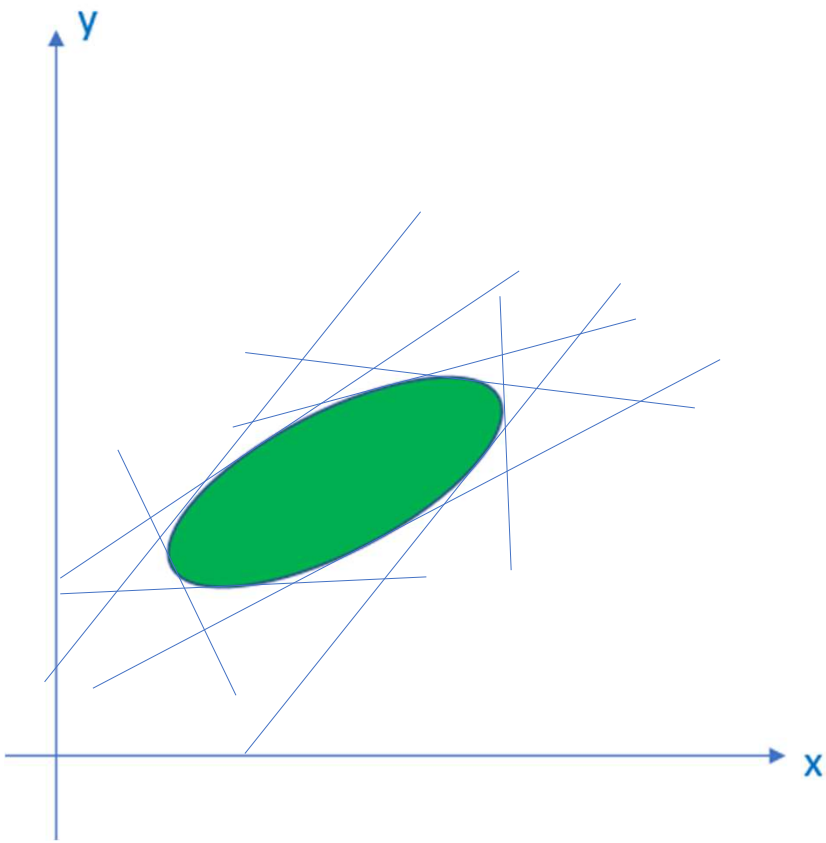
PV – Positivo Verdadeiro (classifica bem o que está dentro da elipse)

NV - Negativo Verdadeiro (classifica bem o que está fora da elipse)

PF – Positivo Falso (classifica como estando dentro da elipse, mas está fora)

NF – Negativo Falso (classifica como estando fora da elipse, mas está dentro)

Exemplo: detetar um cluster de pontos num espaço x-y

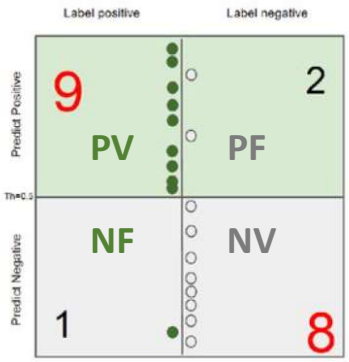


Quantas mais retas tivermos
mais nos conseguimos aproximar
da forma do cluster e portanto
reduzir os falsos e melhorar a precisão e
Acurácia da classificação

Mais retas -> mais neurónios

Contudo, não sabemos a princípio os valores
De wi e de b de todos os neurónios que
correspondam às retas ideais (próximas da
ilustrada na figura). Deverá haver um processo
de ajuste desses valores (treino da rede)

Metricas de Classificação



Matriz de Confusão, uma matriz que ilustra O número de positivos Verdadeiro (PV), Negativos Verdadeiros (NV), Positivos Falsos (PF) e Negativos Falsos (NF)

As principais métricas de classificação são:

- Acurácia
- Erro
- Precisão
- Recall
- F1score

Acurácia $= \frac{PV+NV}{Positivos+Negativos} = \frac{PV+NV}{PV+NV+PF+NF}$

Erro é dado por: $\boldsymbol{Erro = 1 - Acurácia}$

Accuracia = $\frac{9+8}{9+8+1+2}$ = 0.85

$Erro = 1 - 0.85 = 0.15$

$$\boldsymbol{Precisão = \frac{PV}{PV + PF}}$$

$Precisão = \frac{9}{9+2}$ = 0.818

$$\boldsymbol{Recall = \frac{PV}{PV + NF}}$$

$Recall = \frac{9}{9+1}$ = 0.9

$$\boldsymbol{F1score = 2 * \frac{Precisão * Recall}{Precisão + Recall} = \frac{2 * PV}{2 * PV + NF + PF}}$$

$F1score = \frac{2*9}{2*9+1+2}$ = 0.857

Redes Neuronais

Os neurónios artificiais conetam-se através de redes de neurónios

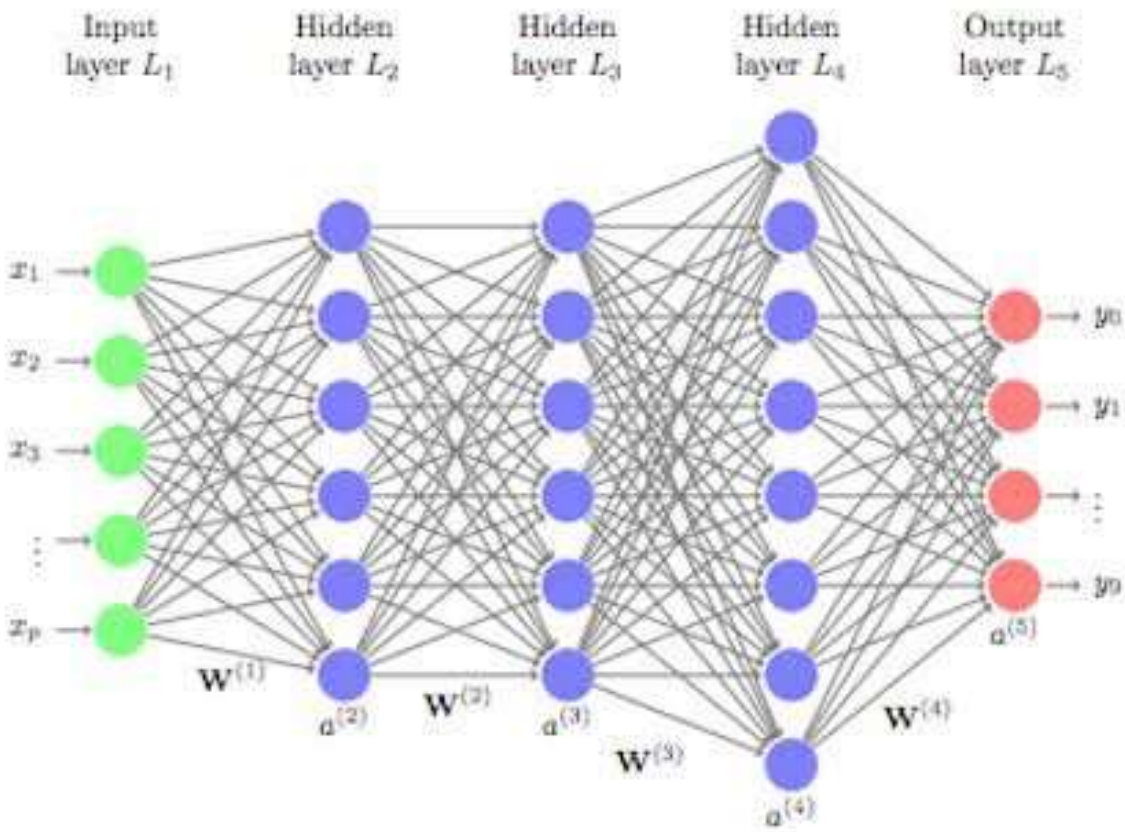
Camada de Entrada

Camadas Escondidas

Camada de Saída

Um neurónio com N entradas corresponde a uma entidade num espaço N-dimensional:

- N=2: reta
- N=3: plano
- …

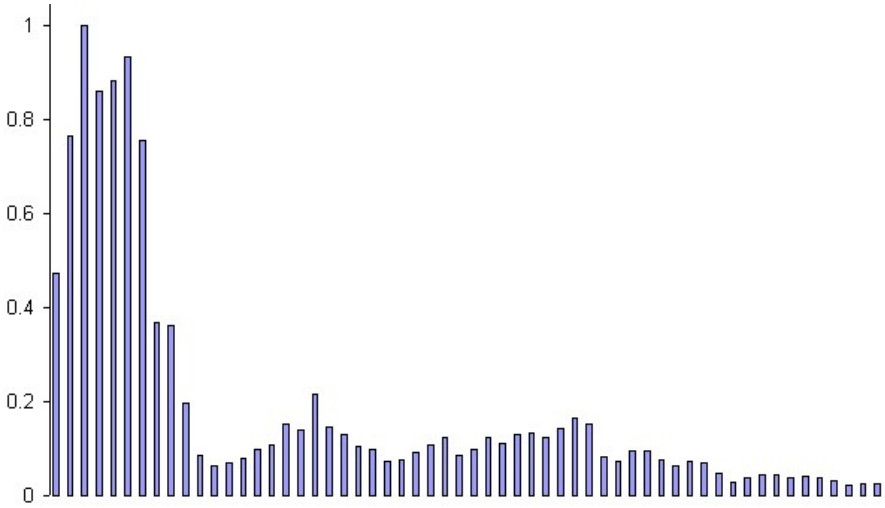


Rede Neuronal Multi-camada

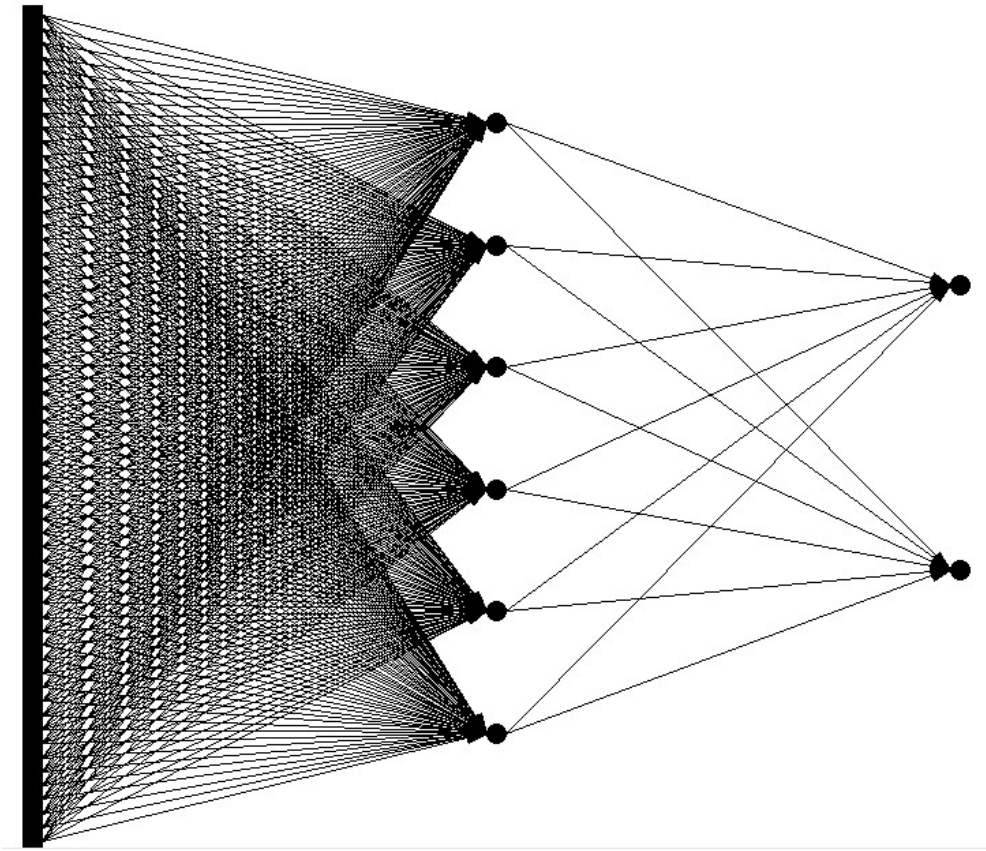
Exemplo: Reconhecimento de Voz

- Tarefa: Aprender a distinguir duas vozes diferentes dizendo “Hello”

- Dados
  - Fontes
    - Steve Simpson
    - David Raubenheimer
  - Formato
    - Distribuição no espetro de frequências(60 bins)

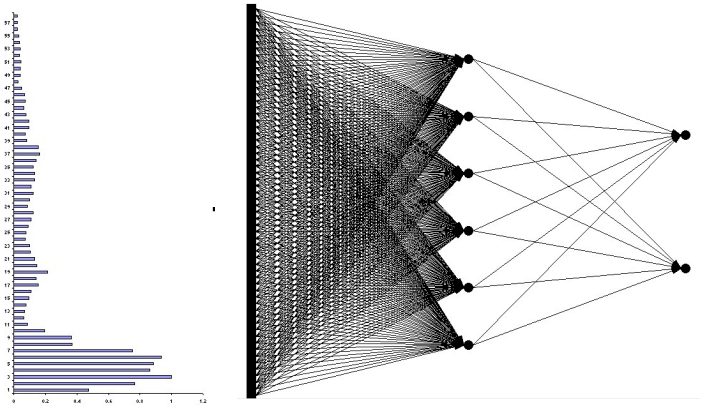


- Arquitetura da ANN
  - Feed forward
  - 60 entradas (uma para cada nível do espetro de frequências)
    - 6 camadas escondidas (hidden layers)
    - 2 saídas(0-1 para o Steve, 1-0 para o David)

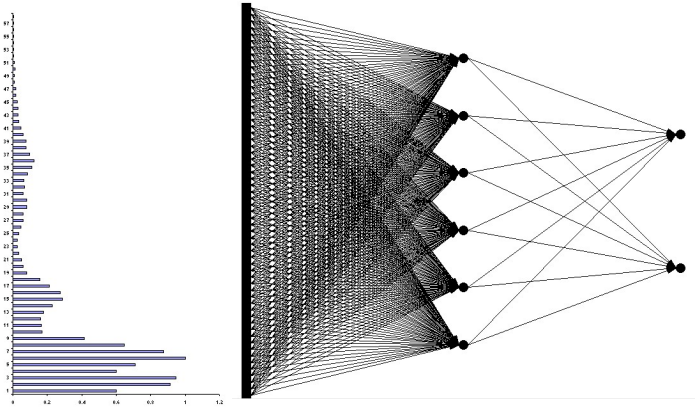


- Introduzindo os Dados

Steve

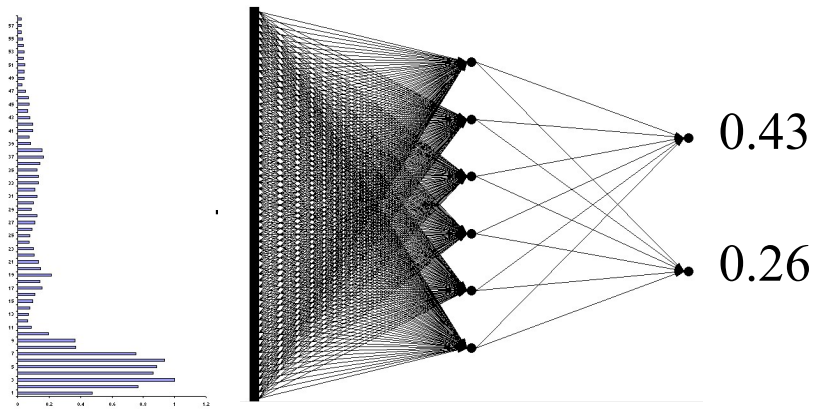


David

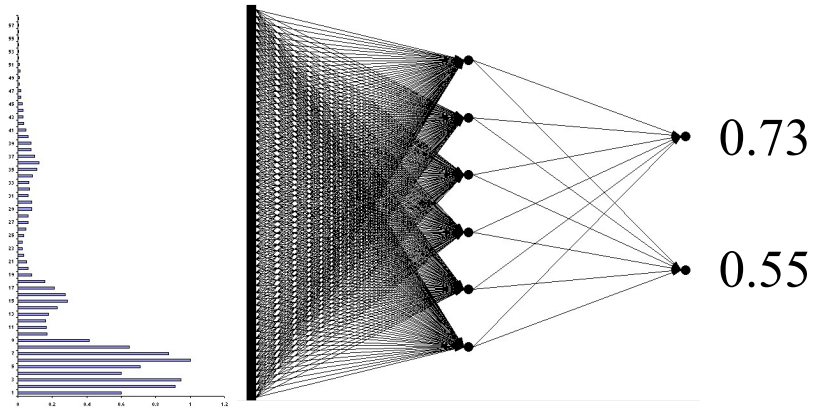


- Introduzindo os dados (rede não treinada)

Steve

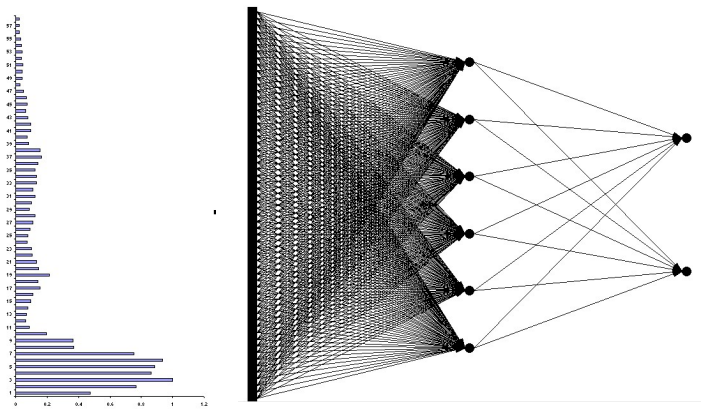


David



- Cálculo do erro

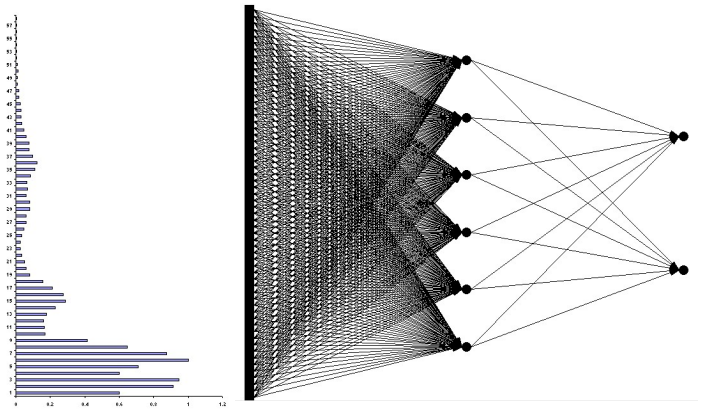
Steve



$$|0.43 - 0| = 0.43$$

$$|0.26 - 1| = 0.74$$

David

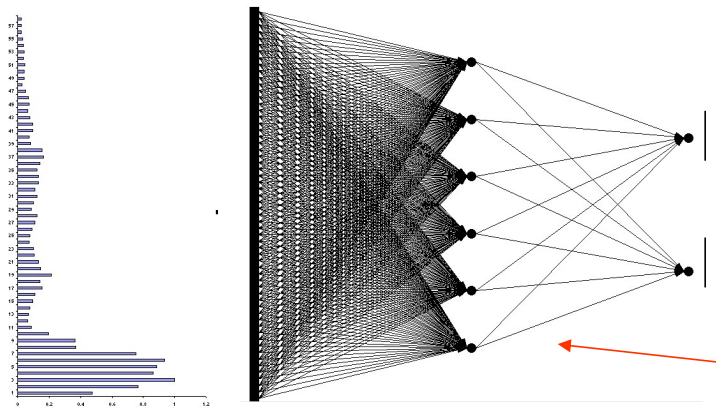


$$|0.73 - 1| = 0.27$$

$$|0.55 - 0| = 0.55$$

- Propagar para trás os erros e ajustar os pesos (Backpropagation)

Steve

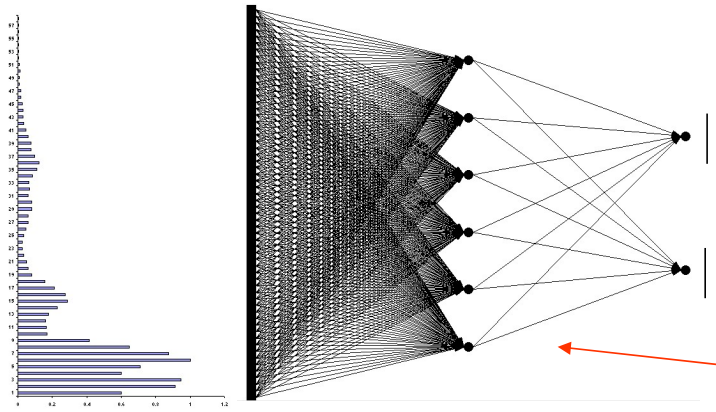


$$|0.43 - 0| = 0.43$$

$$|0.26 - 1| = 0.74$$

$$1.17$$

David



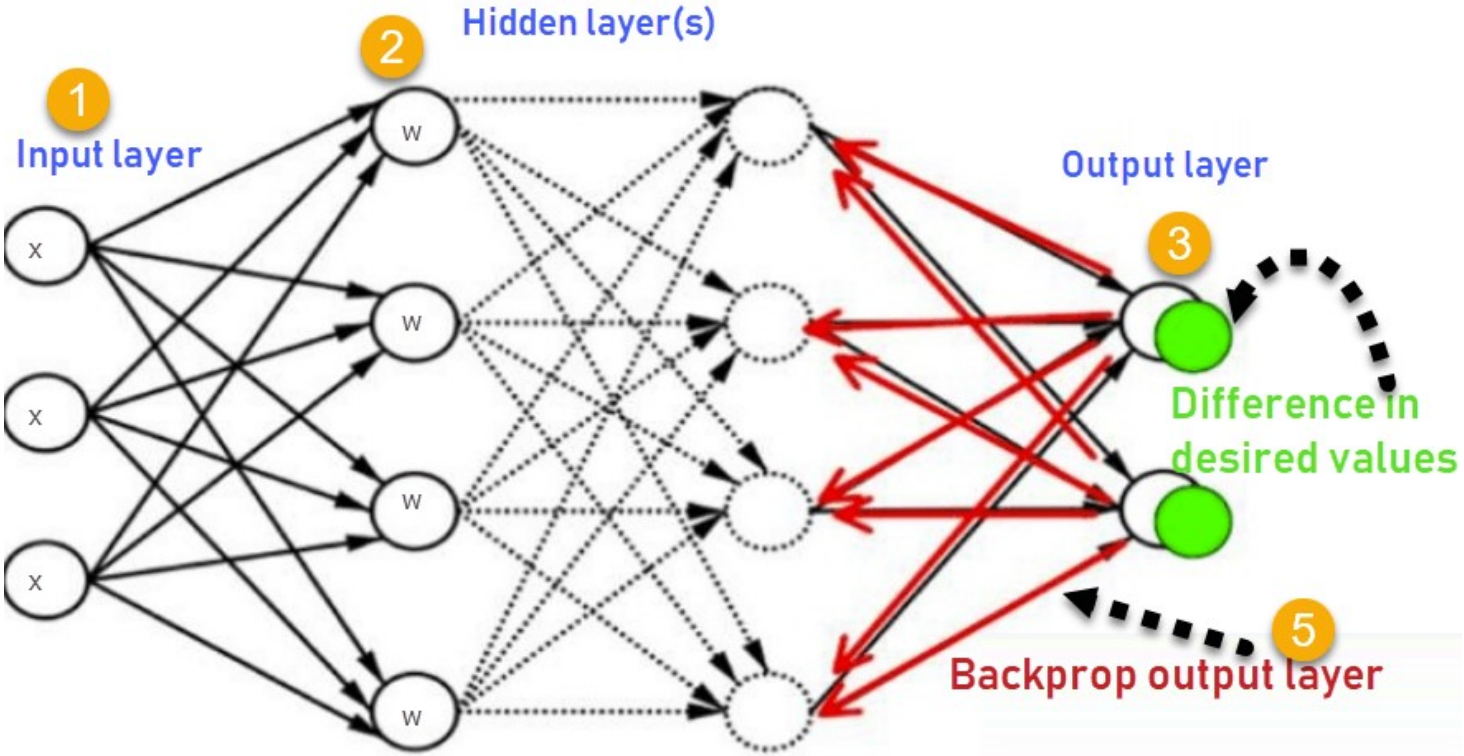
$$|0.73 - 1| = 0.27$$

$$|0.55 - 0| = 0.55$$

$$0.82$$

Retropropagação (Backpropagation)

Na retropropagação os erros à saída dos neurónios são propagados para as entradas e ajustam os valores dos pesos associados às entradas (wi) o processo ocorre no sentido do fim da rede para o princípio e repete-se muitas vezes até que nas saídas apareçam valores próximos do que era esperado. A esse processo designa-se treino da rede neuronal



Gradiente Descendente (Gradient Descent)

Há vários métodos para a Backpropagation – o mais conhecido é o Gradient Descent

D={<(1,1),1>,<(-1,-1),1>,
<(1,-1),-1>,<(-1,1),-1>}

Gradient:
$\nabla E[w]=[\partial E/\partial w_0,\ldots \partial E/\partial w_n]$

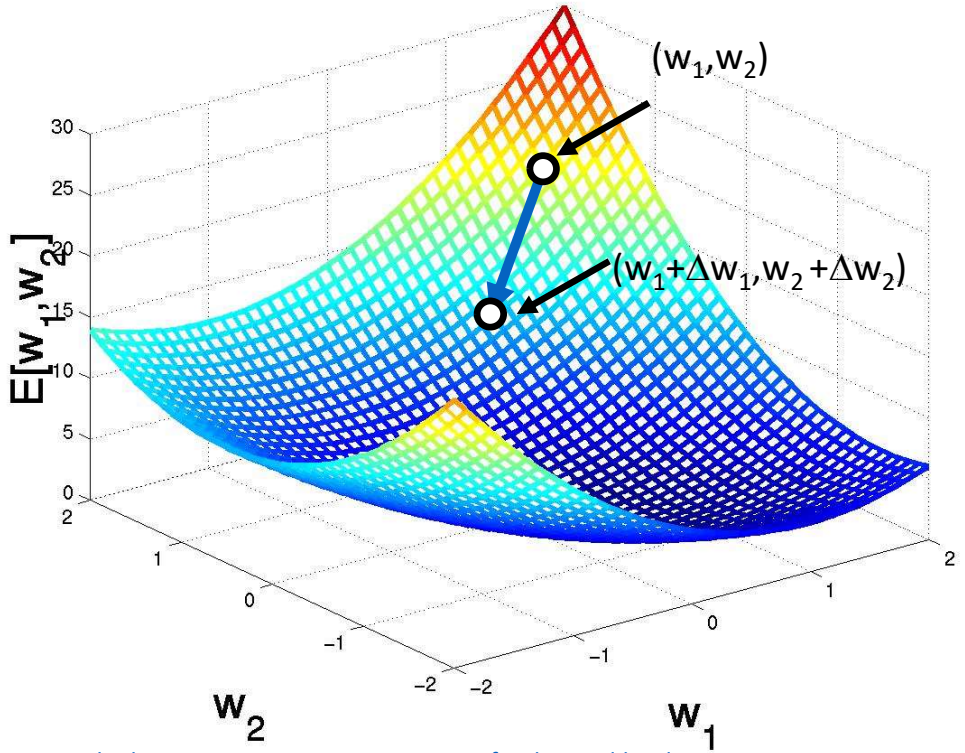
$\Delta w=-\eta \nabla E[w]$

$\Delta w_i=-\eta \partial E/\partial w_i$

$=\partial/\partial w_i \; 1/2\sum_d (t_d-o_d)^2$

$= \partial/\partial w_i \; 1/2\sum_d (t_d-\sum_i w_i x_i)^2$

$= \sum_d (t_d- o_d)(-x_i)$



Retirado de: https://dokumen.tips/documents/foundations-of-learning-and-adaptive-systems-ics320-part-4-artificial-neural.html

Gradient Descent

Gradient-Descent(*exemplos_treino*, η)

Cada exemplo de treino é um par na forma **$<(x_1,\ldots x_n),t>$** onde **$(x_1,\ldots,x_n)$** é o vetor com os valores de entrada e **t** é o valor de saída pretendido, η é a taxa de aprendizagem (por exemplo 0.1)

Initializar cada $\mathbf{w_i}$ com um pequeno valor aleatório

Até que a condição de término seja atendida, Fazer

Inicializar cada $\Delta\mathbf{w_i}$ a zero

Para cada **$<(x_1,\ldots x_n),t>$** dos *exemplos_treino* Fazer

Introduzir **$(x_1,\ldots,x_n)$** na unidade linear e calcular a saída **o**

Para cada peso da unidade linear $\mathbf{w_i}$ Fazer

$\mathbf{\Delta w_i = \Delta w_i + \eta\,(t-o)\,x_i}$

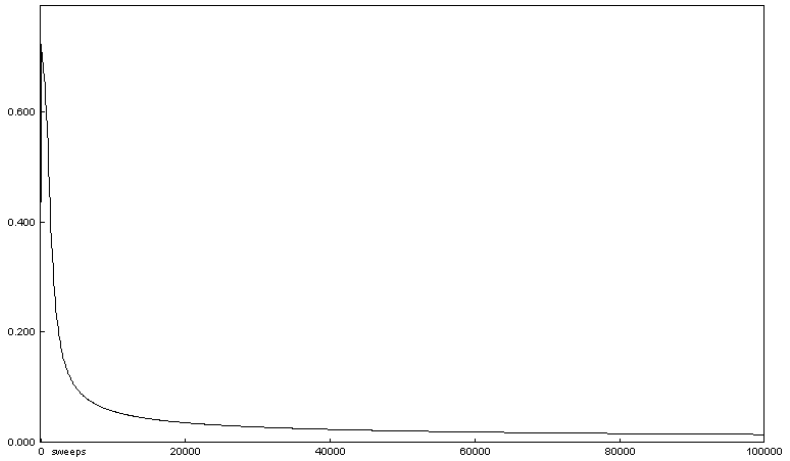
Para cada peso da unidade linear $\mathbf{w_i}$ Fazer

$\mathbf{w_i = w_i + \Delta w_i}$

Retirado de: https://dokumen.tips/documents/foundations-of-learning-and-adaptive-systems-ics320-part-4-artificial-neural.html

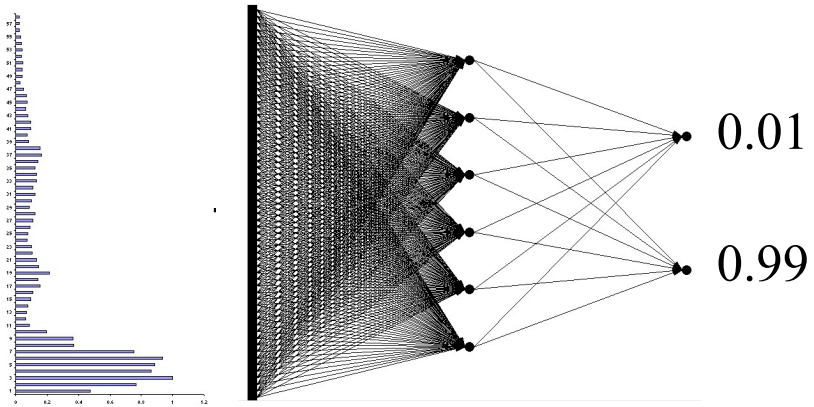
- Repetir o processo para todos os conjuntos de dados de treino
  - Introduzir os dados na entrada
  - Verificar os resultados na saída e calcular os Erros
  - Propagar os erros para trás (Backpropagation)
  - Ajustar os pesos entre nós da Rede Neuronal

- Repetir o processo muitas vezes (o erro vai diminuindo)

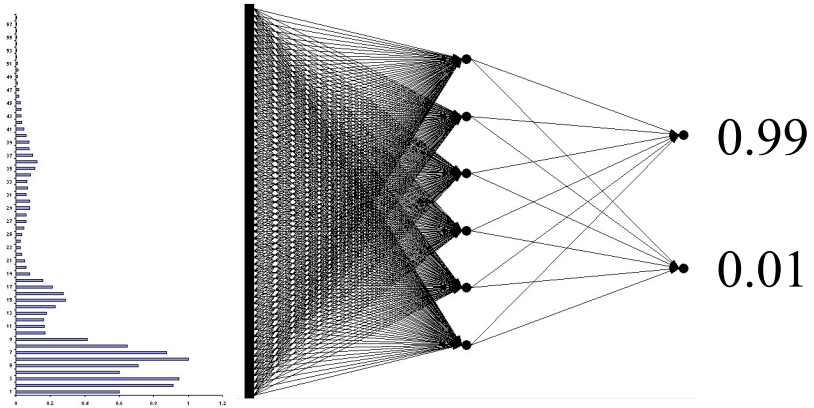


- Após o treino da Rede temos nas saídas valores próximos dos desejados

Steve



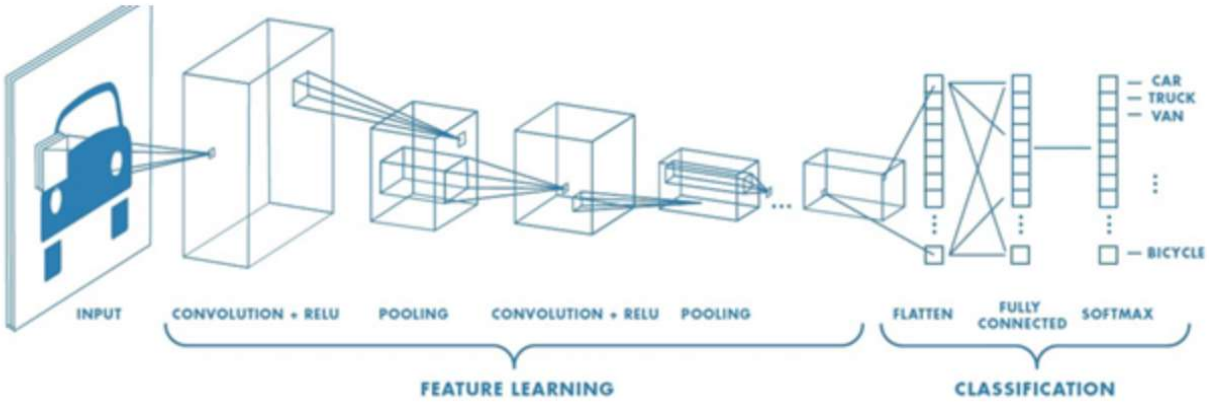
David

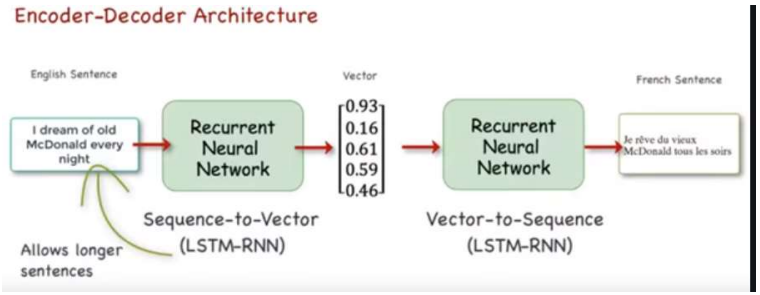


Onde se situa a Aprendizagem Profunda (Deep Learning - DL)?

Uma rede neuronal artificial (RNA) é dita ser de Aprendizagem Profunda quando tem um número considerável de camadas entre as entradas e as saídas

Mas as RNA do tipo DL não se caraterizam por terem todos os nós de uma camada ligados a todos os nós da camada seguinte, como é normal acontecer nas RNA multi-camada convencionais





As Redes neurais Recorrentes (RNN) e as Long-Short Term Memory (LSTM) são muito usadas para lidar com sequências, como por exemplo sequências de palavras numa frase. Das LSTM derivaram os Transformers, usados hoje em dia na IA Generativa

Nas Redes Neuronais Convolucionais (CNN) para tratamento de imagem é normal ter camadas para tratar de operações básicas sobre imagem, onde cada neurónio numa camada é afetado apenas por alguns neurónios da camada seguinte. Recentemente, passaram a ser usados Visual Transformers

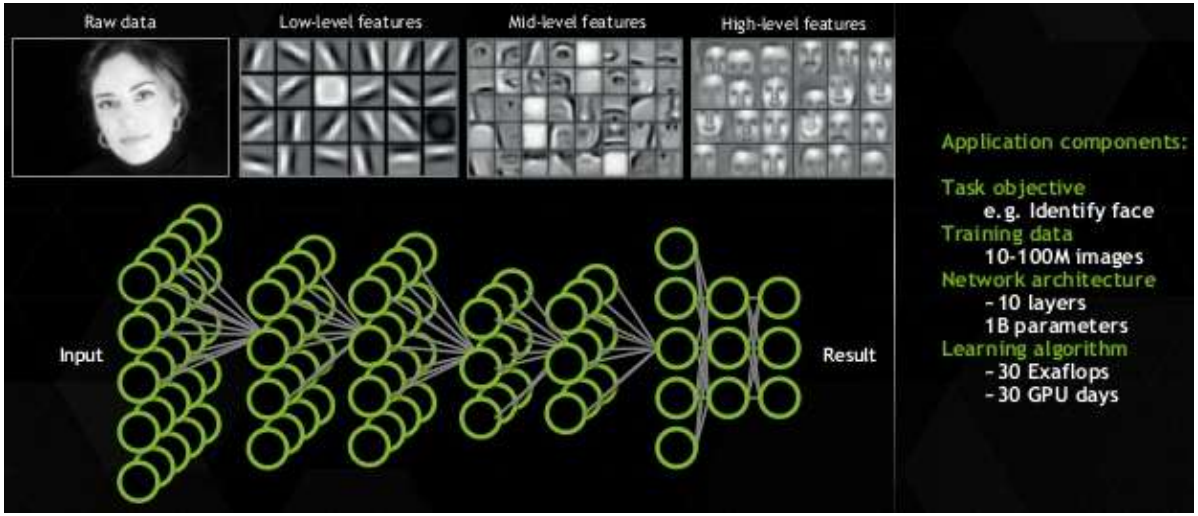
Sucesso da Aprendizagem Profunda

Deep Learning

Hoje é a máquina de cozinha da IA!



- Faz Análise de Dados
- Faz Compreensão de Imagem
- Faz Língua Natural e Tradução Automática
- Faz Recomendação
- Faz Geração de Imagem e Texto
- …e muito mais

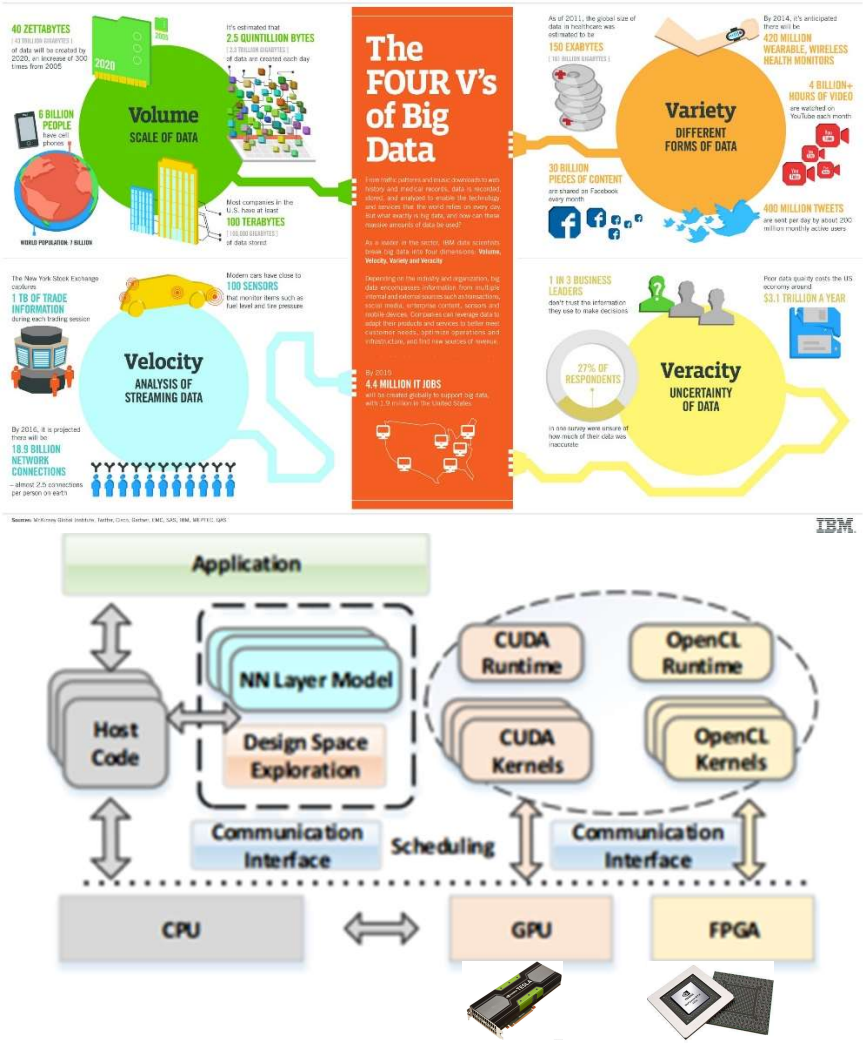


Deep Learning é um tipo de Arquitetura de Rede Neuronal:
- mais camadas
- associadas a alguma semântica
- habilidade para extração de caraterísticas
- supera outras abordagens no que toca ao aumento do desempenho em função da dimensão
- pode exigir uma estrutura de hardware considerável envolvendo paralelismo, GPUs ou FPGAs
- pode exigir muito tempo de treino (dias, meses) mas pouco tempo para teste
- adequada para problemas complexos com enormes volumes de dados (Visão por Computador, Língua Natural, Análise Grandes Volumes de Dados)
- com arquiteturas específicas em função do objetivo

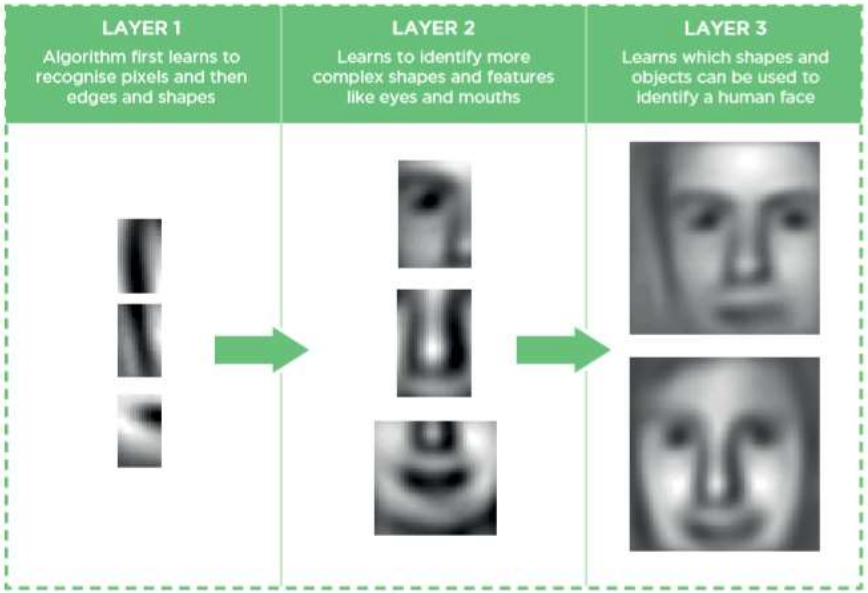
Sucesso da Aprendizagem Profunda

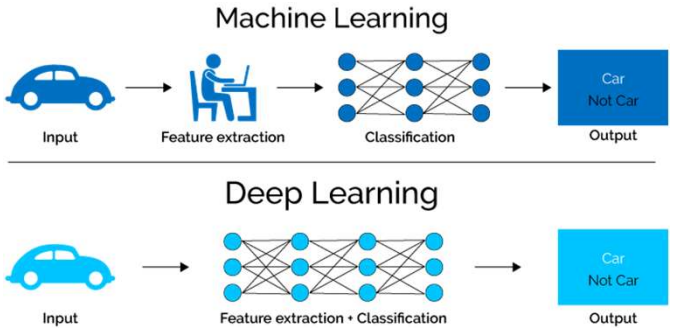
E o que levou a este sucesso da evolução do Deep Learning?

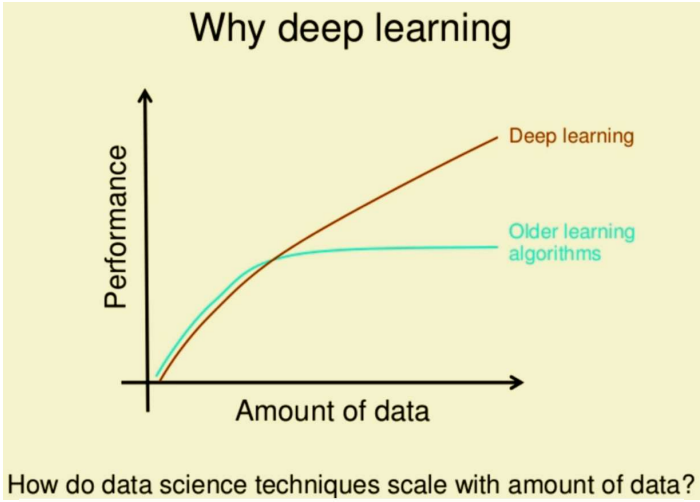
- Evolução da I&D à volta das Redes Neuronais
  - Nomeadamente a inclusão de mais camadas nas redes e associação dessas camadas a alguma semântica
- Disponibilidade de plataformas/bibliotecas que facilitam o uso do Deep Learning (por exemplo, Tensorflow)
- Disponibilidade de grandes volumes de dados
  - Big Data
- Evolução no Hardware
  - Disponibilidade de memória e tempos de processamento que permitem criar redes de grande dimensão
  - Treino das redes passou a ser bem mais rápido
  - Possibilidade de termos redes neuronais com milhões de nós (neurónios)

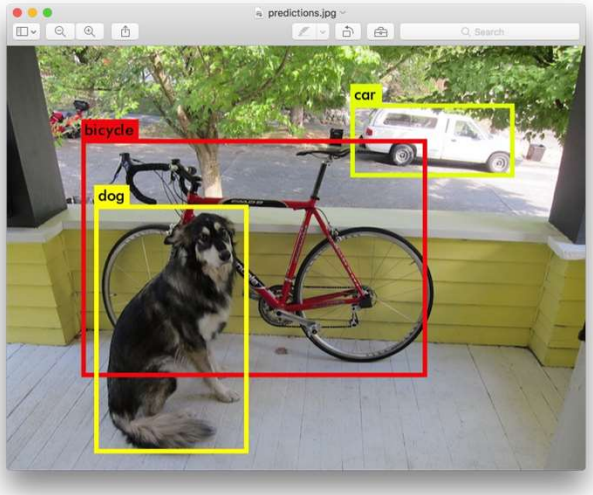


Aprendizagem Profunda (Deep Learning)









Figuras retiradas de https://towardsdatascience.com/why-deep-learning-is-needed-over-traditional-machine-learning-1b6a99177063

ImageNet

O projeto ImageNet constitui um enorme repositório de imagens para serem usadas na investigação na área de reconhecimento de objetos

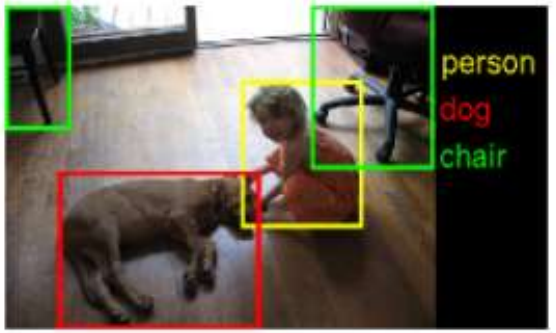
Mais de dez milhões de imagens anotadas!

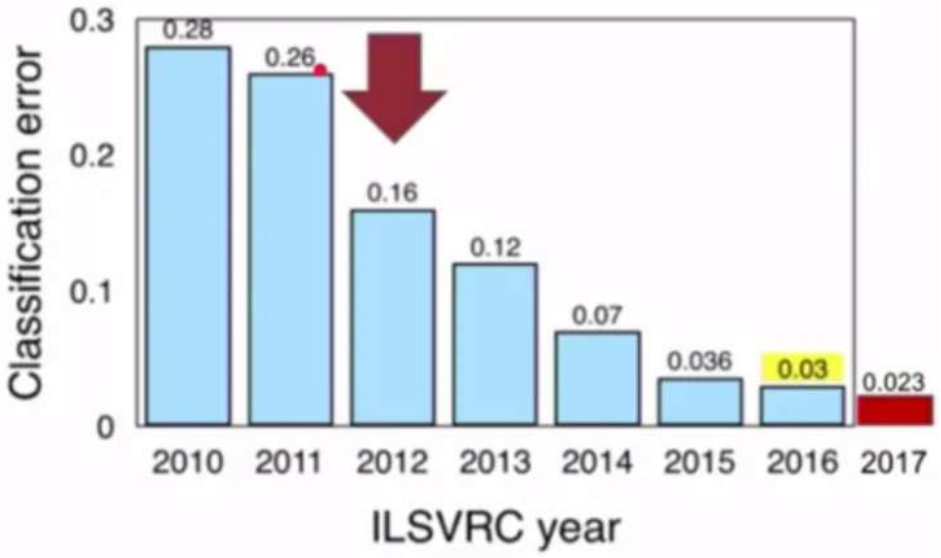
ILSVRC – ImageNet Large Scale Visual Recognition Challenge, desde 2010

ILSVRC 2017

- LOC – localização de objetos entre 1000 categorias
- DET – deteção de objetos entre 200 categorias classificadas em imagens
- VID - deteção de objetos entre 200 categorias classificadas em vídeos







Algumas Ferramentas para desenvolvimento de sistemas com Aprendizagem Automática

	Platform	Cost	Written in language	Algorithms or Features
Scikit Learn	Linux, Mac OS, Windows	Free.	Python, Cython, C, C++	Classification Regression Clustering Preprocessing Model Selection Dimensionality reduction.
PyTorch	Linux, Mac OS, Windows	Free	Python, C++, CUDA	Autograd Module Optim Module nn Module
TensorFlow	Linux, Mac OS, Windows	Free	Python, C++, CUDA	Provides a library for dataflow programming.
Weka	Linux, Mac OS, Windows	Free	Java	Data preparation Classification Regression Clustering Visualization Association rules mining
KNIME	Linux, Mac OS, Windows	Free	Java	Can work with large data volume. Supports text mining & image mining through plugins

	Platform	Cost	Written in language	Algorithms or Features
Apache Mahout	Cross-platform	Free	Java Scala	Preprocessors Regression Clustering Recommenders Distributed Linear Algebra.
Accors.Net	Cross-platform	Free	C#	Classification Regression Distribution Clustering Hypothesis Tests & Kernel Methods Image, Audio & Signal. & Vision
Shogun	Windows Linux UNIX Mac OS	Free	C++	Regression Classification Clustering Support vector machines. Dimensionality reduction Online learning etc.
Keras.io	Cross-platform	Free	Python	API for neural networks
Rapid Miner	Cross-platform	Free plan Small: $2500 per year. Medium: $5000 per year. Large: $10000 per year.	Java	Data loading & Transformation Data preprocessing & visualization.

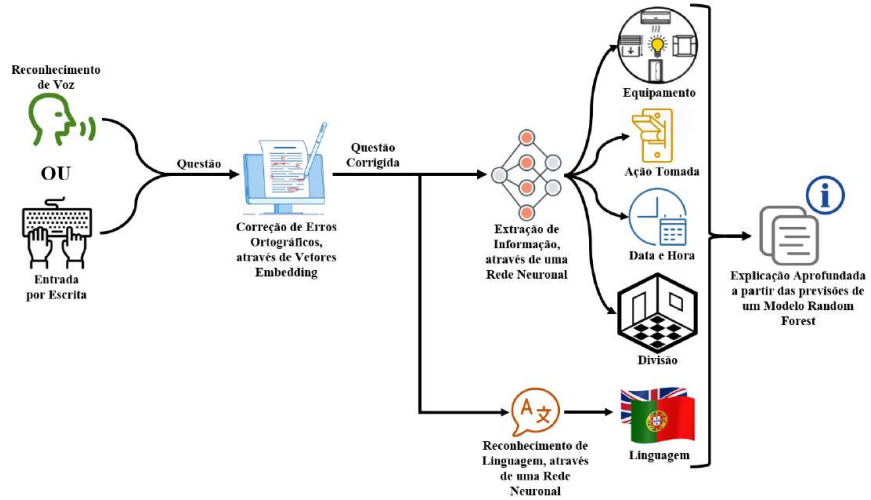
Para saber mais sobre Aprendizagem Automática

- Unidade Curricular de **Análise de Dados** da **Licenciatura em Engenharia Informática** do ISEP (métodos clássicos)
- Unidade Curricular de **Aprendizagem Automática (AAUTIA)** do **Mestrado em Engenharia de Inteligência Artificial (MEIA)** do ISEP (métodos clássicos, Reinforcement Learninig, Ensemble Learning, etc)
- Unidade Curricular de **Redes Neuronais Artificiais e Aprendizagem Profunda (RNAAPIA)** do **Mestrado em Engenharia de Inteligência Artificial (MEIA)** do ISEP (Redes Neuronais Artificiais em detalhe e Aprendizagem Profunda – Deep Learning, também Big Data, Hardware para Deep Learning, Explainable AI, Automated Machine Learning,…)

MEIA
MESTRADO ENGENHARIA INTELIGÊNCIA ARTIFICIAL

Challenges 4Teams
MEIA

Demo Day
MEIA



Equipa de IA aplicada à Energia do MEIA usa Deep Learning para reconhecer várias perguntas após um sistema de Deep Learning ter sugerido decisões para poupança energética em contexto habitacional



Equipa de IA aplicada à Cibersegurança do MEIA usa Redes Neuronais Convolucionais, SVM e K-Means para detetar ataques a sistemas Ciber-Físicos (Sistema de Tratamento de Água)