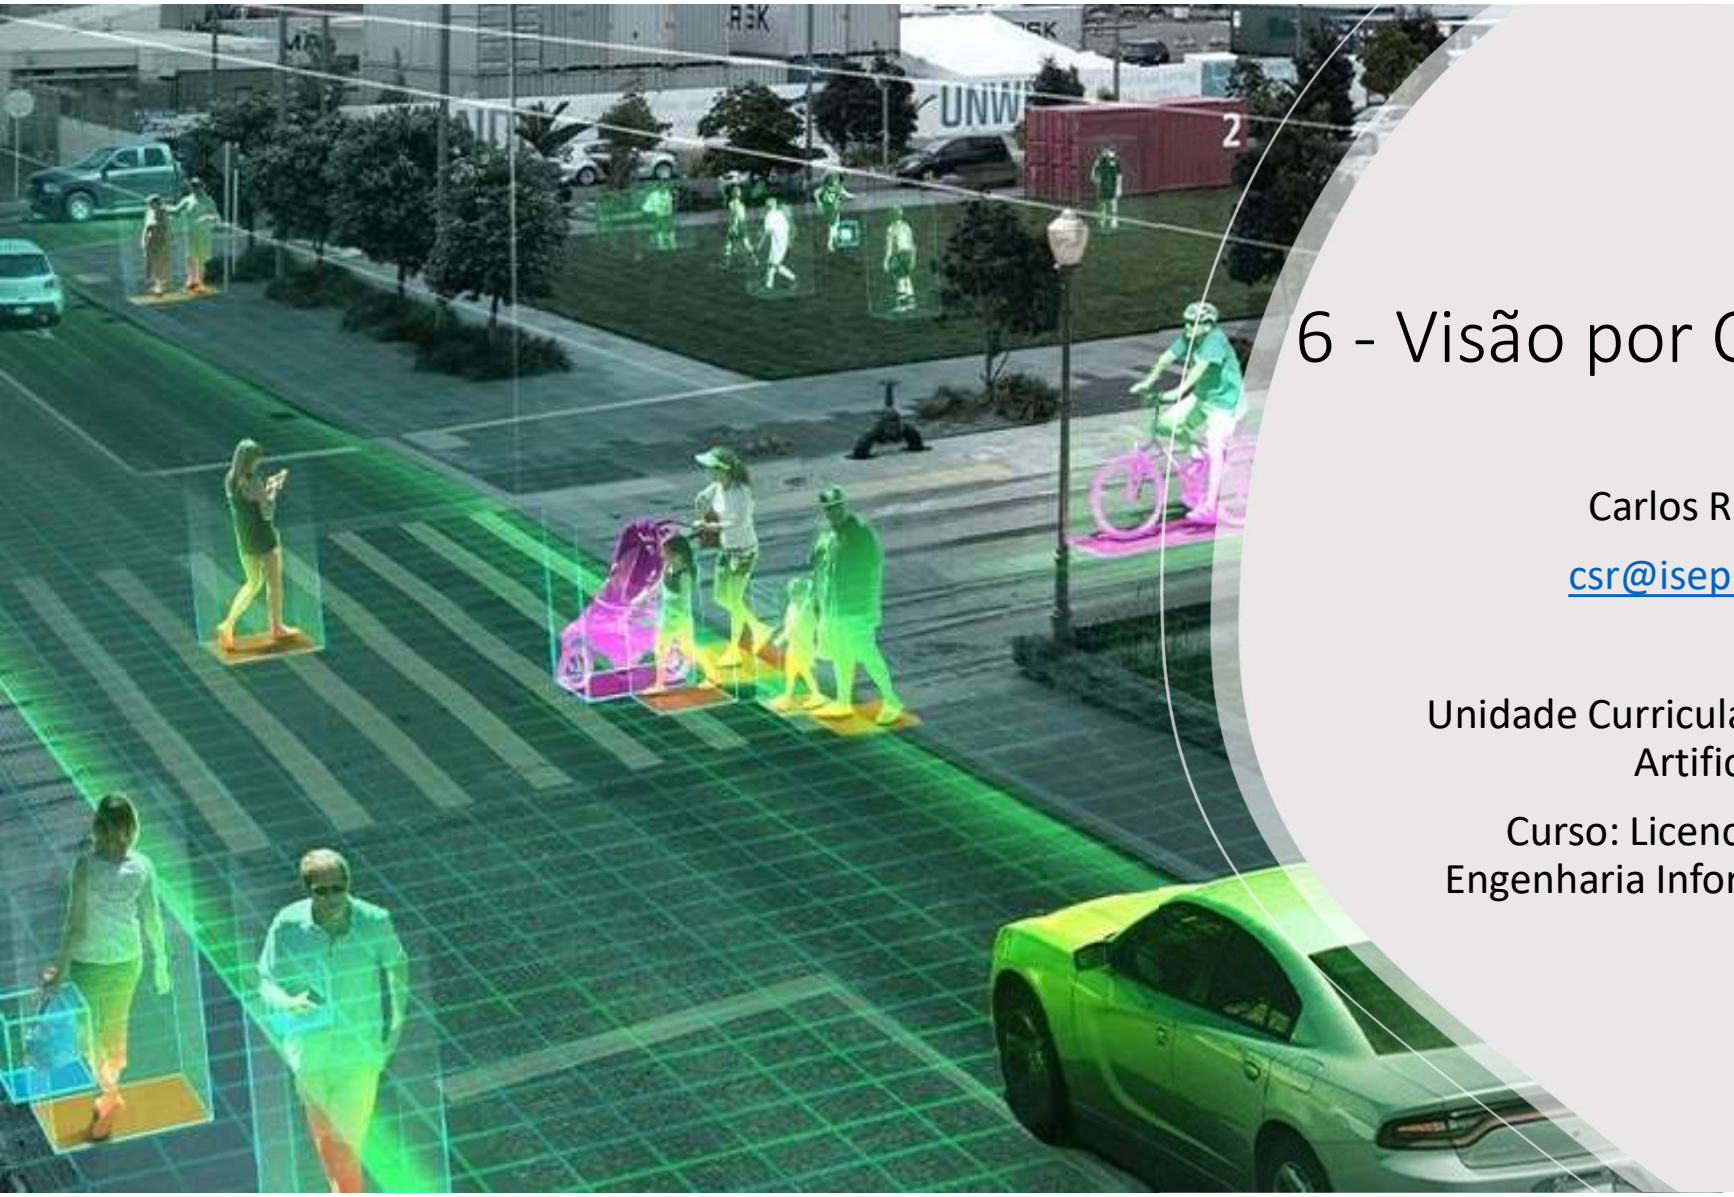


# 6 - Visão por Computador

Carlos Ramos

csr@isep.ipp.pt

Unidade Curricular: Inteligência Artificial

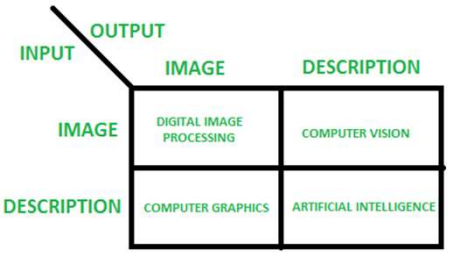
Curso: Licenciatura em Engenharia Informática (ISEP)

# Processamento Digital de Imagem e Visão por Computador

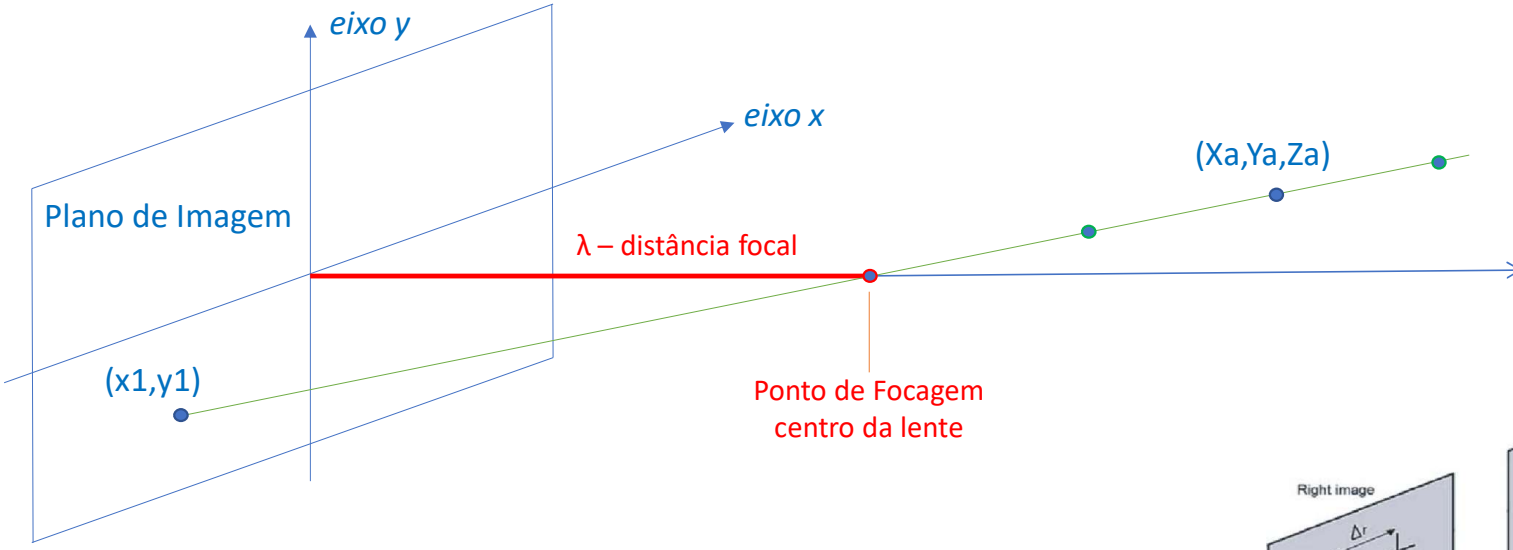
- As câmeras permitem a aquisição de imagem
- As câmeras digitais fazem a aquisição de uma imagem através de um sensor (tecnologia CMOS) e armazenam a imagem numa matriz de pixéis
- O Processamento Digital de Imagem é a área na qual se aplicam algoritmos que operam sobre uma imagem digital previamente armazenada para operações básicas como a redução de ruído, a compensação de distorções ou a compressão (por exemplo para jpeg)
- A Visão por Computador é a área científica na qual pretende-se efetuar o reconhecimento em imagem digital, por exemplo pela identificação de objetos numa imagem, por exemplo itens presentes numa estrada ou problemas identificados numa imagem médica

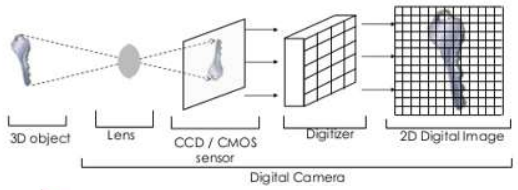




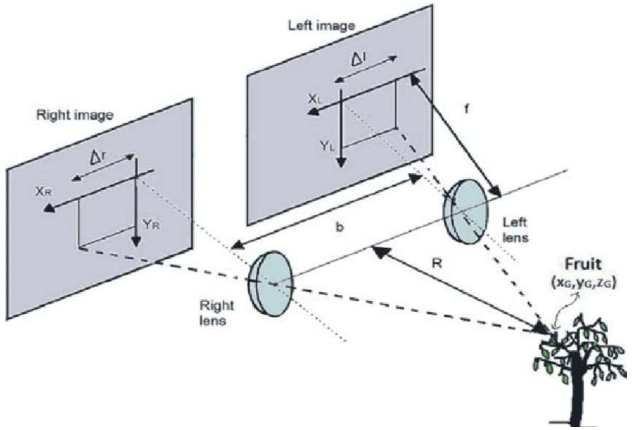



# Formação da imagem




Plano Imagem – onde a imagem se forma (sensor CMOS)
Distância Focal – distância entre o centro da imagem e o ponto de focagem (centro da lente)
A um ponto (Xa,Ya,Za) no espaço corresponderá o ponto (x1,y1) no plano da imagem
Todos os pontos na semireta entre o ponto de focagem e passando por (Xa,Ya,Za) serão projetadas em (x1,y1)
Como o que conhecemos na imagem é (x1,y1) não sabemos exatamente onde está o ponto que lhe deu origem (Xa,Ya,Za)




Para podermos saber exatamente onde está um ponto no espaço vamos necessitar de 2 câmeras e relacionar os pixéis de projeção correspondentes, a isso designamos Visão Estéreo

## Caracterísctcas das Imagens

Uma imagem é uma matriz de pixéis, no exemplo é usado 1 byte para representar cada pixel

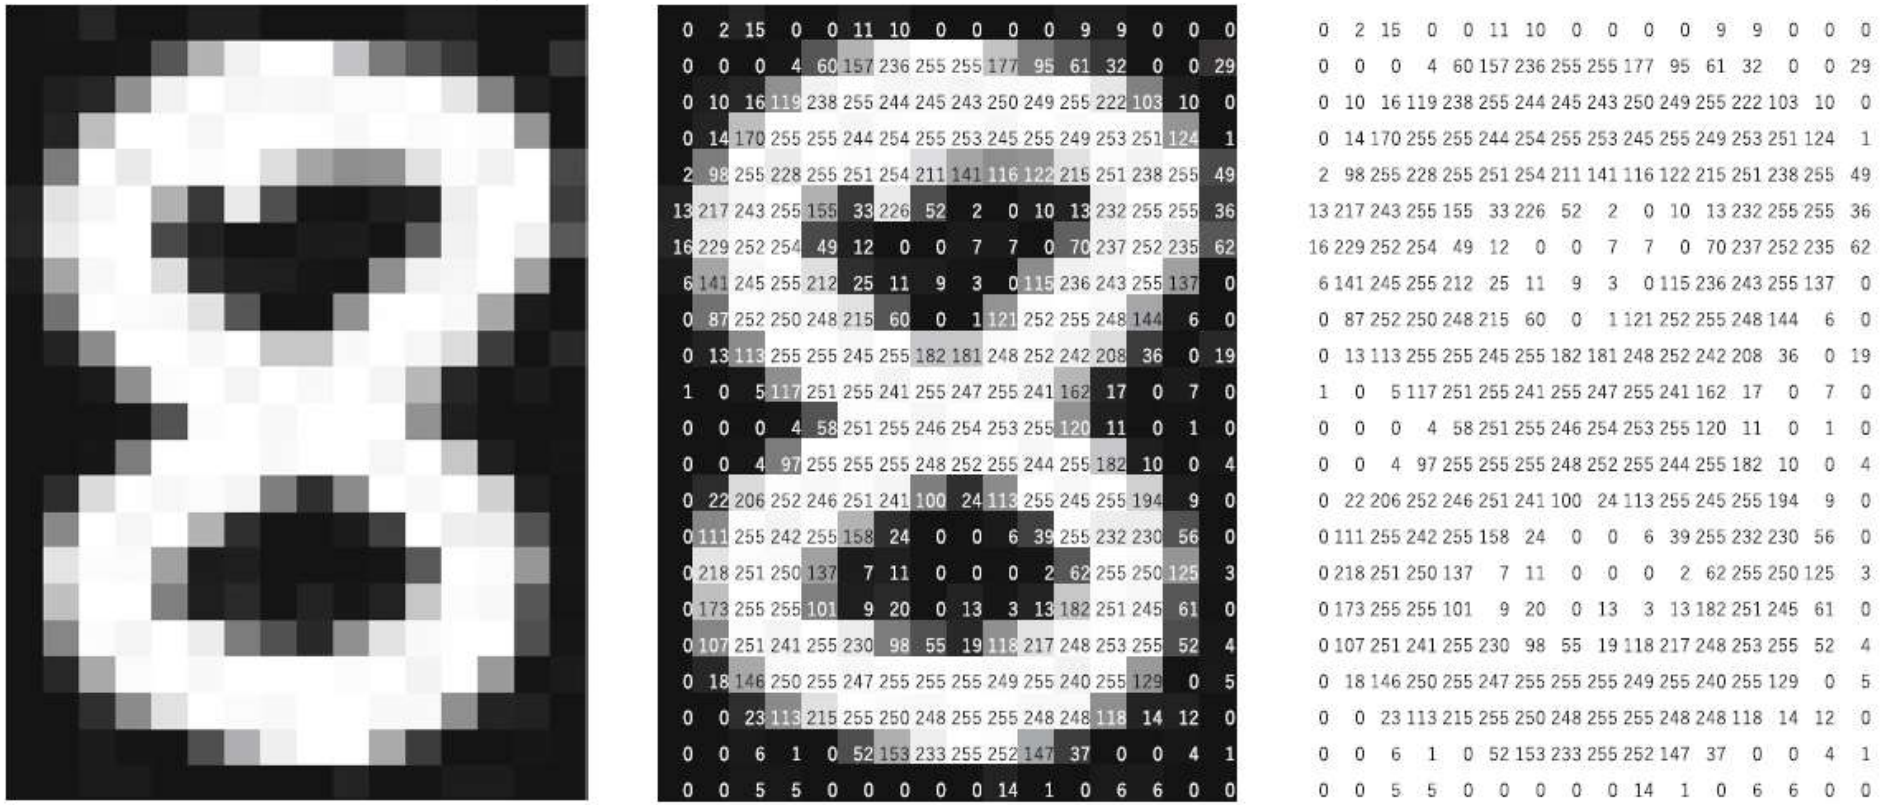


Fig. 2 A computer sees an image as an array of numbers. The matrix on the right contains numbers between 0 and 255, each of which corresponds to the pixel brightness in the left image. Both are overlaid in the middle image. The source image was downloaded via http://yann.lecun.com/exdb/mnist

# Caracterísctica das Imagens

- Resolução (nº de píxeis) – maior resolução implica mais memória, mas também mais detalhe
- Níveis de Intensidade - número de níveis diferentes que se pode representar num pixel que se relaciona com o espaço de armazenamento ocupado (por exemplo 256 níveis em 1 byte)

Uma imagem 256x256 em que cada pixel ocupa 1 byte vai ocupar 65536 bytes para representar os píxeis

Com 1 byte podemos representar 256 níveis diferentes (níveis de cinzento)

Imagens binárias ocupam 1 bit por pixel (branco,preto)

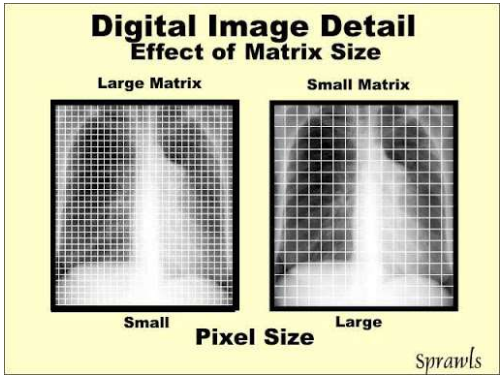
Se a cor for importante cada pixel pode ocupar 3 bytes (código RGB – Red, Green, Blue com 1 byte para cada cor, portanto 3 bytes/pixel)

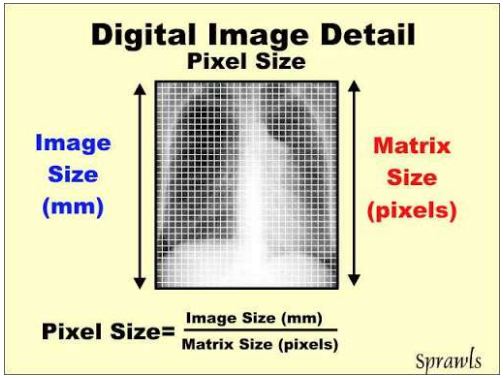


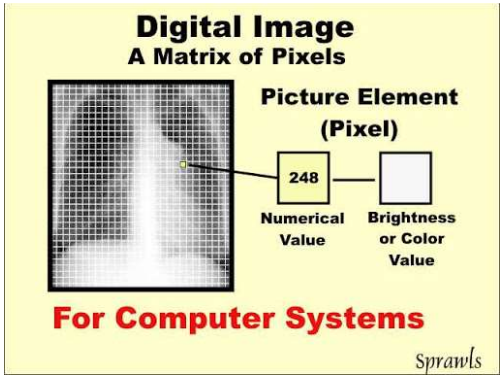
Variação da resolução



Variação do nº de níveis de intensidade



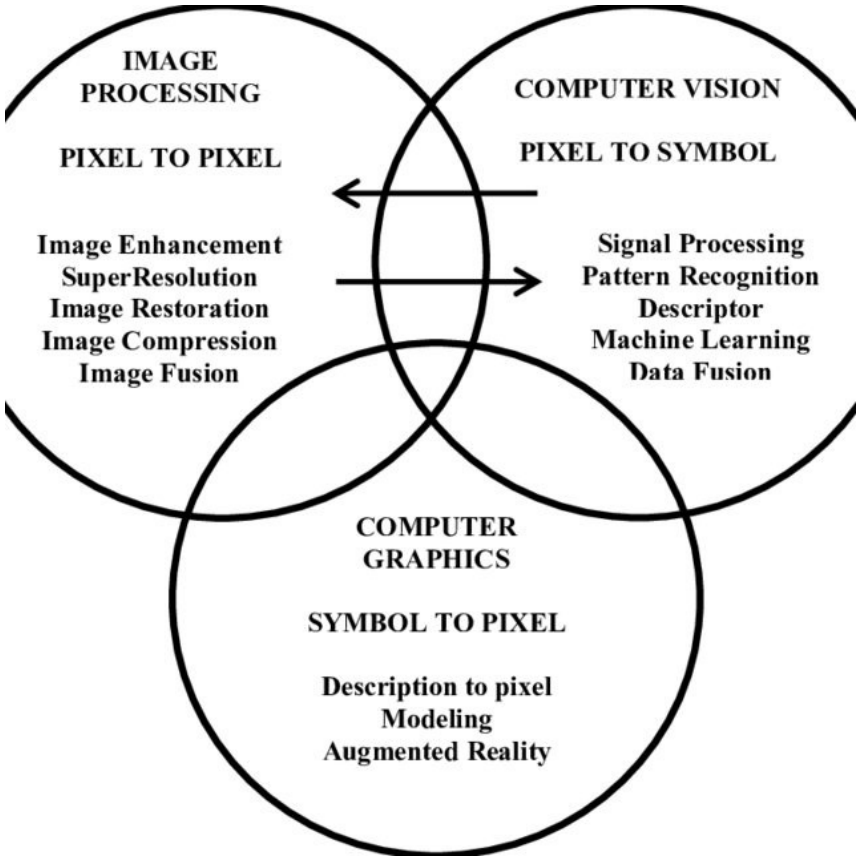



# Processamento de Imagem, Visão por Computador e Computação Gráfica - diferenças

- Computação Gráfica – temos modelos de objetos e queremos criar uma imagem sintética que os envolvam em determinadas posições e orientações, do modo mais realista possível. Idealmente o ser humano até deveria ter dificuldade em distinguir uma imagem real de uma imagem sintética. Aspetos como oclusões entre objetos, sombras e reflexos são importantes para dar realismo à imagem

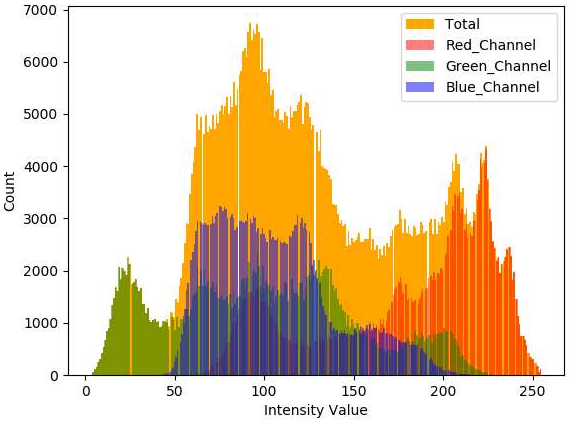
- Visão por Computador – o caminho é o inverso da Computação Gráfica, temos uma imagem real e queremos saber quais são os objetos presentes, suas posições e orientações (por exemplo usando visão estéreo). Oclusões, sombras e reflexos são aspetos com os quais temos de lidar e que criam complicações no processo

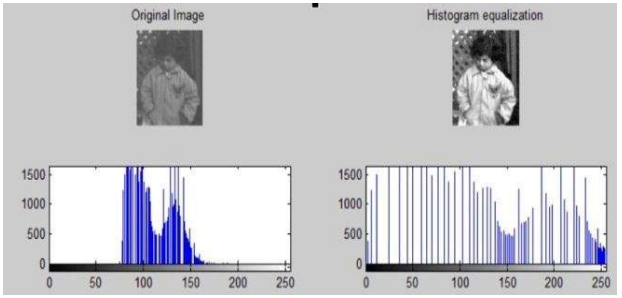
- Processamento de Imagem – o processo é feito dentro do espaço das imagens



# Histogramas

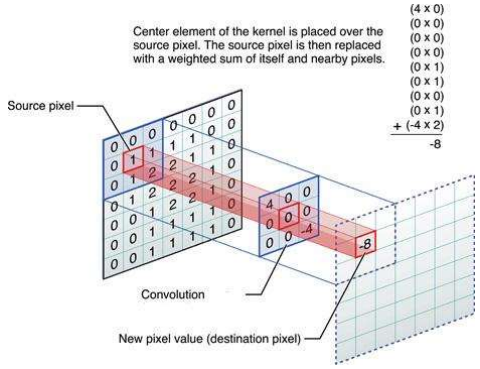
- Um histograma é um gráfico de barras que nos dá uma ideia do nº de ocorrências de uma dada intensidade (branco-preto, níveis de cinzento, código RGB) numa imagem
- Quando queremos fazer uma binarização numa imagem podemos socorrer-nos do histograma para decidir o threshold (nível de corte, ou seja o nível de intensidade abaixo do qual temos um valor, por exemplo preto, e acima do qual temos outro valor, branco)
- A equalização do histograma permite geralmente  melhoria do brilho e contraste da imagem

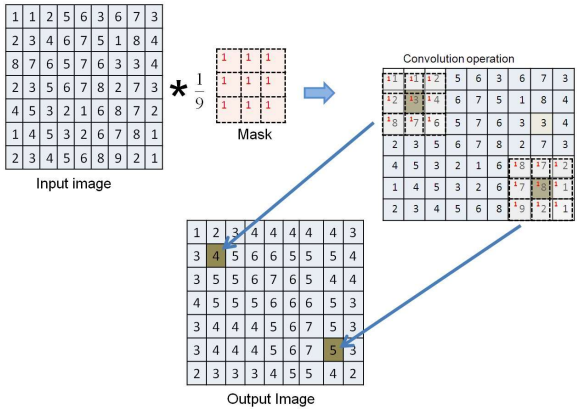


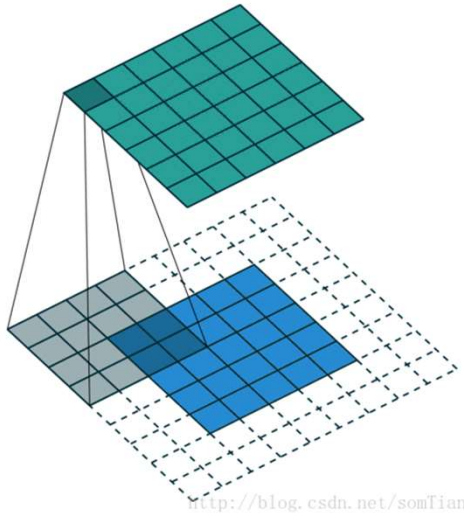
# Convolução e Máscaras/Filtros

- Na Matemática a convolução é uma operação que a partir de 2 funções (*f* e *g*) produz *f*g*, traduz como uma das funções é moldada à outra. É muito usada em processamento de sinal (e imagem é um sinal visual)
- Em processamento de imagem faz-se frequentemente a convolução da imagem original com uma máscara/filtro de dimensão reduzida (por exemplo, uma matriz 3x3) sendo o resultado na imagem transformada o valor centrado do somatório dos produtos dos elementos da máscara com os valores da imagem original nas posições correspondentes. Essa operação é feita pelo varrimento completo da máscara/filtro sobre a imagem original



# Convolução e Máscaras/Filtros




Resultado após convolução – matriz esverdeada 6x6

Filtro (ou máscara) – matriz cinzenta 4x4
Nas CNN recebe normalmente o nome kernel

Imagem original – matriz tracejada 9x9

Contudo é normal os filtros terem dimensão impar (3x3; 5x5) para ficarem centrados num pixel

http://cs231n.github.io/convolutional-networks/

# Principais Máscaras/Filtros

| | | |
|---|---|---|
| -1 | -1 | -1 |
| -1 | 8 | -1 |
| -1 | -1 | -1 |

Máscara para detetar
pixels isolados (possivelmente ruído)

| | | |
|---|---|---|
| 1 | 1 | 1 |
| 1 | 1 | 1 |
| 1 | 1 | 1 |

Máscara de Média
para suavização da imagem

| | | | | |
|---|---|---|---|---|
| 1 | 1 | 1 | 1 | 1 |
| 1 | 1 | 1 | 1 | 1 |
| 1 | 1 | 1 | 1 | 1 |
| 1 | 1 | 1 | 1 | 1 |
| 1 | 1 | 1 | 1 | 1 |

As máscaras podem ter diversas
Dimensões (Máscara de Média 5x5)

As máscaras podem definir apenas a zona de atuação
Por exemplo a máscara de mediana (também para suavização)
vai considerar o valor da imagem na matriz 3x3 que está a meio de uma ordenação desses 9 valores

| | | |
|---|---|---|
| 0 | 1 | 0 |
| 1 | -4 | 1 |
| 0 | 1 | 0 |

Laplaciano - Máscara para detetar
Transições (edge detection)

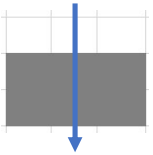
| | | |
|---|---|---|
| -1 | 0 | 1 |
| -2 | 0 | 2 |
| -1 | 0 | 1 |

Sobel H - Máscara para detetar
transições na horizontal



| | | |
|---|---|---|
| 1 | 2 | 1 |
| 0 | 0 | 0 |
| -1 | -2 | -1 |

Sobel V - Máscara para detetar
transições na vertical

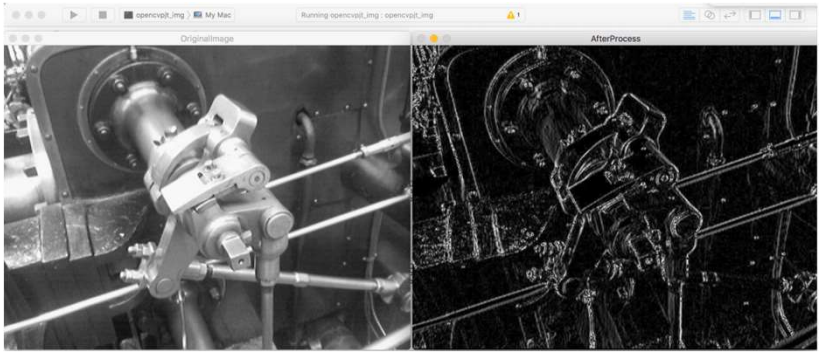


As máscaras de transições definem apenas onde estão pixels de transição. Com o Sobel H e V temos alguma ideia da direção da transição, o que é útil para agrupar pixels de transição vizinhos

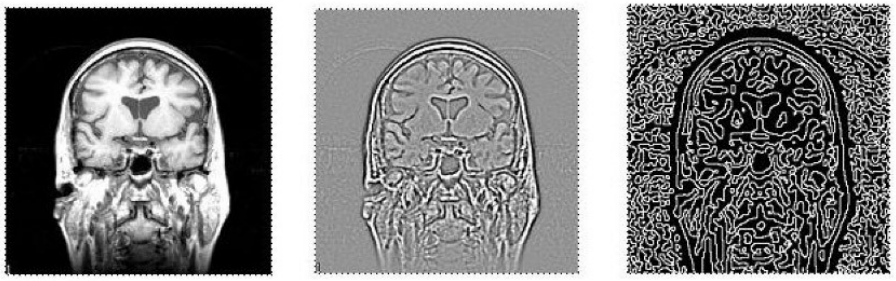
# Principais Máscaras/Filtros



Suavização de imagem – à direita com filtro de mediana




Deteção de transições com filtro de Sobel

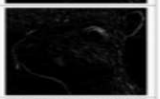


(A) Original MR image

(B) Laplacian results

(C) Extraction of the zero crossing of the Laplacian (object edges)

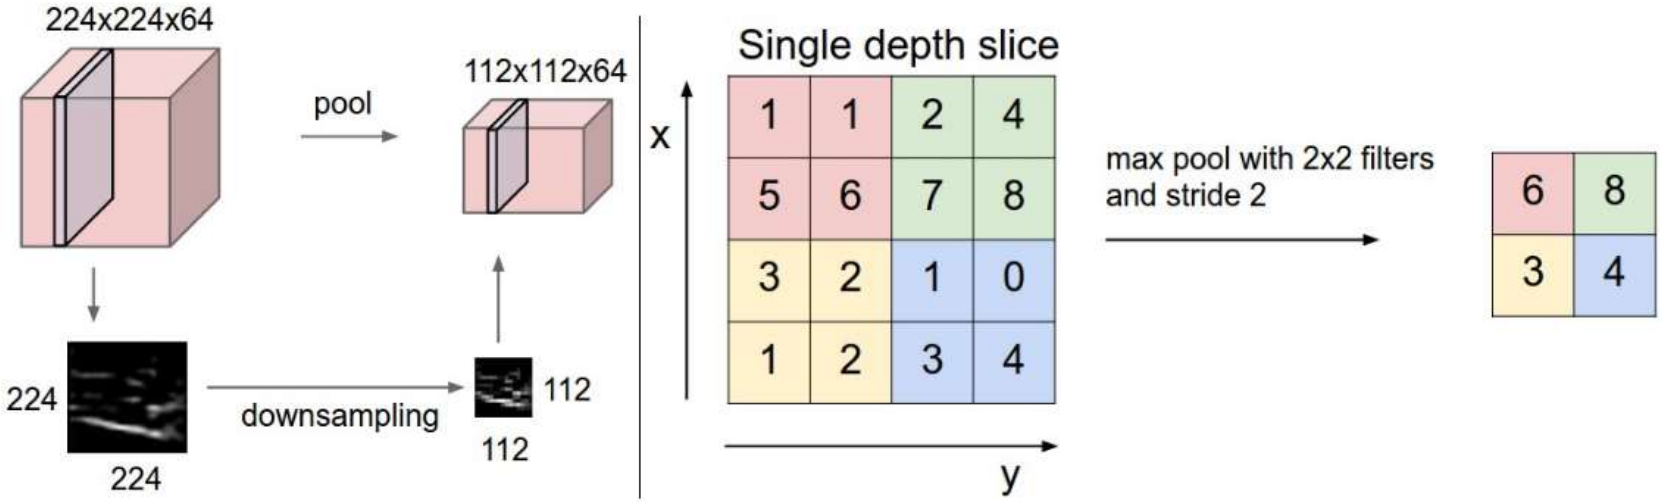
Deteção de transições com filtro Laplaciano

| Operation | Filter | Convolved Image |
|---|---|---|
| **Identity** | $\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ |  |
| **Edge detection** | $\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$ |  |
| | $\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$ |  |
| | $\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$ |  |
| **Sharpen** | $\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$ |  |
| **Box blur** (normalized) | $\frac{1}{9}\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$ |  |
| **Gaussian blur** (approximation) | $\frac{1}{16}\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$ |  |

# Pooling

A operação de pool faz uma redução da dimensão da matriz imagem, ou seja, reduz a resolução da imagem e também o espaço de memória ocupado, por consideração dos píxeis da imagem original que ficam dentro da máscara considerada

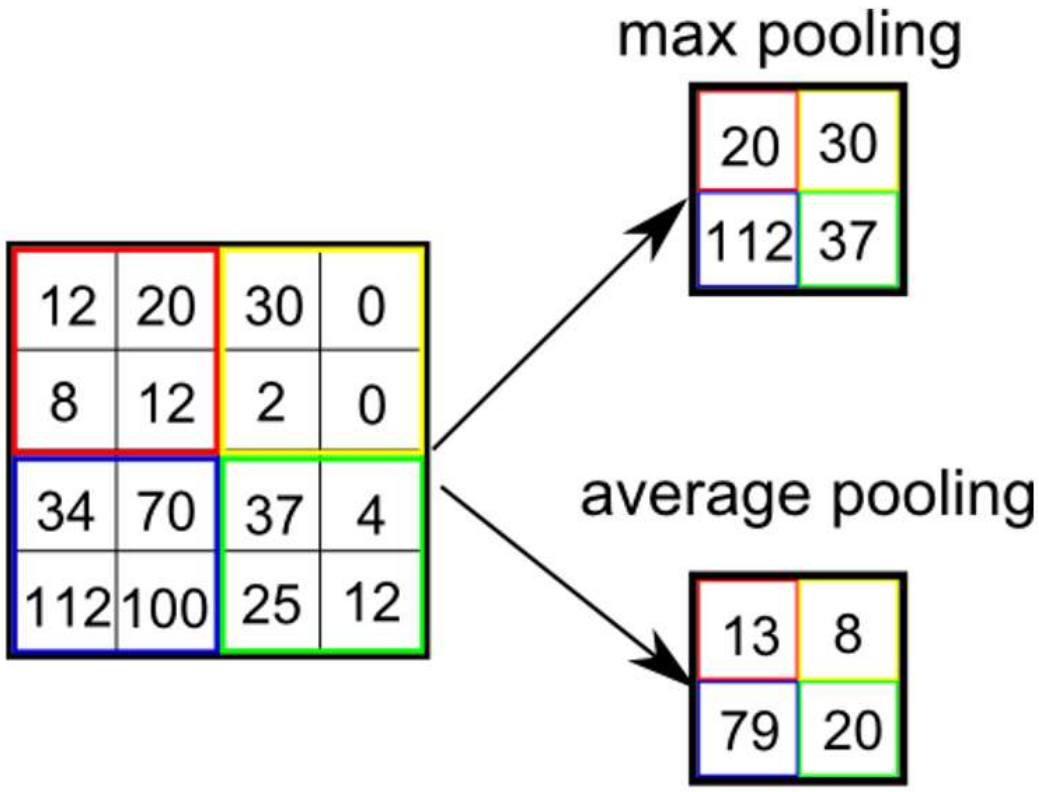
As situações mais normais são substituir pela média ou pelo valor máximo




Pooling layer downsamples the volume spatially, independently in each depth slice of the input volume. **Left:** In this example, the input volume of size [224x224x64] is pooled with filter size 2, stride 2 into output volume of size [112x112x64]. Notice that the volume depth is preserved. **Right:** The most common downsampling operation is max, giving rise to **max pooling**, here shown with a stride of 2. That is, each max is taken over 4 numbers (little 2x2 square).

http://cs231n.github.io/convolutional-networks/

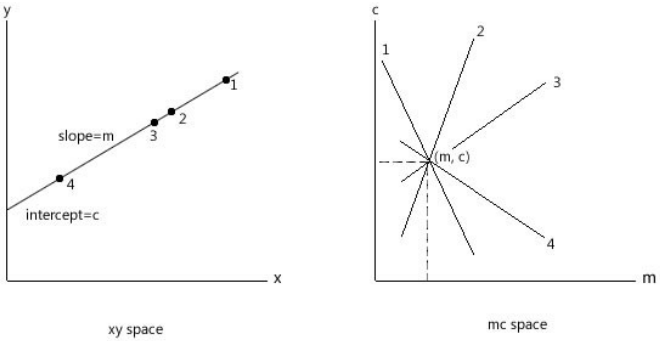
# Pooling

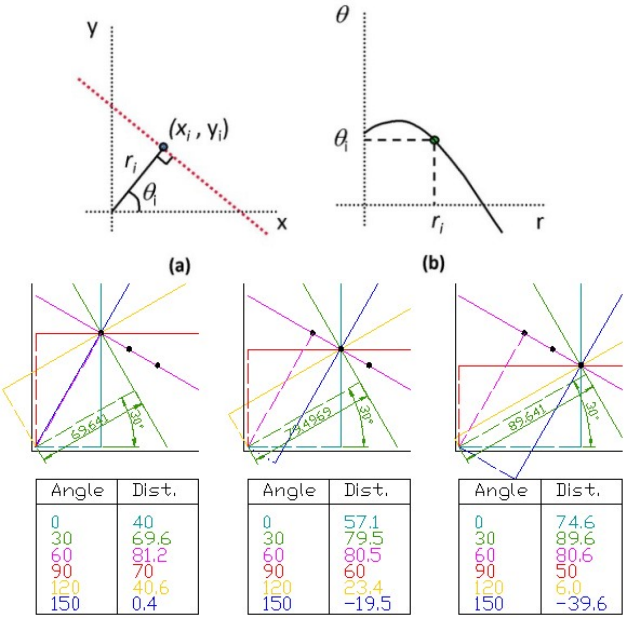



http://cs231n.github.io/convolutional-networks/

# Identificando transições a partir de pixels de transição

- Transformada de Hough – com base em pixels de transição e direções de transição (Sobel) constrói um quadro onde as semiretas de transição têm um peso maior e portanto são mais facilmente identificadas
- Passamos do espaço x-y para o espaço m-c (equação da reta y=m*x+c). Vários pixels de transição de uma mesma semireta têm valores de m e c similares
- Por razão de dimensionalidade do quadro da Transformada de Hough usa-se o espaço r-Θ, onde r é a distância da reta à origem e Θ o ângulo



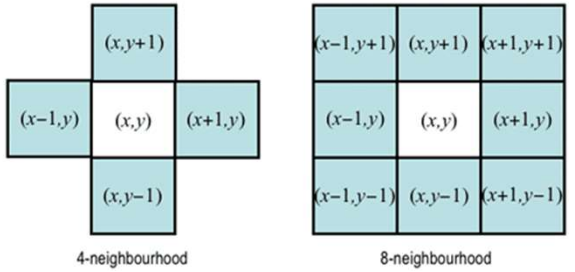

| Angle | Dist. |
|---|---|
| 0 | 40 |
| 30 | 69.6 |
| 60 | 81.2 |
| 90 | 70 |
| 120 | 40.6 |
| 150 | 0.4 |

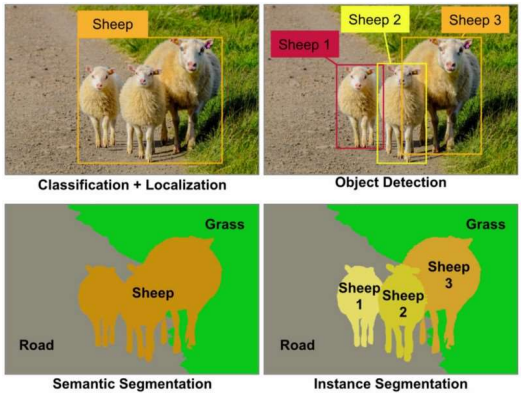
| Angle | Dist. |
|---|---|
| 0 | 57.1 |
| 30 | 79.5 |
| 60 | 80.5 |
| 90 | 60 |
| 120 | 23.4 |
| 150 | -19.5 |

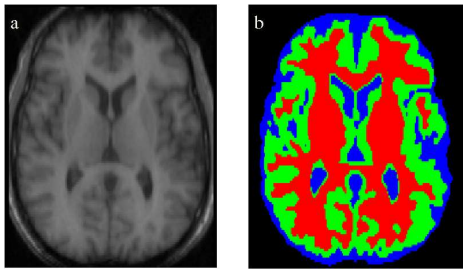
| Angle | Dist. |
|---|---|
| 0 | 74.6 |
| 30 | 89.6 |
| 60 | 80.6 |
| 90 | 50 |
| 120 | 6.0 |
| 150 | -39.6 |

# Segmentação

- A Segmentação consiste na divisão da imagem em conjuntos de pixels que m conjunto partilham algo de comum (por exemplo, a mesma cor, ou cores próximas, constituem uma mesma superfície ou objeto, etc)
- Pode ser feita por crescimento de regiões agregando pixels vizinhos (4 vizinhos, 8 vizinhos)
- Pode ser feita pela análise das transições (fronteira dos objetos na imagem)



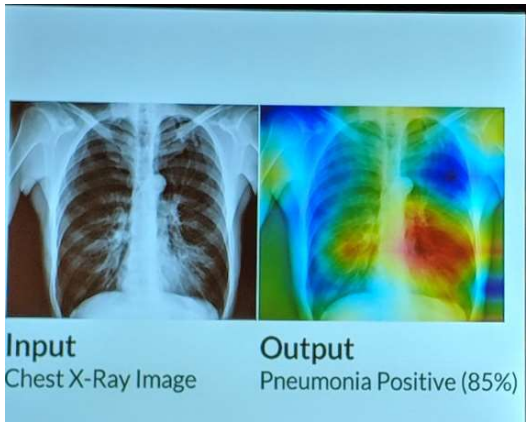



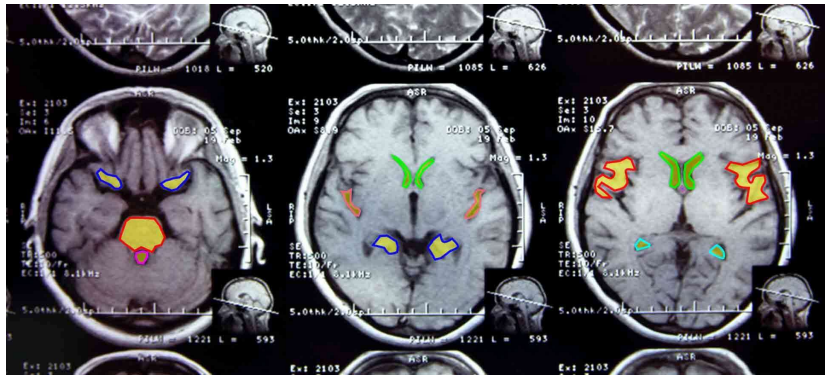



# Aplicações de Visão por Computador

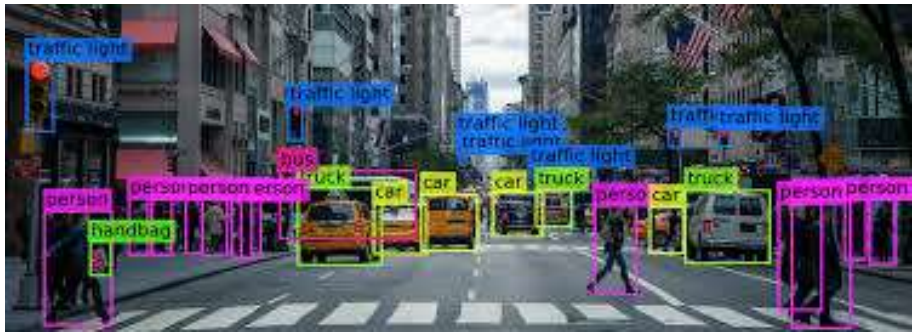



Indústria (exemplo bin picking)



Saúde




Veículos Autónomos

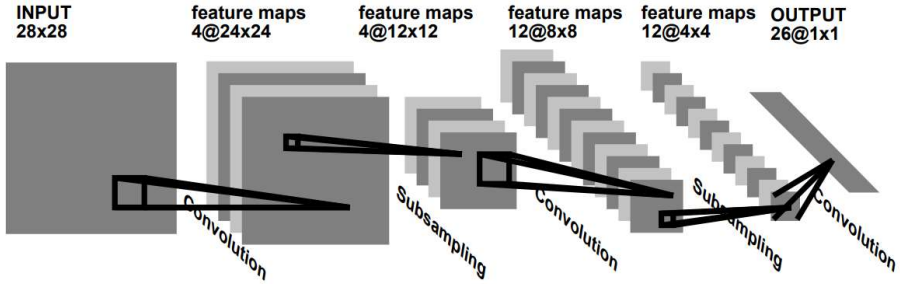



Segurança

.....

# Introdução às Redes Neuronais Convolucionais

- O cientista francês Yann LeCun (Professor da Universidade de Nova Iorque e Diretor de IA da Facebook Inc.) propõe um novo modelo de rede neuronal particularmente adaptado ao processamento de imagem e reconhecimento de imagem dando origem às Redes Neuronais Convolucionais (CNN)
- LeCun recebeu em 2018 o Prémio Turing (considerado o "Nobel da Informática")




Primeira CNN, proposta por Yann LeCun em 1990 para Reconhecimento de carateres manuscritos



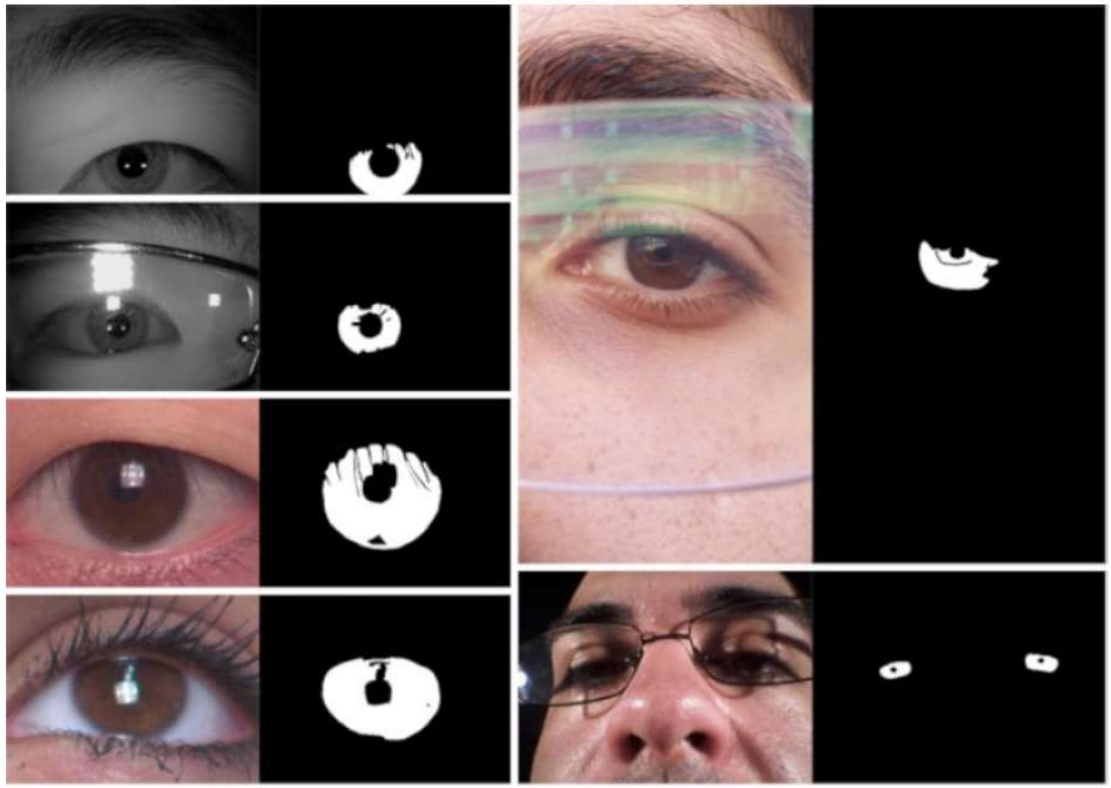

Yann LeCun

# Aplicações populares das CNN



Identificação de Veículos e matrículas

# Aplicações populares das CNN



Biometria

# Aplicações populares das CNN



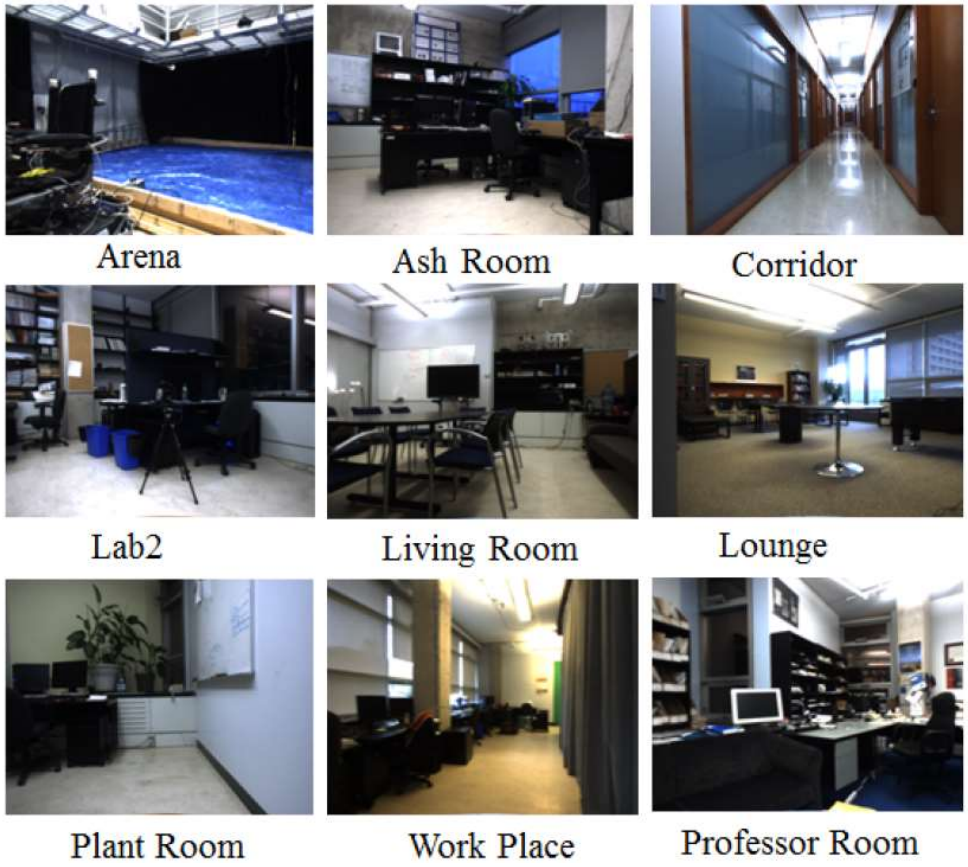
Veículos Autónomos

# Aplicações populares das CNN



Identificação de peões

# Aplicações populares das CNN

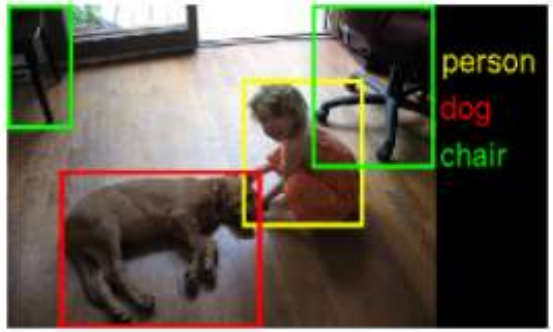



Identificação de ambientes interiores

# ImageNet

ImageNet (ImageNet Large Scale Visual Recognition Challenge) Dataset




O ImageNet foi uma competição que se realizou entre 2010 e 2017 e que visou avaliar sistemas de deteção de objetos e classificação de imagens

Reúne mais de 15 milhões de imagens de alta-resolução etiquetadas cobrindo cerca de 22000 categorias

A ideia de criar o ImageNet veio da Professora Fei-Fei Li, da Universidade de Stanford em 2006

O ImageNet Large Scale Visual Recognition Challenge (ILSVRC) usa "apenas" 1,3 milhões de imagens no conjunto de treino, 50 mil imagens no conjunto de validação e 1 milhão de imagens no conjunto de teste



O que serão estes números?

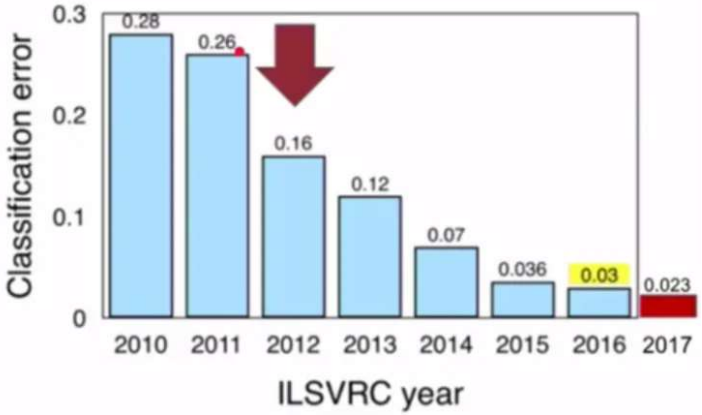
# ImageNet

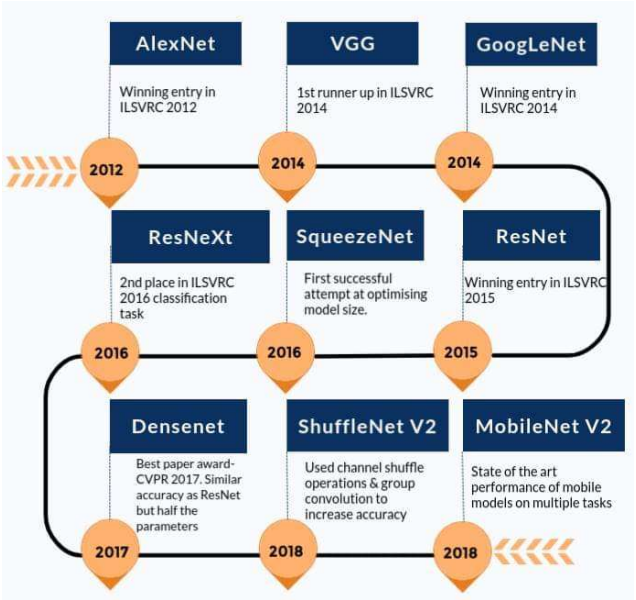
Para cada desafio anual eram publicados datasets próprios

ILSVRC 2017

- LOC Dataset – localização de objetos entre 1000 categorias
- DET Dataset – deteção de objetos entre 200 categorias classificadas em imagens
- VID Dataset - deteção de objetos entre 200 categorias classificadas em vídeos

O ILSVRC foi muito importante para o sucesso das Convolutional Neural Networks (CNN) na área de Processamento de Imagem e Visão por Computador, permitindo que sistemas de Deep Learning com CNN ultrapassassem o desempenho do ser humano na classificação de itens em imagens



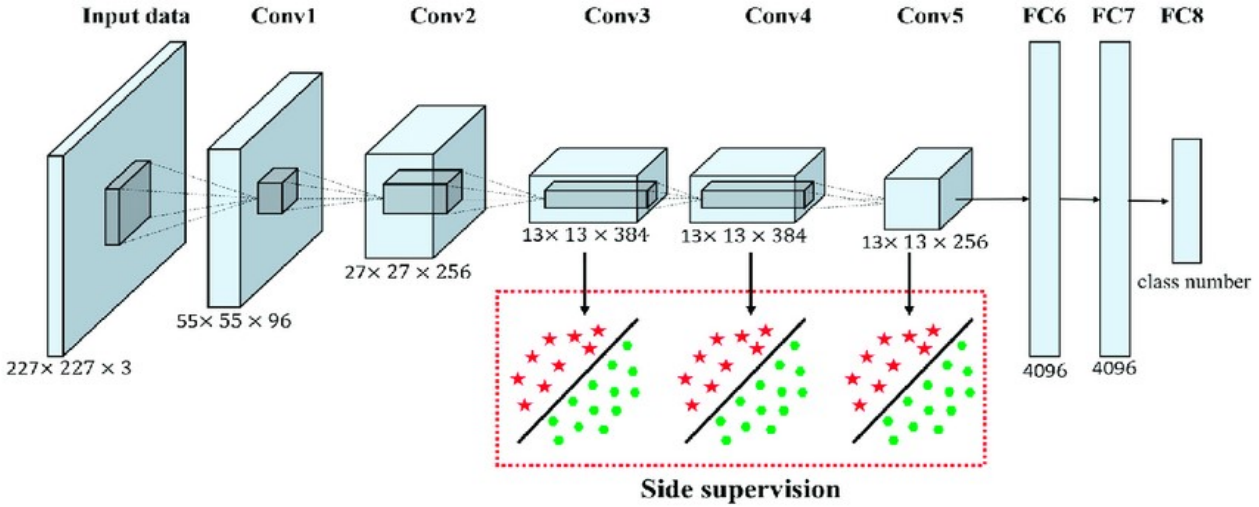
# ImageNet

A **AlexNet** foi a rede vencedora da competição em **2012**

A equipa de Alex Krizhevsky treinou uma CNN usando GPUs

A AlexNet foi então responsável pelo Boom das CNN na área da Imagem, fazendo com que a taxa de erro que em 2011 era superior a 25%, caísse para pouco mais de 15%

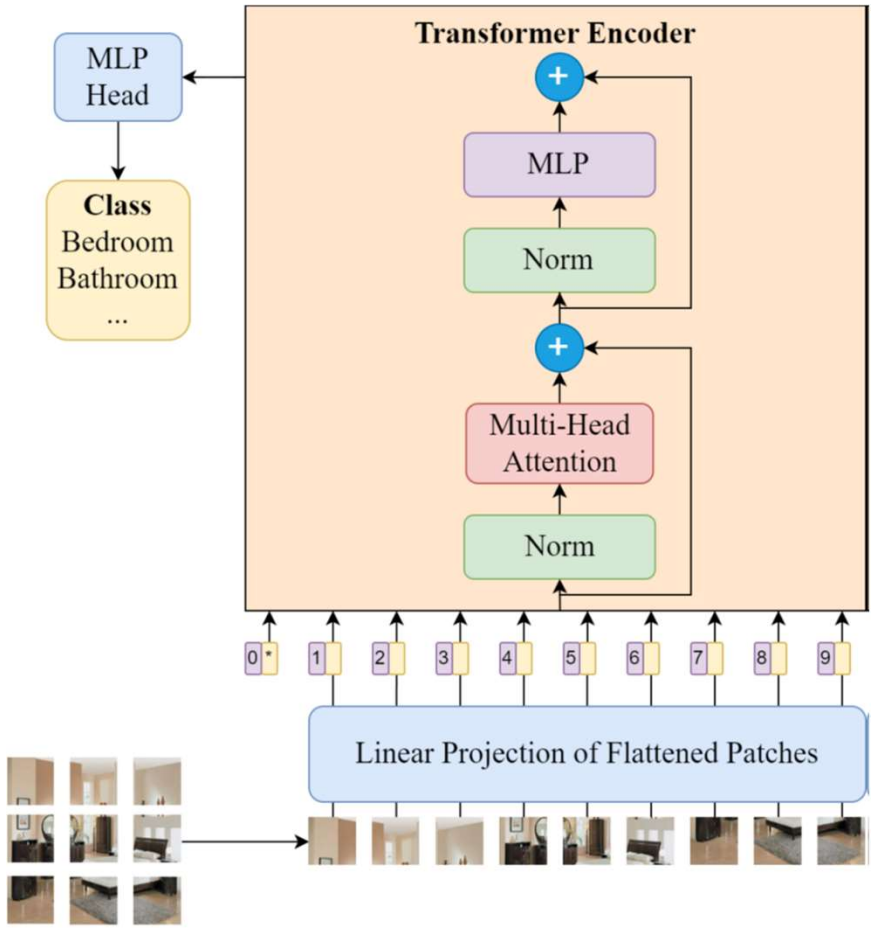
A AlexNet contém 5 camadas convolucionais e 3 completamente conectadas, dispõe de uma função de ativação do tipo ReLU para incluir não-linearidade e usa vários GPUs no treino. A rede envolve cerca de 60 milhões de parâmetros. Usa também pooling de sobreposição para diminuir o erro.




https://machinelearningknowledge.ai/popular-image-classification-models-in-imagenet-challenge-ilsvrc-competition-history/

# ImageNet e depois…

Em 2020 surgem os **Visual Transformers**. Os Transformers propostos em 2014 por Ashish Vaswani e que se focaram sobretudo no Processamento de Língua Natural foram adaptados para lidar com problemas de imagem, dando origem aos Visual Transformers, que demonstraram ser competidores das arquiteturas baseadas em CNN

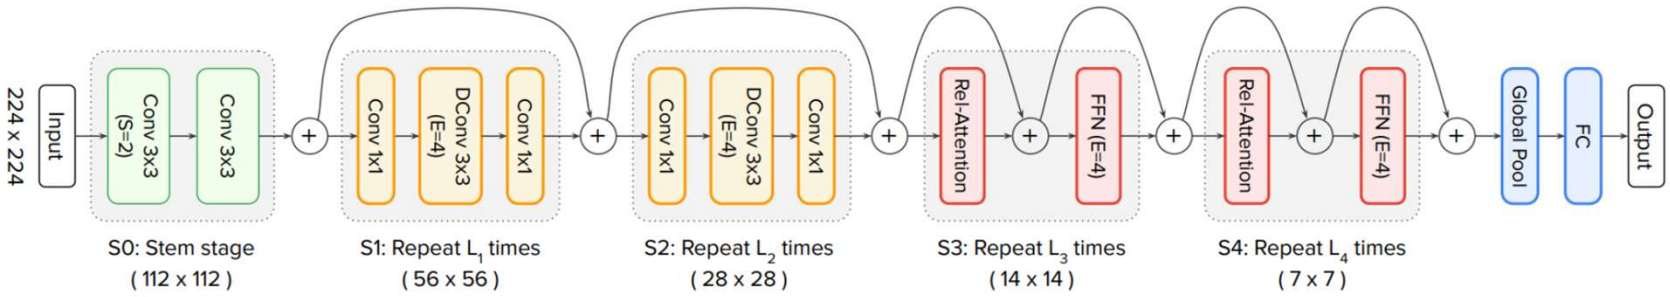


# ImageNet e depois…

Em 2021 a **CoAtNet** combina as CNN com os Visual Transformers.

Introduziu a noção de cardinalidade e blocos topológicos, o que reduz o número de parâmetros permitindo juntar mais camadas à rede.

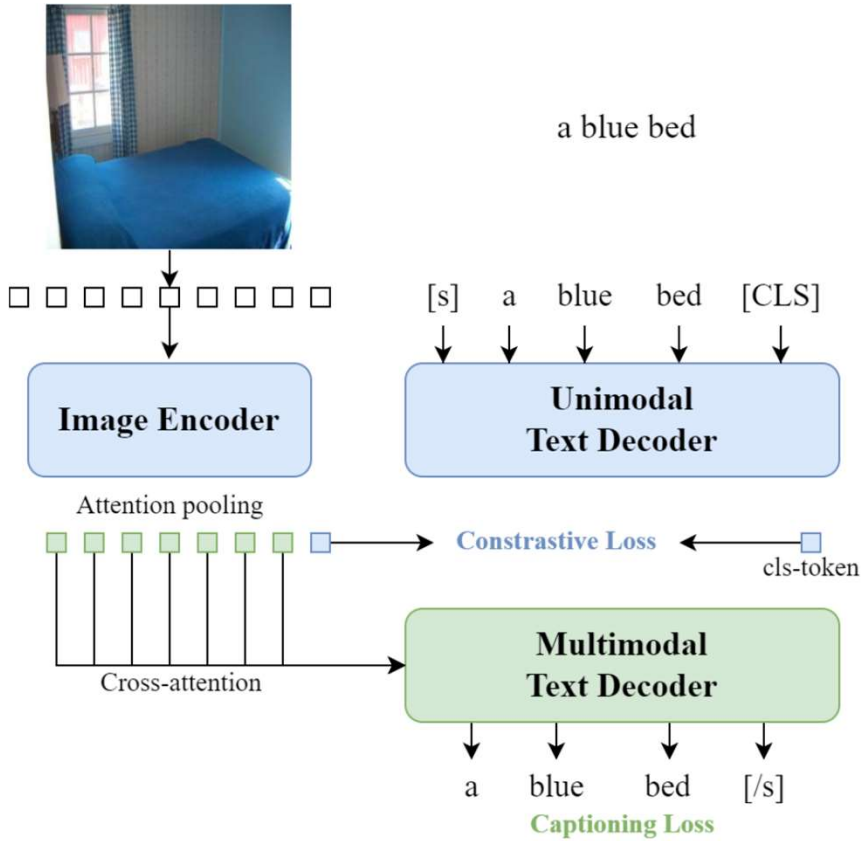
Na figura é apresentado um layout de 5 fases, onde são esperadas imagens de entrada de tamanho 224x224. Na primeira fase, composta por duas camadas convolucionais e é feita a redução para 112x112. Nas duas fases seguintes são utilizados blocos MBConv reduzindo para 56x56 e depois para 28x28. As duas fases finais utilizam uma autoatenção relativa seguida de um FFN que reduzem para 14x14 e depois para 7x7. No final passa-se por um pool global e uma camada totalmente conectada para obter a classificação final.



# ImageNet e depois…

Em 2022 surge a **CoCa – Contrastive Captioner**. Ao contrário do que acontece com os modelos anteriores, o CoCa não depende de anotações da imagem e vetores rotulados, mas prefere utilizar o conhecimento de Língua Natural ao descrever uma imagem.

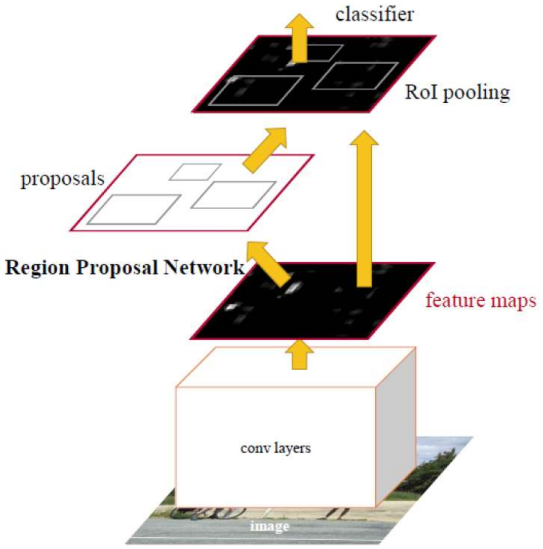
Há três elementos: o codificador de imagem, o descodificador de texto unimodal e o descodificador de texto multimodal. O processo começa por dividir uma imagem 228x228 em patches 18x18 e a associar tokens de texto e alimentá-lo tanto para o codificador de imagem como para o descodificador. A saída do codificador passa por um agrupador de atenção que ajudará a compreender melhor a imagem.

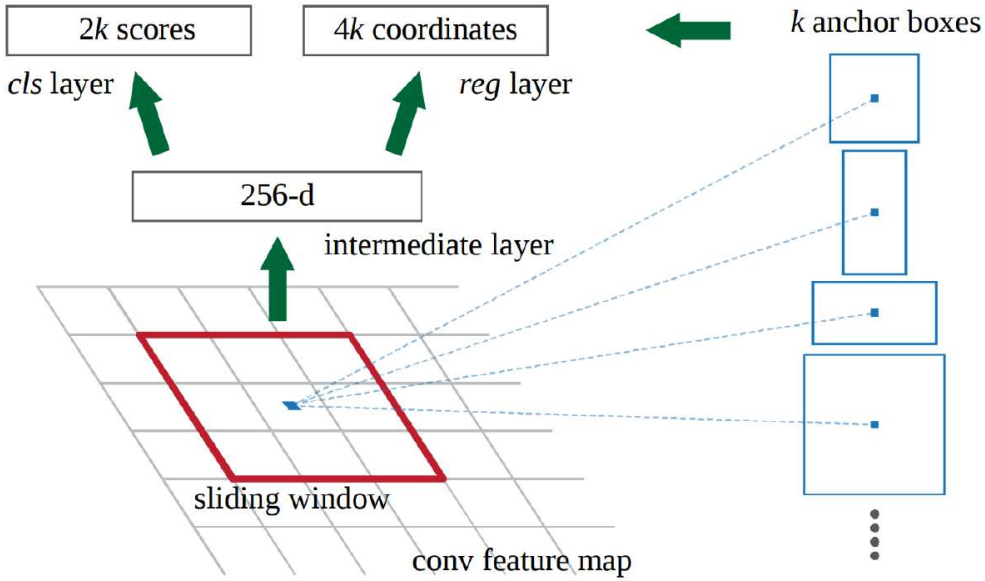


# Redes baseadas em Regiões

As Redes Neuronais Convolucionais baseadas em Regiões (R-CNN - Region-based Convolutional Network) usam mecanismos de Region Proposal Network (RPN)

A Faster é uma R-CNN que gera anchor boxes, regiões da imagem onde há possibilidade de aparecerem objetos




Eduardo Todt, Bruno Krinsky, Convolutional Neural Networks, UFPR

# Redes baseadas em Regiões

A YOLO (You Only Look Once) é uma R-CNN onde se criam boxes associadas a possibilidades de ocorrência de objetos, as de menor probabilidade são descartadas, ficando as restantes

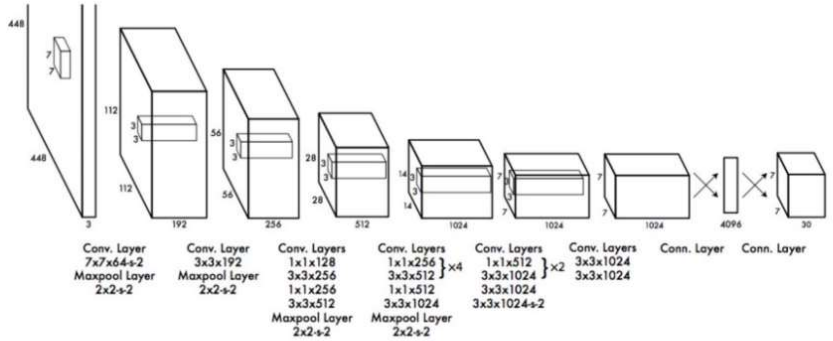
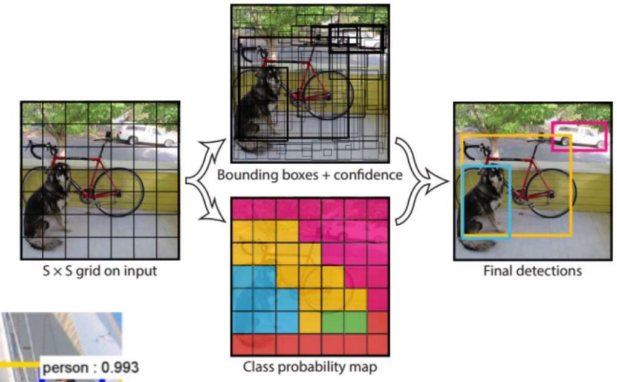
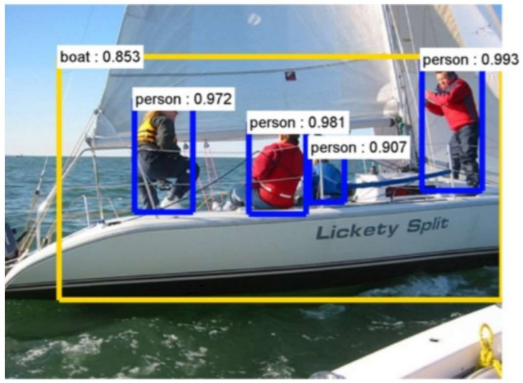



**Figure 3: The Architecture.** Our detection network has 24 convolutional layers followed by 2 fully connected layers. Alternating $1 \times 1$ convolutional layers reduce the features space from preceding layers. We pretrain the convolutional layers on the ImageNet classification task at half the resolution ($224 \times 224$ input image) and then double the resolution for detection.

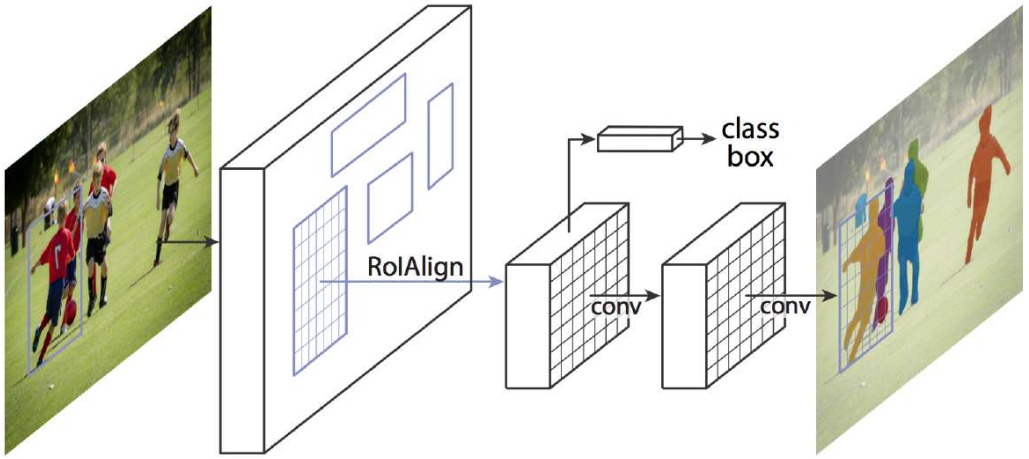



https://towardsdatascience.com/yolo-you-only-look-once-real-time-object-detection-explained-492dc9230006

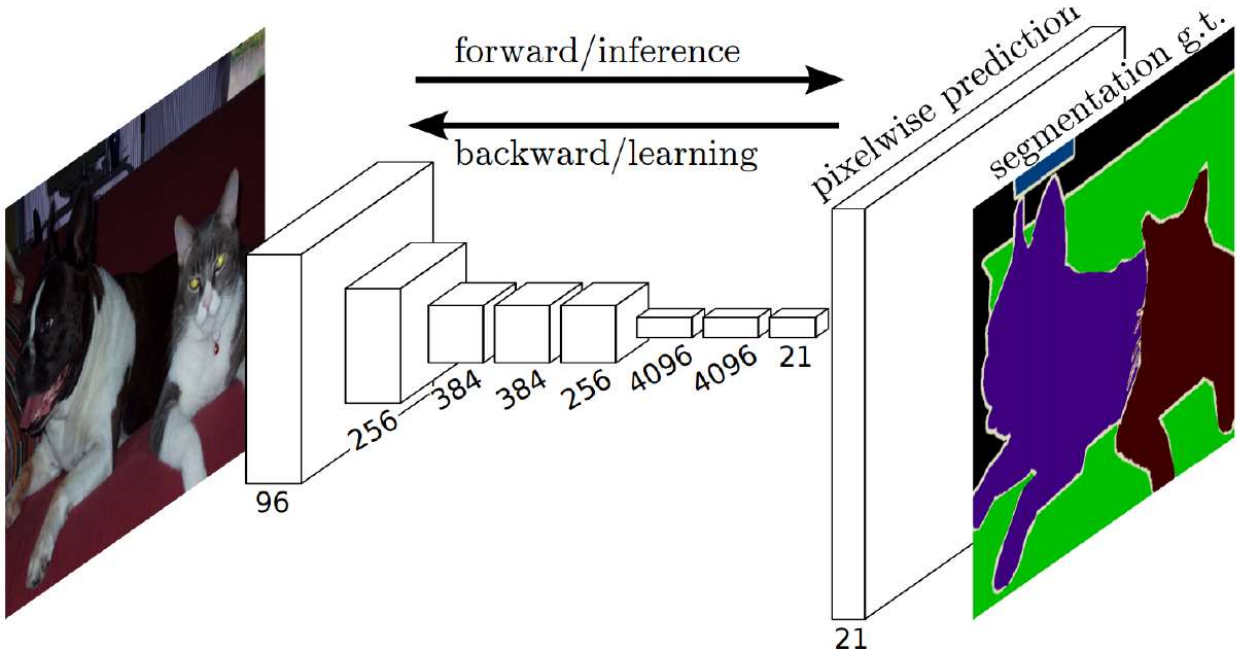
## Redes baseadas em Regiões

A Mask é outra R-CNN com 3 tarefas: classificação, deteção e segmentação



## Redes Convolucionais Completas - Segmentação

Nas Fully Convolutional Networks (FCN) a ideia é classificar cada pixel como podendo pertencer a um mesmo objeto (no fundo fazendo um género de segmentação da imagem)



# Plataformas/Linguagens para Visão por Computador

- OpenCV – muito completa, liga com C++ e Python e para diversos ambientes (Linux, Windows, Android). O processamento fica mais lento em grandes volumes de dados. Não permite de base desenvolvimento em GPU
- Matlab – permite código conciso, de leitura e debug fáceis. É bom para prototipagem e I&D, mas não é rápido. É pago
- Aforge.NET/Accord.NET – adequado para quem desenvolve em C# e .NET, com muitas operações sobre as imagens, mas não permite as capacidades de um OpenCV
- TensorFlow – hoje em dia muita da Visão por Computador é feita com recurso a técnicas de Machine Learning (ML), em particular Deep Learning (DL). Mas necessita dominar esses temas, além de ser uma plataforma muito exigente em termos de hardware, tirando partido de GPUs
- CUDA – plataforma da NVIDIA para computação paralela, tirando partido dos GPUs. Exige dominar bem computação paralela e GPU
- SimpleCV – adequada para prototipagem e quando não é necessário entrar em profundidade em Processamento de Imagem e Visão por Computador
- GPUImage – biblioteca iOS que aplica efeitos e filtros acelerados por GPU à imagem
- Há ainda plataformas de Visão por Computador como um serviço: Google Cloud Vision, Mobile Vision, Amazon Rekognition, Microsoft Azure Computer Vision
- Também pode ser feito desenvolvimento com várias linguagens e algumas bibliotecas, como por exemplo usando Python com SciPy e NumPy

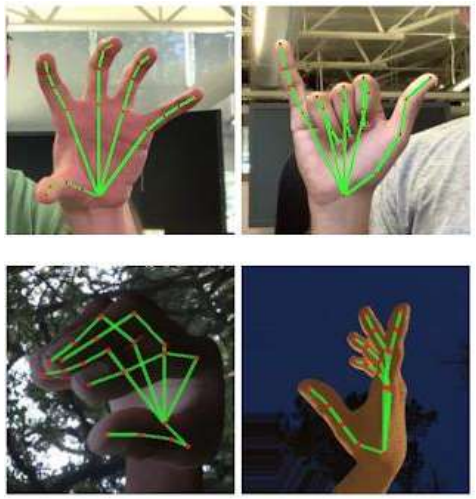
# Para saber mais sobre Visão por Computador

- Unidade Curricular de **Redes Neuronais Artificiais e Aprendizagem Profunda (RNAAPIA)** do **Mestrado em Engenharia de Inteligência Artificial (MEIA)** do ISEP
- Hoje em dia grande parte do que se faz em Visão por Computador usa Deep Learning, nomeadamente Redes Neuronais Convolucionais e Visual Transformers
- O tema é ainda abordado em RAINTIA (Robótica e Ambientes Inteligentes) ligado à parte da Robótica

MEIA
MESTRADO ENGENHARIA INTELIGÊNCIA ARTIFICIAL

Challenges 4Teams
MEIA

Demo Day
MEIA



Equipa de IA aplicada à Saúde do MEIA usa Deep Learning para Reconhecer palavras de Língua Gestual




Equipa de IA aplicada a Recursos Humanos do MEIA usa Deep Learning para avaliação do desempenho de um candidato numa entrevista