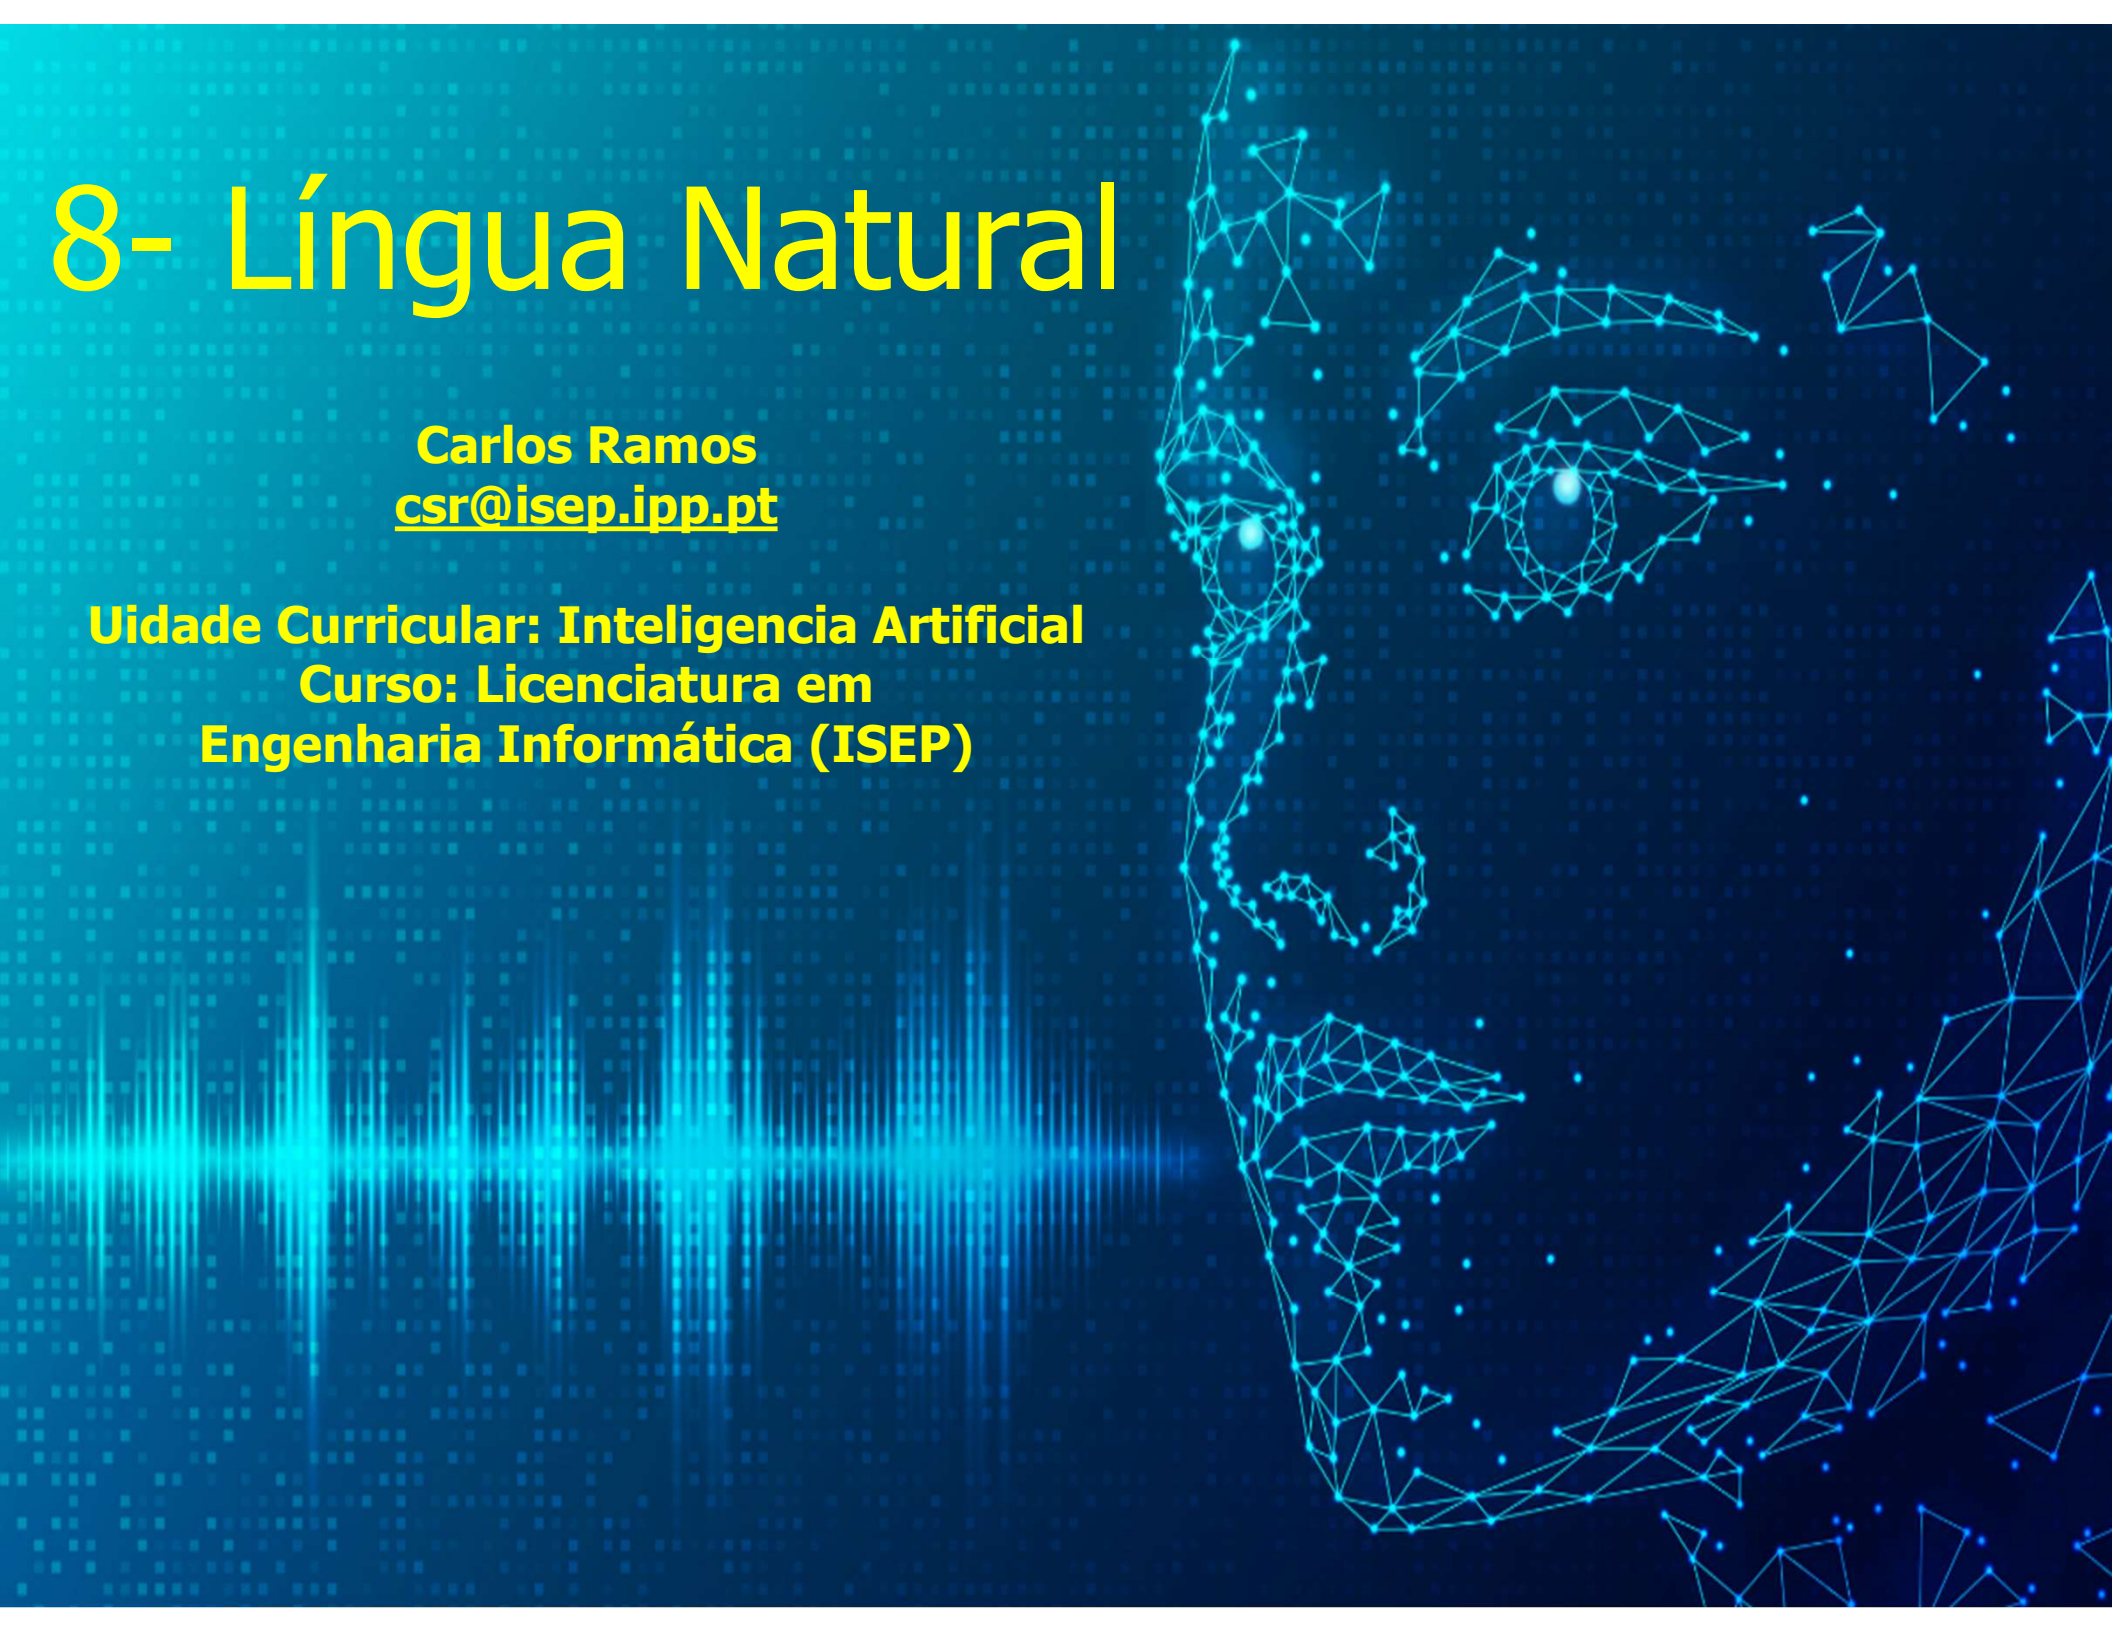
8- Língua Natural

Carlos Ramos
csr@isep.ipp.pt

Uidade Curricular: Inteligencia Artificial
Curso: Licenciatura em Engenharia Informática (ISEP)



Língua Natural

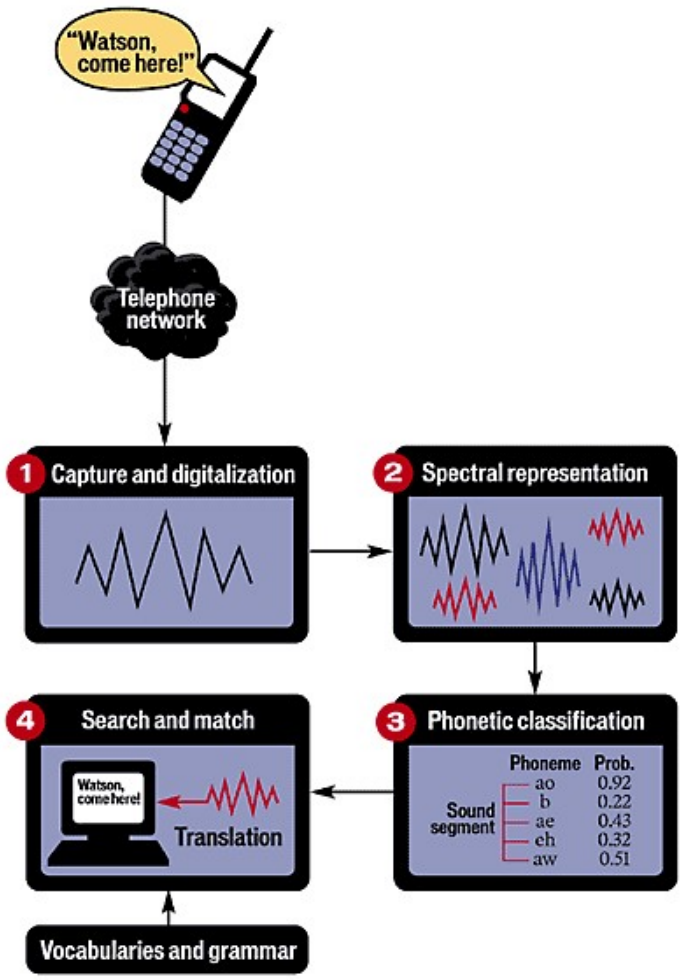
A Língual Natural, ou Linguagem Natural, é a área da Inteligência Artificial que se debruça sobre a compreensão textual, tarefa simples para os seres humanos, mas complicada para os sistemas computacionais

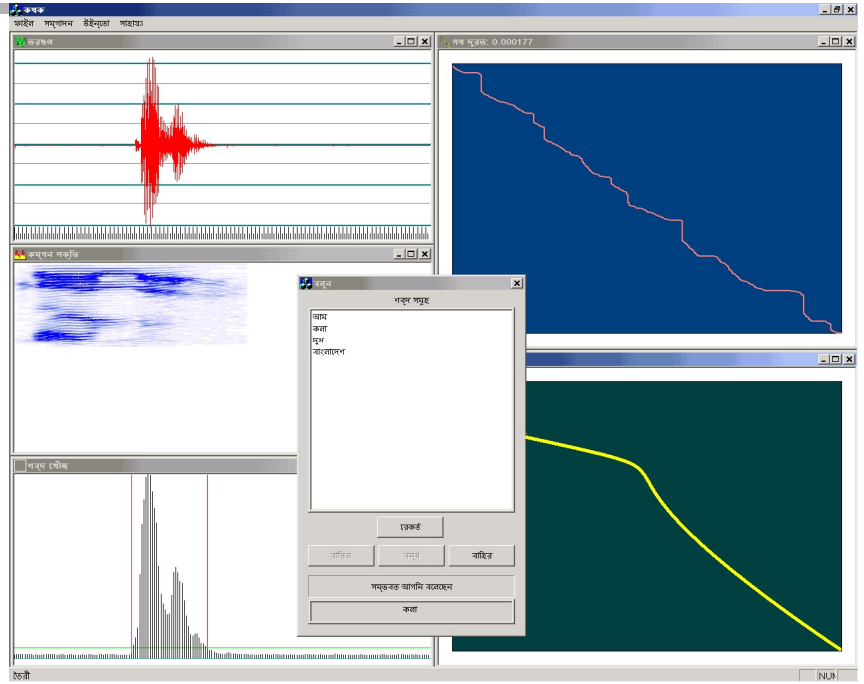
É entendido que a entrada de um sistema de Língua Natural é uma informação textual, onde já estão identificadas as palavras, por exemplo através de uma "string" ou lista de palavras. Vejamos um exemplo:

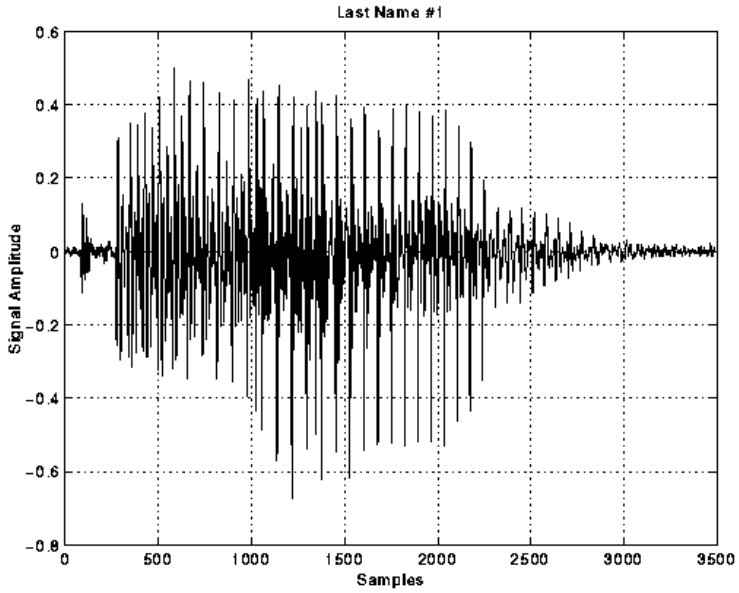
"o menino joga a bola" ou se preferirmos [o,menino,joga,a,bola]

O reconhecimento da voz e da fala pode gerar a entrada para um programa de LN, mas corresponde a uma área diferente, usando técnicas de Processamento de Sinal para proceder ao reconhecimento de fonemas e palavras. É usual em sistemas de legendagem automática e de interação com o utilizador (telemóveis, carros, assistentes pessoais como Alexa, Siri ou Google Assistant)

Reconhecimento da Voz e da Fala



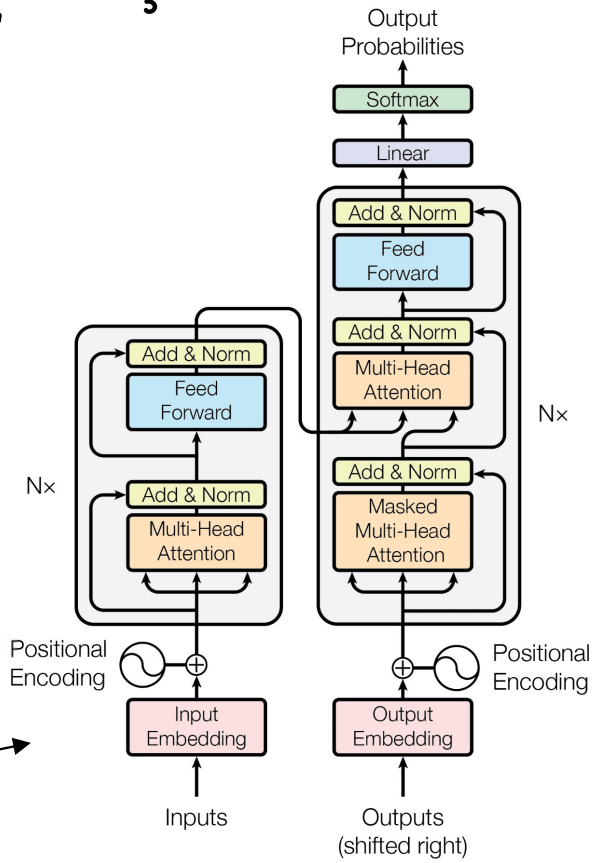




Processamento de Língua Natural & IA Generativa

A Língua Natural pode ser usada para diveras aplicações:

- Compreensão de frases isoladas
- Compreensão de Textos → ChatGPT
- Geração de Texto
- Tradução Automática → DeepL
- Interfaces (textuais ou voz) bots, assistentes → Siri, alexa
- Geração de Código (Programação)
- Acesso a Informação
- Mineraçao de Texto



A arquitetura Transformer está na origem do grande sucesso da IA Generativa, com um produto revolucionário (ChatGPT) emergindo no final de 2022
Iremos ver isto depois

Sintaxe

- Na Língua Natural encontramos duas grandes áreas: a sintaxe e a semântica
- Na sintaxe definimos o modo como cada palavra é escrita, no fundo o vocabulário, e as sequências possíveis de palavras segundo o seu tipo, ou seja a Gramática
- Um programa em Língua Natural só conhece um vocabulário limitado e uma gramática limitada. Esse tem sido um dos problemas típicos nas interfaces por Língua Natural, pois uma falha na compreensão de uma frase pode dever-se ao facto da Base de Conhecimento do sistema ser limitada e não devido a erros de sintaxe

Semântica

A semântica analisa o significado das frases que construímos. As palavras de uma frase podem estar correctamente escritas e obedecerem a uma construção gramatical viável, mas a frase pode não fazer sentido

Convém notar que o problema é muito complexo. Há frases às quais podemos atribuir vários significados. Quando inseridas num texto podemos retirar algumas ambiguidades, mas isoladamente a sua compreensão não é possível

- Maria escolheu direito – pode ser interpretada como uma escolha acertada ou como a escolha de um curso de direito (embora nesse caso se devesse escrever Direito)
- O rapaz viu o homem na colina com o telescópio – quem estava na colina (o rapaz ou o homem) e quem tinha o telescópio (o rapaz ou o homem)

Análise da Sintaxe

Para a análise da sintaxe o mais habitual é a escrita de uma Gramática e de um Interpretador, tal como se costuma fazer para a implementação de uma linguagem de programação. O interpretador irá atribuir uma árvore de identificação (parsing) a cada frase

Frase → SN SV

SN → Artigo Nome

SN → Nome

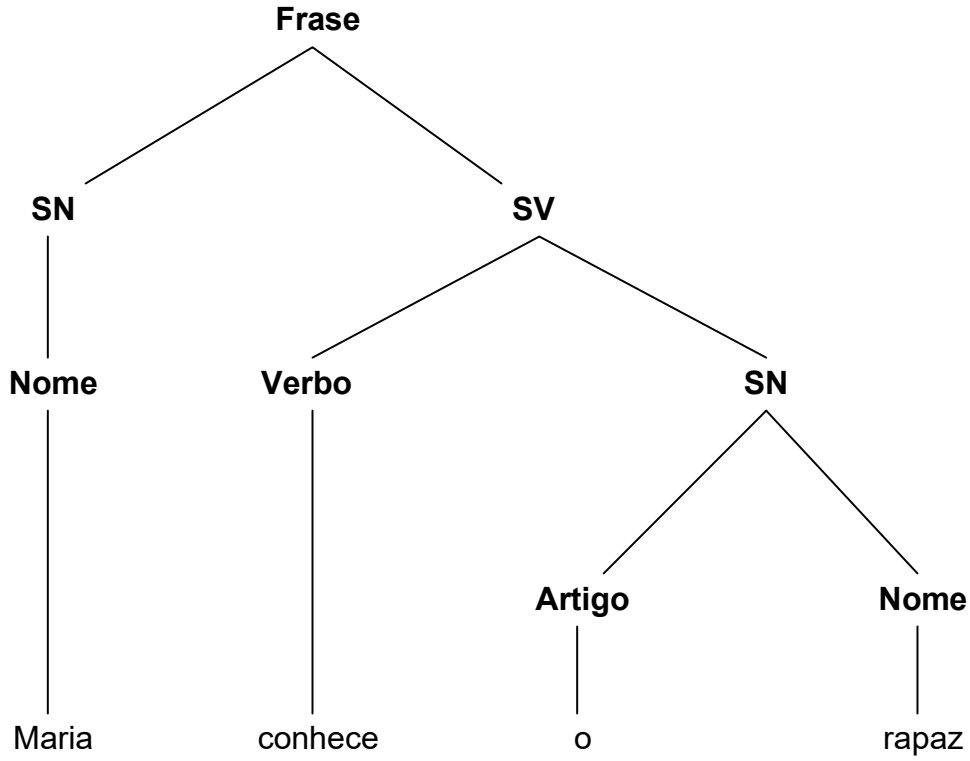
SV → Verbo SN

SV → Verbo

Artigo → o | a

Nome → rapaz | Maria | bola

Verbo → conhece | joga



Análise da Sintaxe

Exemplo de um tratamento simples sobre a Sintaxe feito em PROLOG (Gramática e Vocabulário), estamos a representar a Sintaxe por um sistema baseado em regras

```
frase --> sintagma_nominal(N), sintagma_verbal(N).
sintagma_nominal(N) --> artigo(G,N), nome(G,N).
sintagma_nominal(N) --> nome(_,N).
sintagma_verbal(N) --> verbo(N), sintagma_nominal(_,_).

artigo(m,s) --> [o].
artigo(f,p) --> [as].
nome(m,s) --> [rapaz].
nome(f,p) --> [cartas].
verbo(s) --> [joga].
verbo(p) --> [jogam].
```

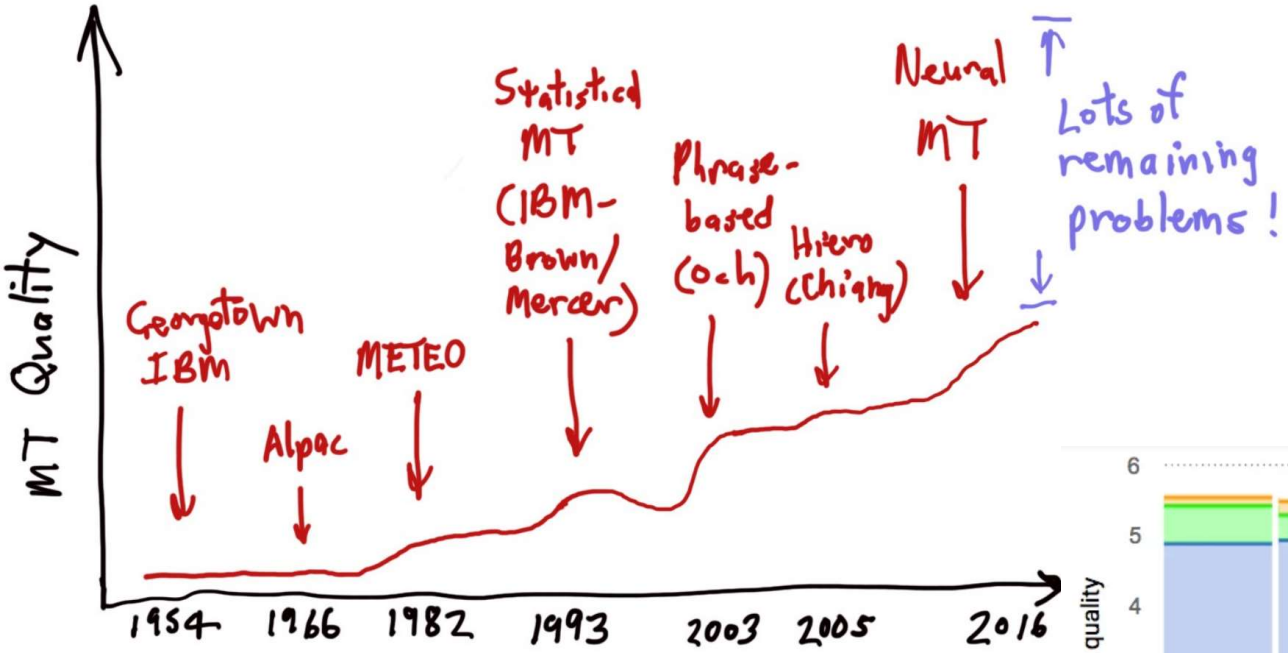
Nota: --> é um operador do PROLOG que basicamente substitui o :- e coloca mais 2 argumentos em cada termo

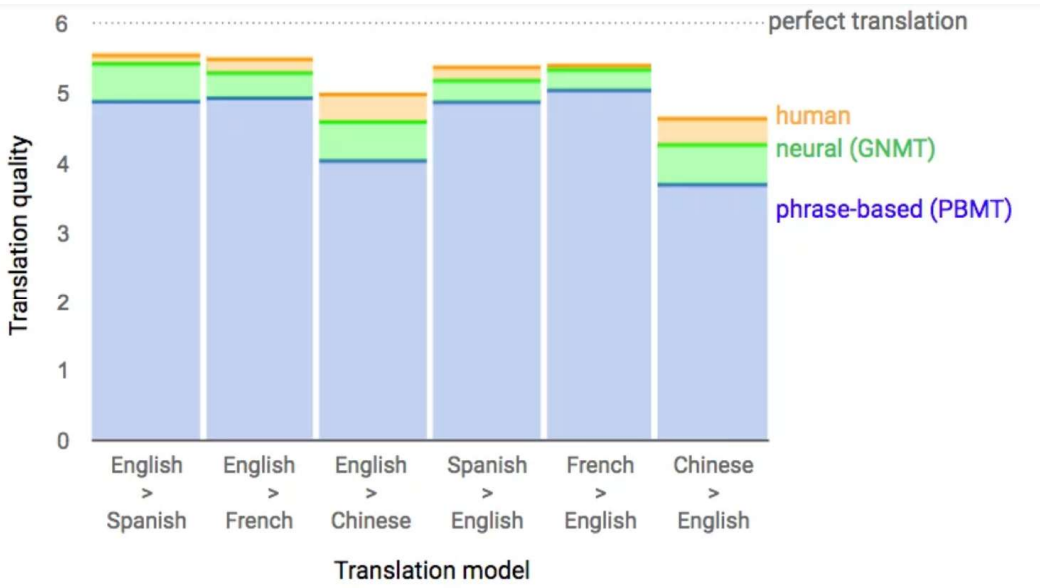
A chamada poderia ser

```
?-frase([o,rapaz,joga,as,cartas],L).
L=[ ]
```

Tradução Automática

A Tradução automática é um dos grandes desafios da IA desde os primórdios





Retirado de
https://nlp.stanford.edu/projects/nmt/Luong-Cho-Manning-NMT-ACL2016-v4.pdf

Tradução Automática

O Sistema **METEO** (1981) desenvolvido no Canadá faz a tradução bidirectional de previsões do tempo entre Francês e Inglês com base em Regras

Aujourd'hui, 26 novembre

Généralement nuageux. Vents du sud-ouest de 20 km/h avec rafales à 40 devenant légers cet après-midi. Températures stables près de plus 2.

Ce soir et cette nuit, 26 novembre

Nuageux. Neige débutant ce soir. Accumulation de 15 cm. Minimum zéro.

Today, 26 November

Mainly cloudy. Wind southwest 20 km/h gusting to 40 becoming light this afternoon. Temperature steady near plus 2.

Tonight, 26 November

Cloudy. Snow beginning this evening. Amount 15 cm. Low zero.

Nota: é bem mais simples fazer tradução num domínio específico que geral

Tradução Automática

A tradução automática baseada em conhecimento explicitado através de regras é elegante, mas tem grandes limitações:

- Se a compreensão de frases isoladas já levanta problemas de análise semântica o uso de mais do que uma língua levanta ainda mais problemas, a tradução não pode ser feita apenas traduzindo palavra a palavra e adaptando construções gramaticais diferentes entre línguas
- Na maioria dos casos, quer em texto escrito quer (sobretudo) em texto obtido a partir de voz, há erros nas palavras e nas construções gramaticais

Surgem então os sistemas de Tradução baseada em Estatística que se popularizaram no início deste século e usam um Corpus (grandes volumes de texto)

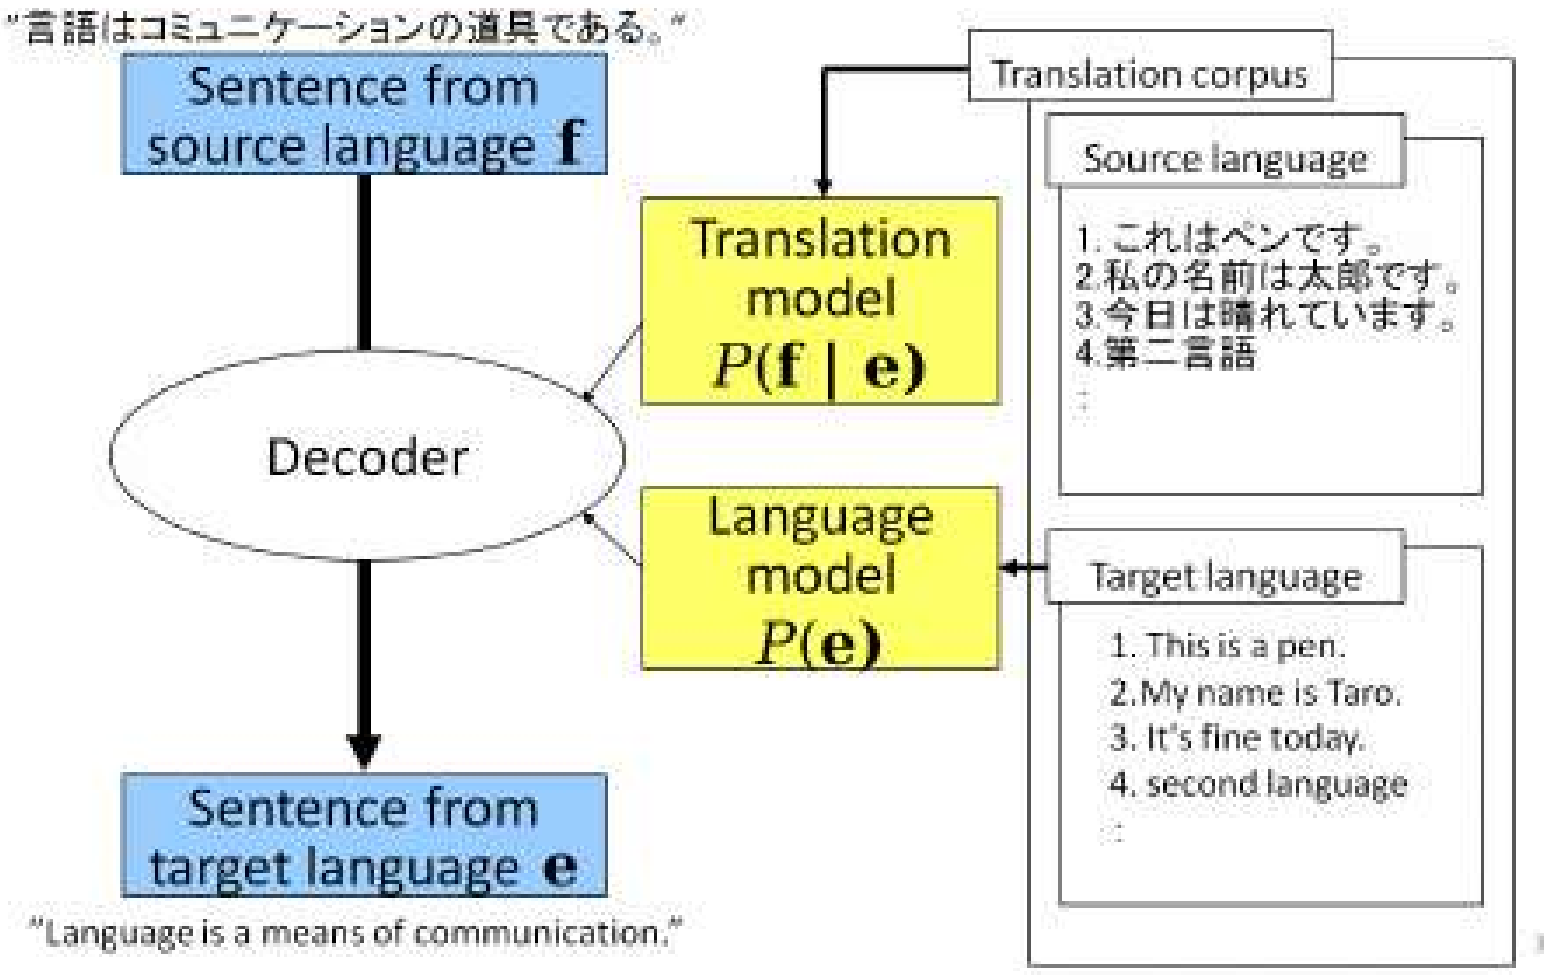
Tradução Automática

Os Corpus estão na base dos LLM (Large Language Models) que estão na origem do sucesso da IA Generativa

Tradução baseada em Corpus:

- Há um conjunto de textos na língua fonte e os mesmos textos na língua destino
  - Por exemplo a tradução de documentos nas Nações Unidas foi usada pela Google para constituir seus Corpora
- Os modelos estatísticos de Tradução Automática assumem que cada frase T numa língua é uma tradução da frase S de outra língua com uma dada probabilidade P(T|S) e a melhor tradução é a que tiver maior valor da probabilidade

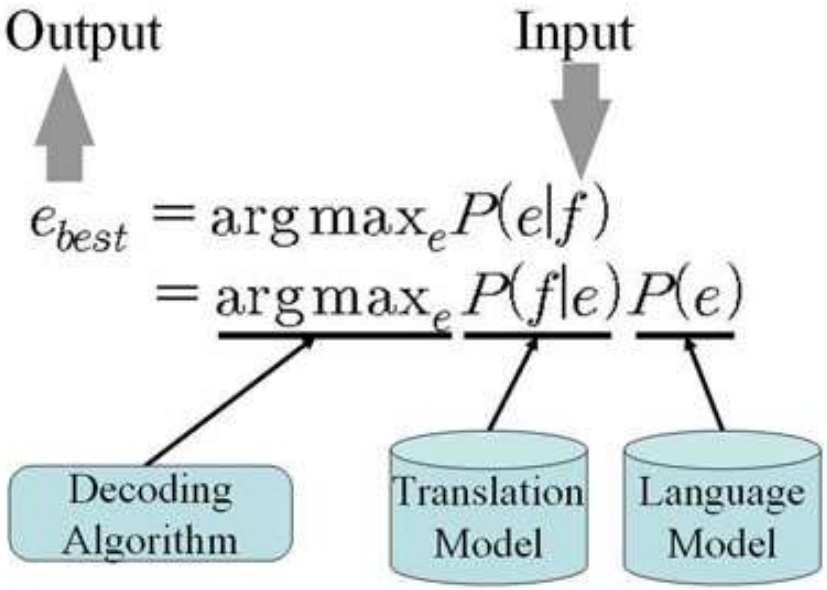
Tradução Automática



Retirado de
https://www.researchgate.net/figure/Statistical-Machine-Translation-system_fig3_267940056

Tradução Automática

- *P(f | e)* está relacionado com a identificação (matching) de palavras
- *P(e)* está relacionado com a correção da construção gramatical na linguagem pretendida, dá-nos a probabilidade de uma sequência de palavras ser viável
- *argmax* vai encontrar a tradução *e* com maior valor de probabilidade para traduzir *f*
- Obter *argmax (P(e | f))* é a função principal do Descodificador (Decoder)



Retirado de http://nlp.postech.ac.kr/research/previous_research/smt/

Tradução Automática

- Uma maneira de lidar com P(e) é o uso de n-gramas (n-grams), ou seja, ver num corpus a probabilidade de aparecer uma dada sequência de n palavras consecutivas de uma frase
  - Por exemplo, na frase "I have a black dog" temos os 3-gramas "I have a", "have a black" e "a black dog"
  - O 3-grama "I have a" é muito mais provável que o "a have I"
  - Vamos incorporando novas palavras no n-grama e calculando a probabilidade condicionada
  - A contagem de sequências de palavras numa query ao Google pode ser um bom indicador

Retirado de
https://www.researchgate.net/publication/287196051_An_Overview_of_Statistical_Machine_Translation

Tradução Automática

Assunção de Markov de ordem n

- Numa sequência de palavras uma dada palavra depende normalmente de uma sequência de palavras anteriores, não é necessário considerar todas as anteriores

$$p(x_1, x_2, \ldots, x_T) = \prod_{t=1}^{T} p(x_t | x_1, \ldots, x_{t-1})$$

$$\approx \prod_{t=1}^{T} p(x_t | x_{t-n}, \ldots, x_{t-1})$$

Tradução Automática

ON VOIT JON À LA TÉLÉVISION

	good English? P(E)	good match to French? P(F|E)
Jon appeared in TV.		✓
It back twelve saw.		
In Jon appeared TV.		✓
Jon is happy today.	✓	
Jon appeared on TV.	✓	✓
TV appeared on Jon.		✓
Jon was not happy.	✓	

Retirado de https://pt.slideshare.net/hbnair080/statistical-machine-translation

Tradução Automática

Os tradutores automáticos de maior sucesso hoje em dia usam a aprendizagem automática, em particular as Redes Neuronais com Deep Learninig, conduzindo ao que se conhece como Neural Machine Translation (NTM)

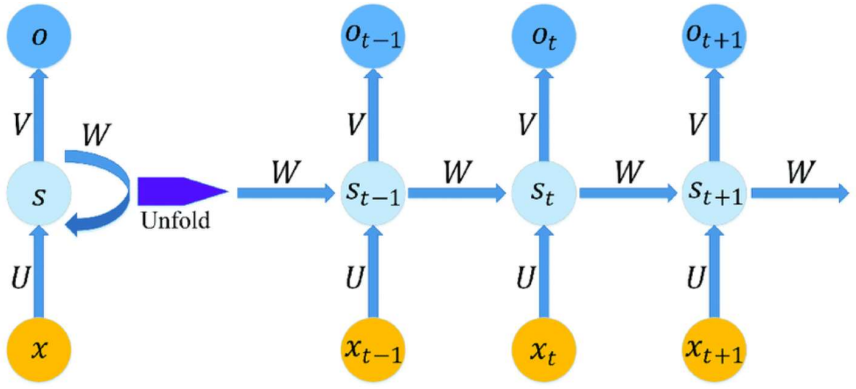
A arquitetura de base da NMT foi a arquitetura Encoder-Decoder, constituída por 2 Redes Neuronais Recorrentes

Tradução Automática

Os tradutores automáticos de maior sucesso hoje em dia usam a aprendizagem automática, em particular as Redes Neuronais com Deep Learninig, conduzindo ao que se conhece como Neural Machine Translation (NTM)

O modelo NTM representa as palavras como vetores densamente distribuídos que podem partilhar pesos em termos estatísticos entre palavras similares

A arquitetura de rede mais usada em NMT é a arquitetura Encoder-Decoder, constituída por 2 Redes Neuronais Recorrentes

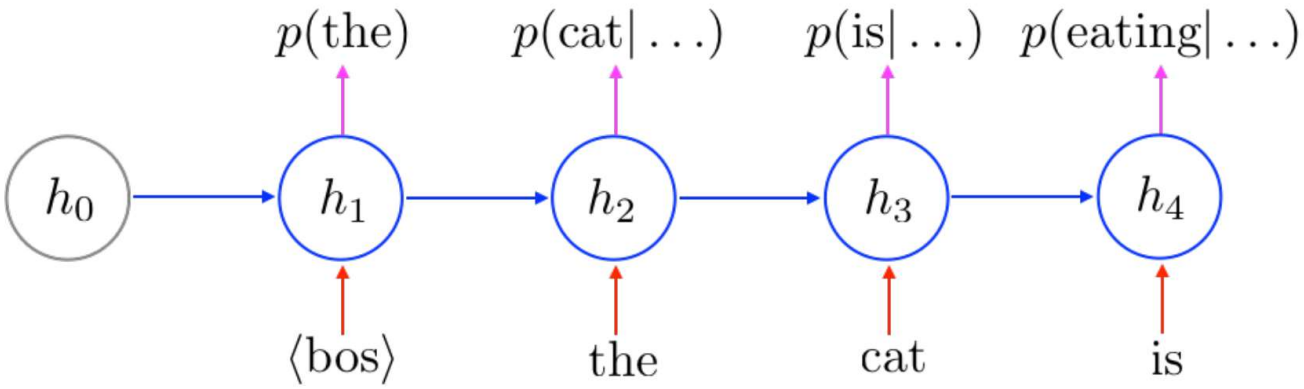


Rede Neuronal Recorrente

Tradução Automática

- As Redes Neuronais Recorrentes (RNN) vão adequar-se muito bem às cadeias de Markov, sem necessitarem considerar a assunção de Markov de ordem n

$$p(x_1, x_2, \ldots, x_T) = \prod_{t=1}^{T} p(x_t | x_1, \ldots, x_{t-1})$$



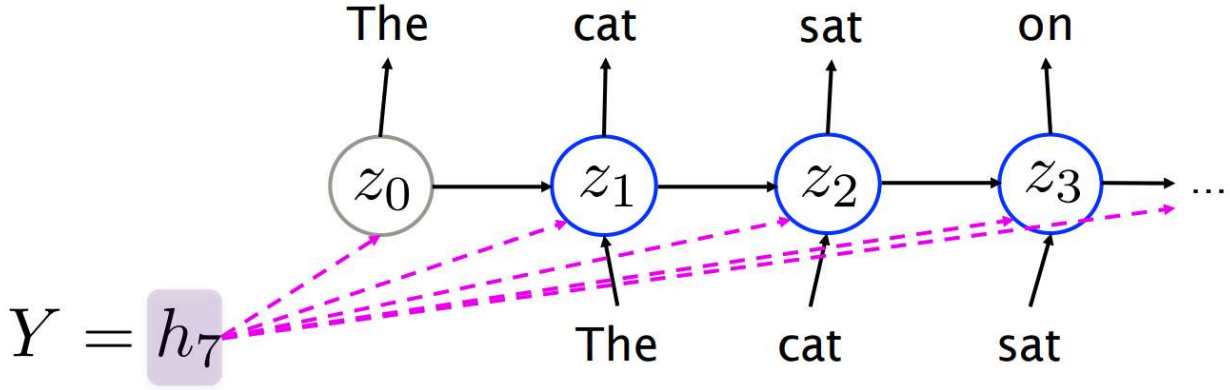
Mas as RNN também têm de ser treinadas e sujeitarem-se à Retropropagação
Constituem bons codificadores

Tradução Automática

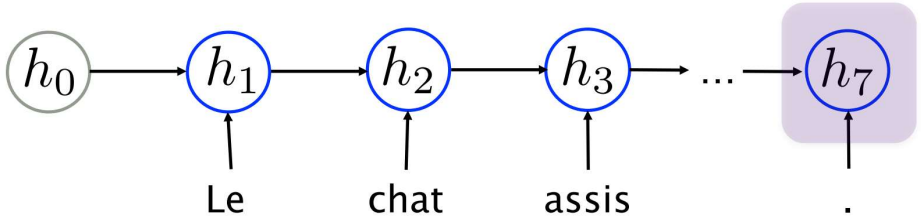
- Mas é necessário ter um par codificador-descodificador

Le chat assis sur le tapis.





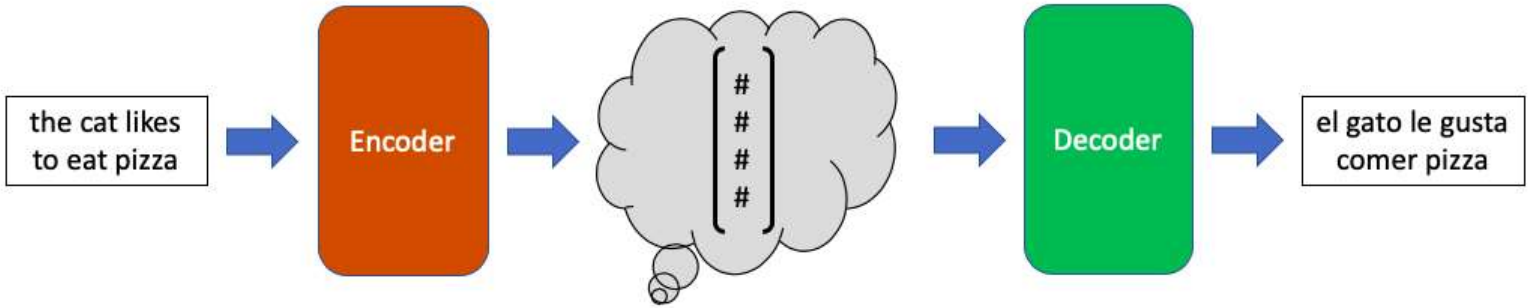
Descodificador



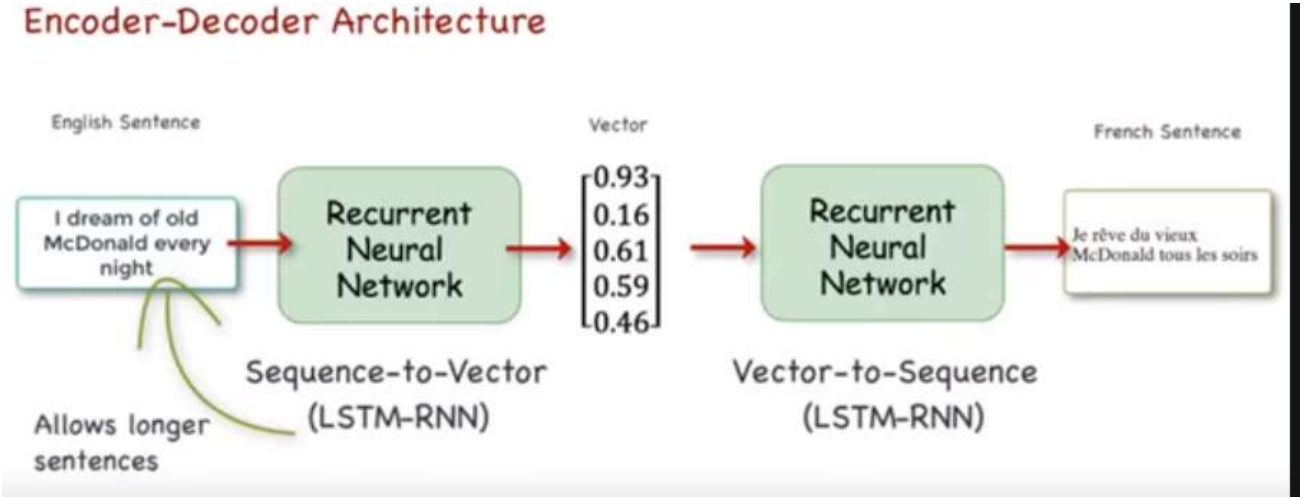
Codificador

Codificador e Descodificador são ambos RNN montadas em tandem

Tradução Automática

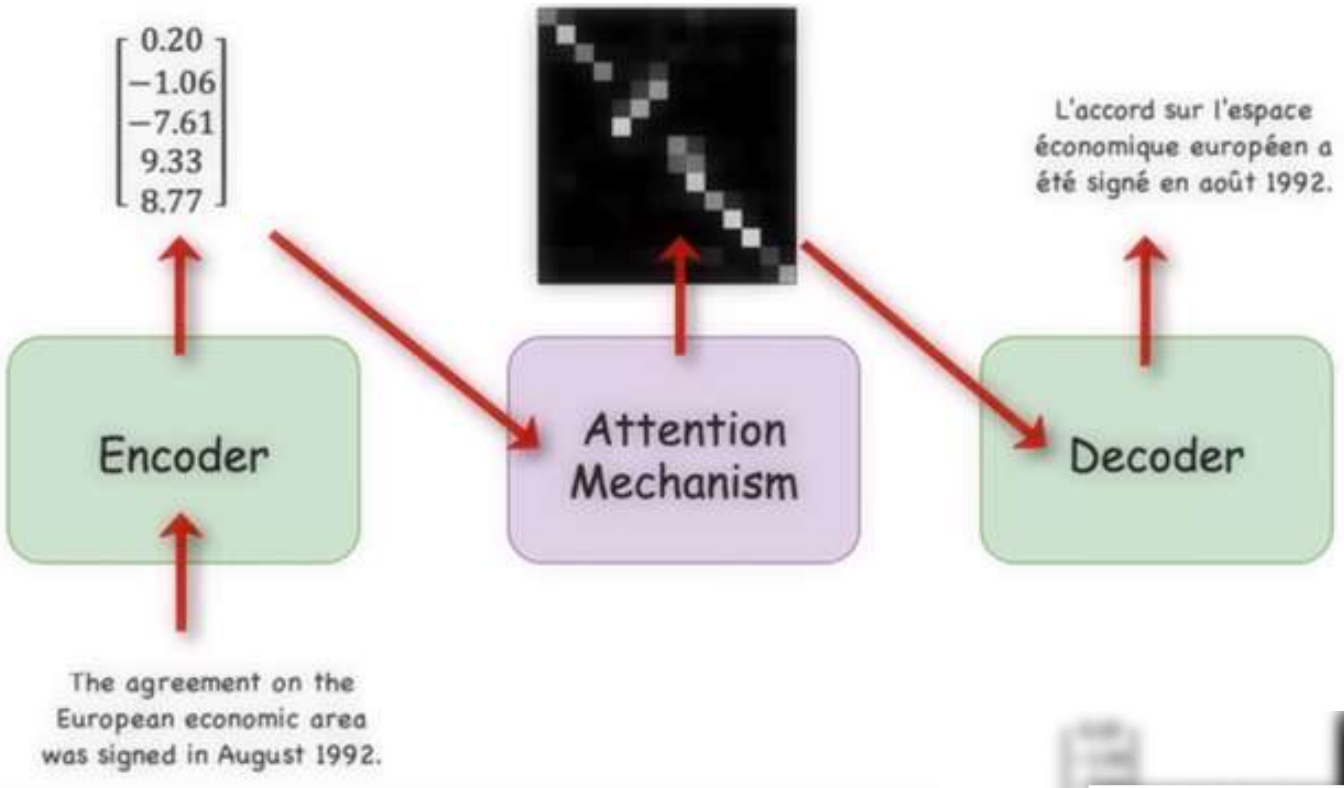


A RNN do Codificador converte uma sequência de palavras numa língua para um Vetor e a RNN do descodificador converte o vetor numa sequência de palavras noutra língua

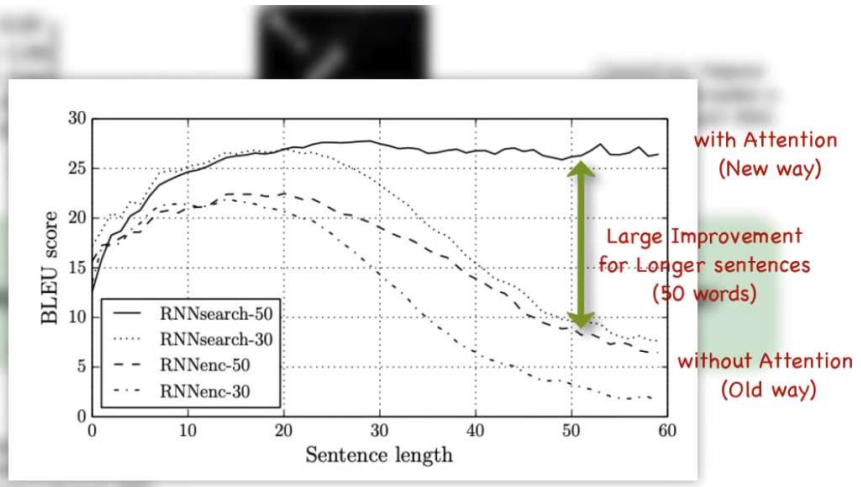


LSTM – Long Short-Term Memory, uma arquitetura de RNN

Tradução Automática



O Mecanismo de Atenção foca numa parte mais importante resultante da entrada, neste caso em palavras que são mais importantes



Source: Neural Machine Translation by jointly learning to align & translate (Bahdanau et al., 2016)

Inteligência Artificial Generativa

- É a nova revolução da IA, sobretudo depois de finais de 2022 quando a OpenAI disponibiliza o ChatGPT

- Baseado em Transformers, que surgem primeiro na sequência da evolução natural das Redes Neurais Recorrentes (RNN) e Long/Short – Term Memory (LSTM), com grande sucesso na geração de texto, sobretudo usando Large Language Models (LLM)

- Mas, sobre estes temas, vamos estudar mais no capítulo seguinte